

Maschinelles Lernen in der Fahrzeugtechnik: Auf dem Weg zum autonomen Fahren

Prof. Dr.-Ing. Michael Botsch

09.06.2017

Inhalt

Maschinelle Lernverfahren und automatisiertes Fahren

Deep-Learning und Ensemble-Methoden

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung
für autonome Fahrzeuge

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

Maschinelle Lernverfahren und automatisiertes Fahren

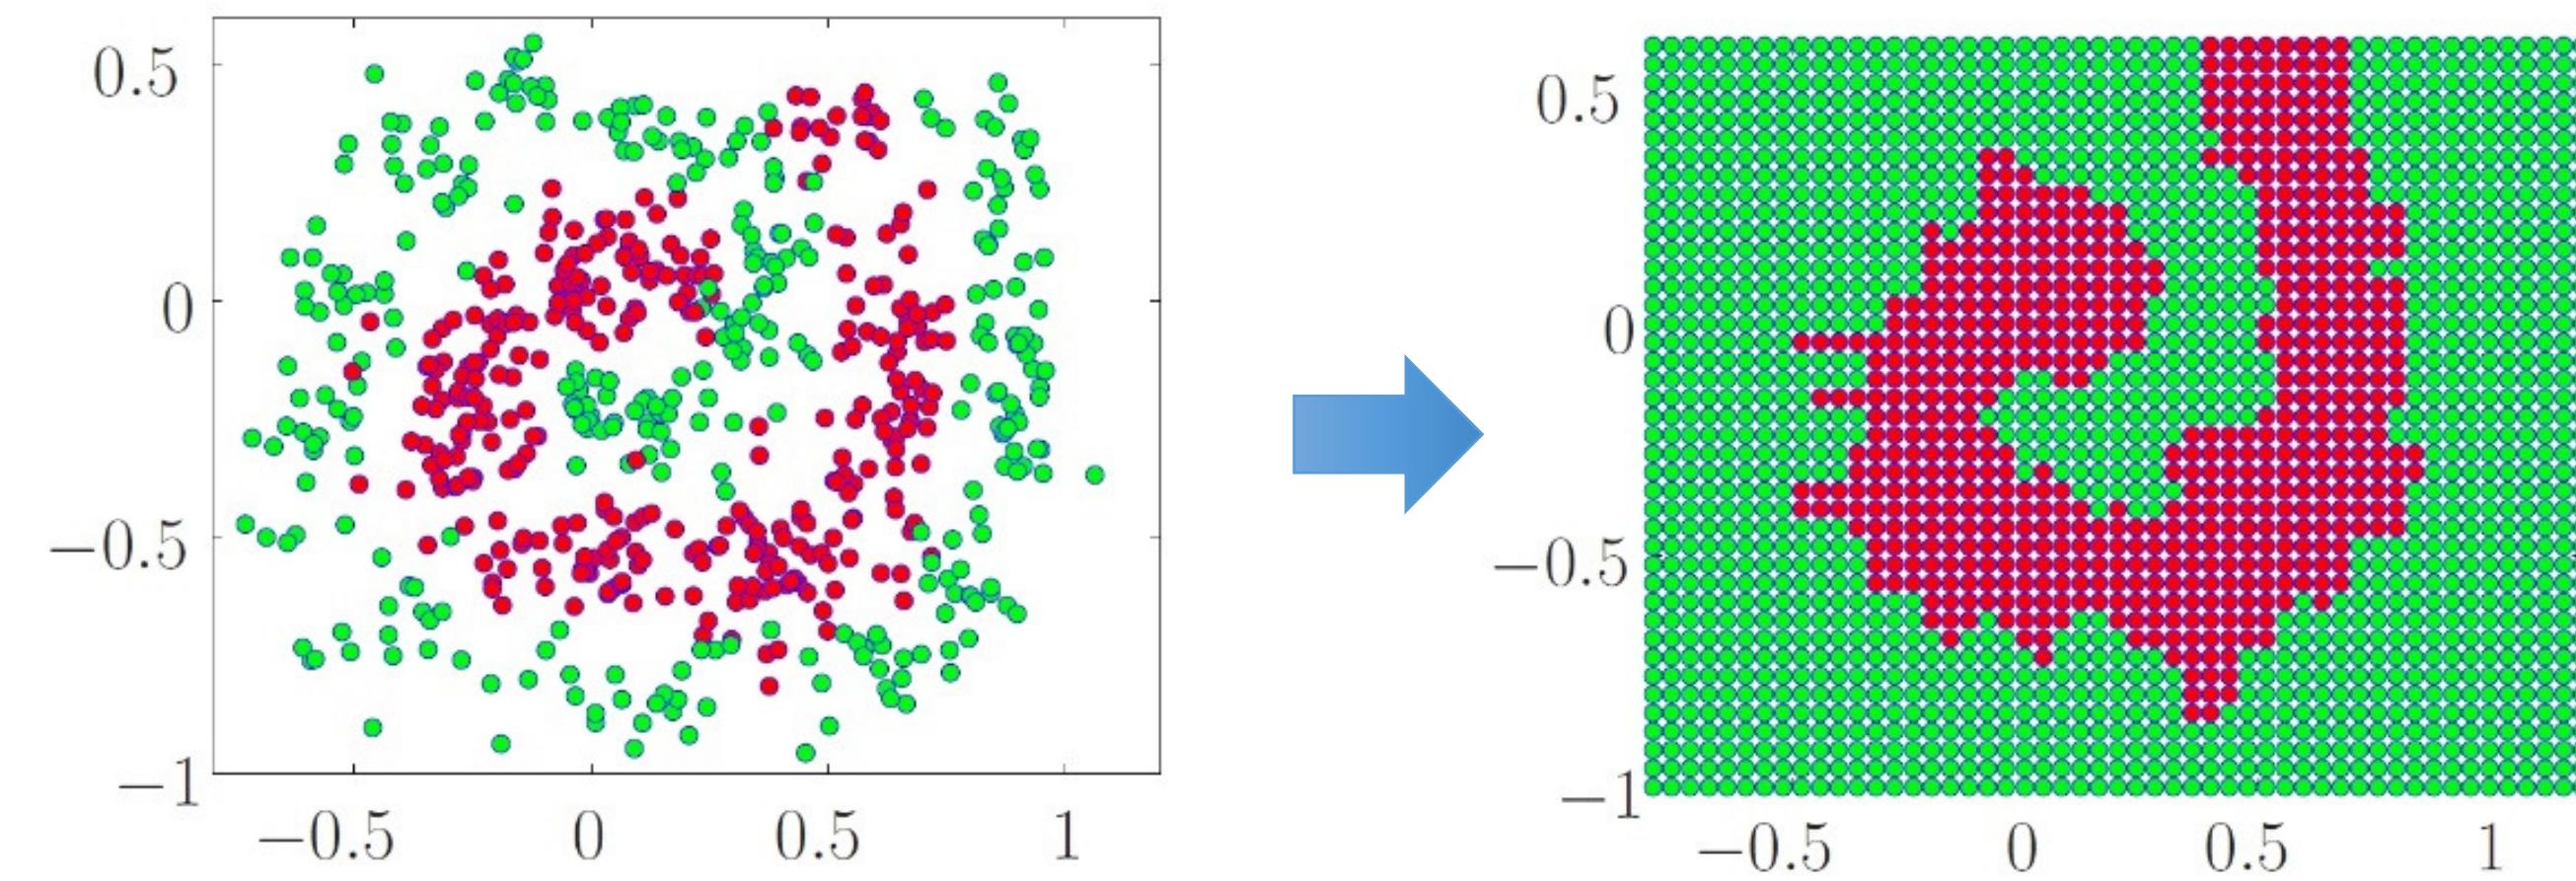
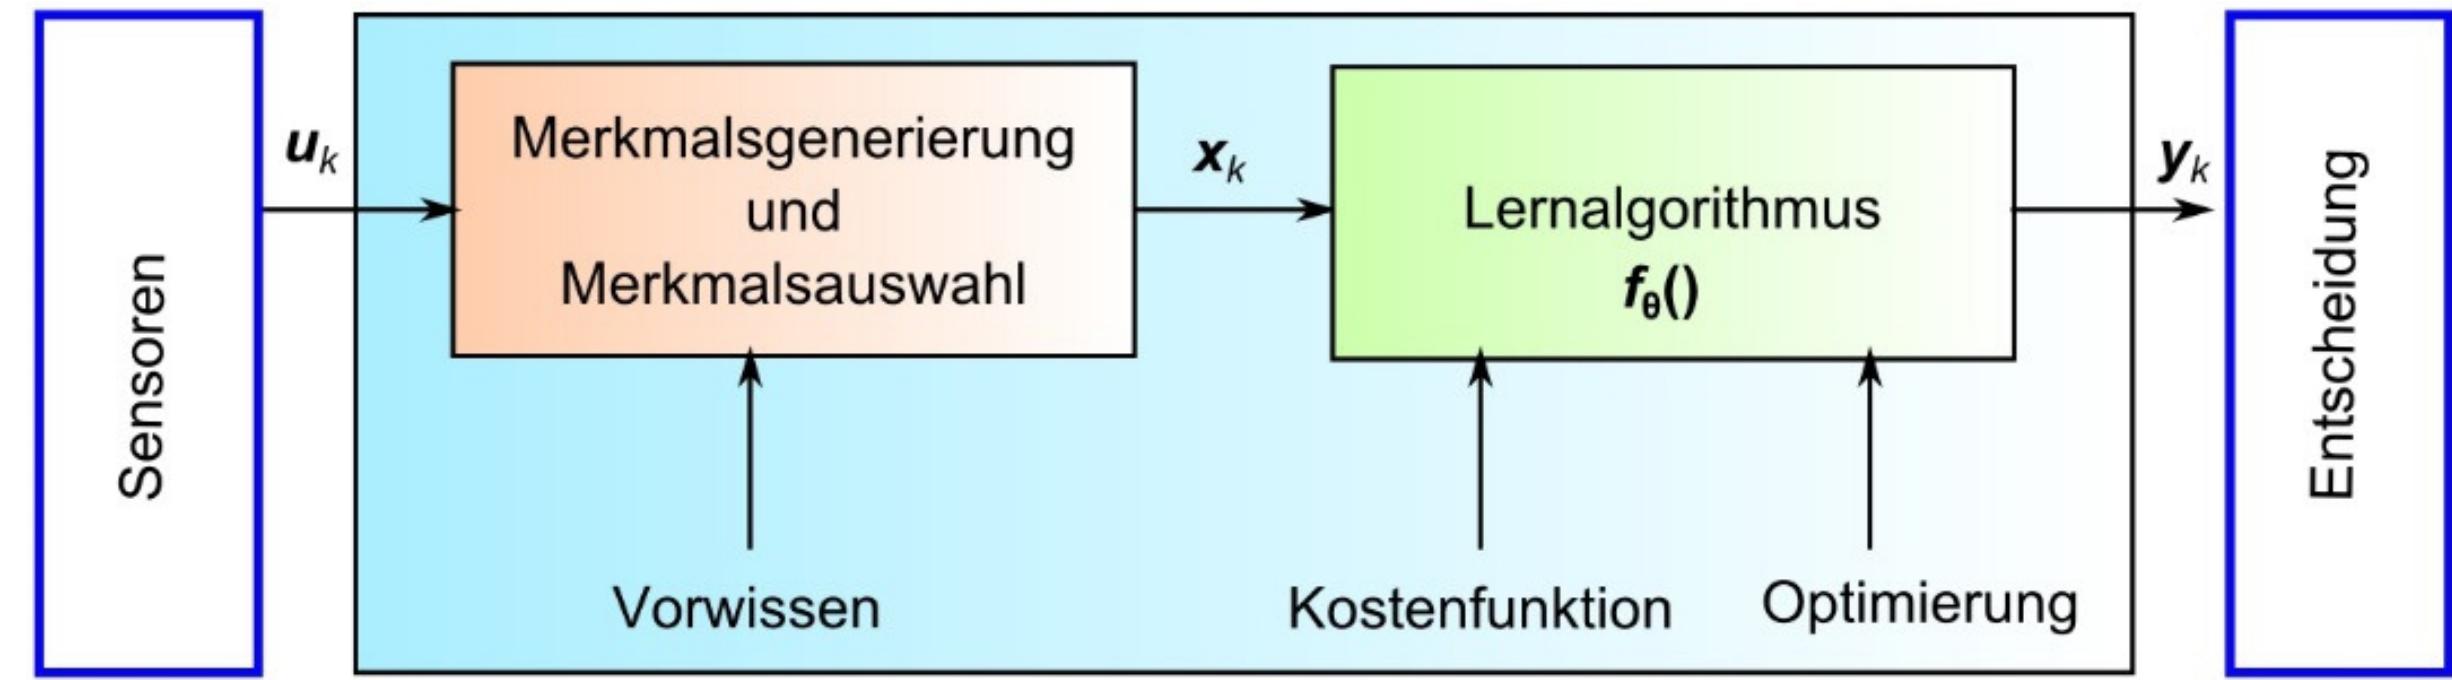
Geschichte maschineller Lernverfahren

| Jahr | Ereignisse |
|---------------|---|
| 1950 | Alan Turing führt den „Turing-Test“ ein: eine Maschine muss einen Menschen täuschen, so dass dieser denkt die Maschine sei ein Mensch |
| 1957 | Bernard Widrow, Marcian Hoff und Frank Rosenblatt führen die ersten Lernalgorithmen und das Perceptron, das einfachste Neuronale Netz (NN), ein |
| 1969 | Marvin Minsky und Seymour Papert veröffentlichen eine Kritik des zweischichtigen Perceptrons ⇒ NN-Forschung kommt für Jahre zum Stocken |
| 70er | Expertensysteme dominieren die datenbasierten Verfahren |
| 80er | Wiederentdeckung des Backpropagation-Algorithmus (Paul Werbos, David Rumelhart) und Verwendung von NN in praktischen Anwendungen |
| 90er | Lernende Algorithmen für große Datenmengen, „Neural Net Winter“ |
| 2000er | Graphische Methoden, Kernel-Methoden; Geoffrey Hinton führt 2006 den Begriff „Deep Learning“ ein |
| Heute | Google, Facebook, Apple, Baidu, Microsoft, etc. investieren hohe Summen in Projekte mit maschinellen Lernverfahren: Google-Brain, Alpha-Go, DeepFace von Facebook, Human-Brain-Projekt der EU, Watson von IBM, etc. |

Maschinelle Lernverfahren und automatisiertes Fahren

Mustererkennung (Pattern Recognition)

- Erkennen von Gesetzmäßigkeiten, Ähnlichkeiten also von Mustern in Daten
 - Merkmalsgewinnung
 - Klassifikation
 - Regression
- Verfahren
 - Neuronale Netze
 - Entscheidungsbäume
 - Support Vektor Maschinen
 - Ensemble Methoden
 - ...
- Beispiele:
 - Spracherkennung
 - Texterkennung
 - Bilderkennung
 - ...



Maschinelle Lernverfahren und automatisiertes Fahren



Explaining How End-to-End Deep Learning Steers a Self-Driving Car

Share: Posted on May 23, 2017 by Mariusz Bojarski, Larry Jackel, Ben Firner and Urs Muller | 0 Comments
Tagged Autonomous Vehicles, Deep Learning, DRIVE PX, Visualization
[Quelle: https://devblogs.nvidia.com/parallelforall/explaining-deep-learning-self-driving-car/](https://devblogs.nvidia.com/parallelforall/explaining-deep-learning-self-driving-car/)

Proceedings of the 2011 IEEE International Conference on Robotics and Biomimetics December 7-11, 2011, Phuket, Thailand

Autonomous Driving: A Comparison of Machine Learning Techniques by Means of the Prediction of Lane Change Behavior

Ürün Dogan and Johann Edelrunner and Ioannis Iossifidis
IEEE ROBIO 2011

Intelligent Machines

Machine Learning and Data Are Fueling a New Kind of Car

Here's why Intel just offered \$15.3 billion for Mobileye, an Israeli company that specializes in machine vision and learning for cars.

by Will Knight March 14, 2017

The automobile is being dismantled, reimaged, and rebuilt in Silicon Valley.

Quelle: MIT Technology Review

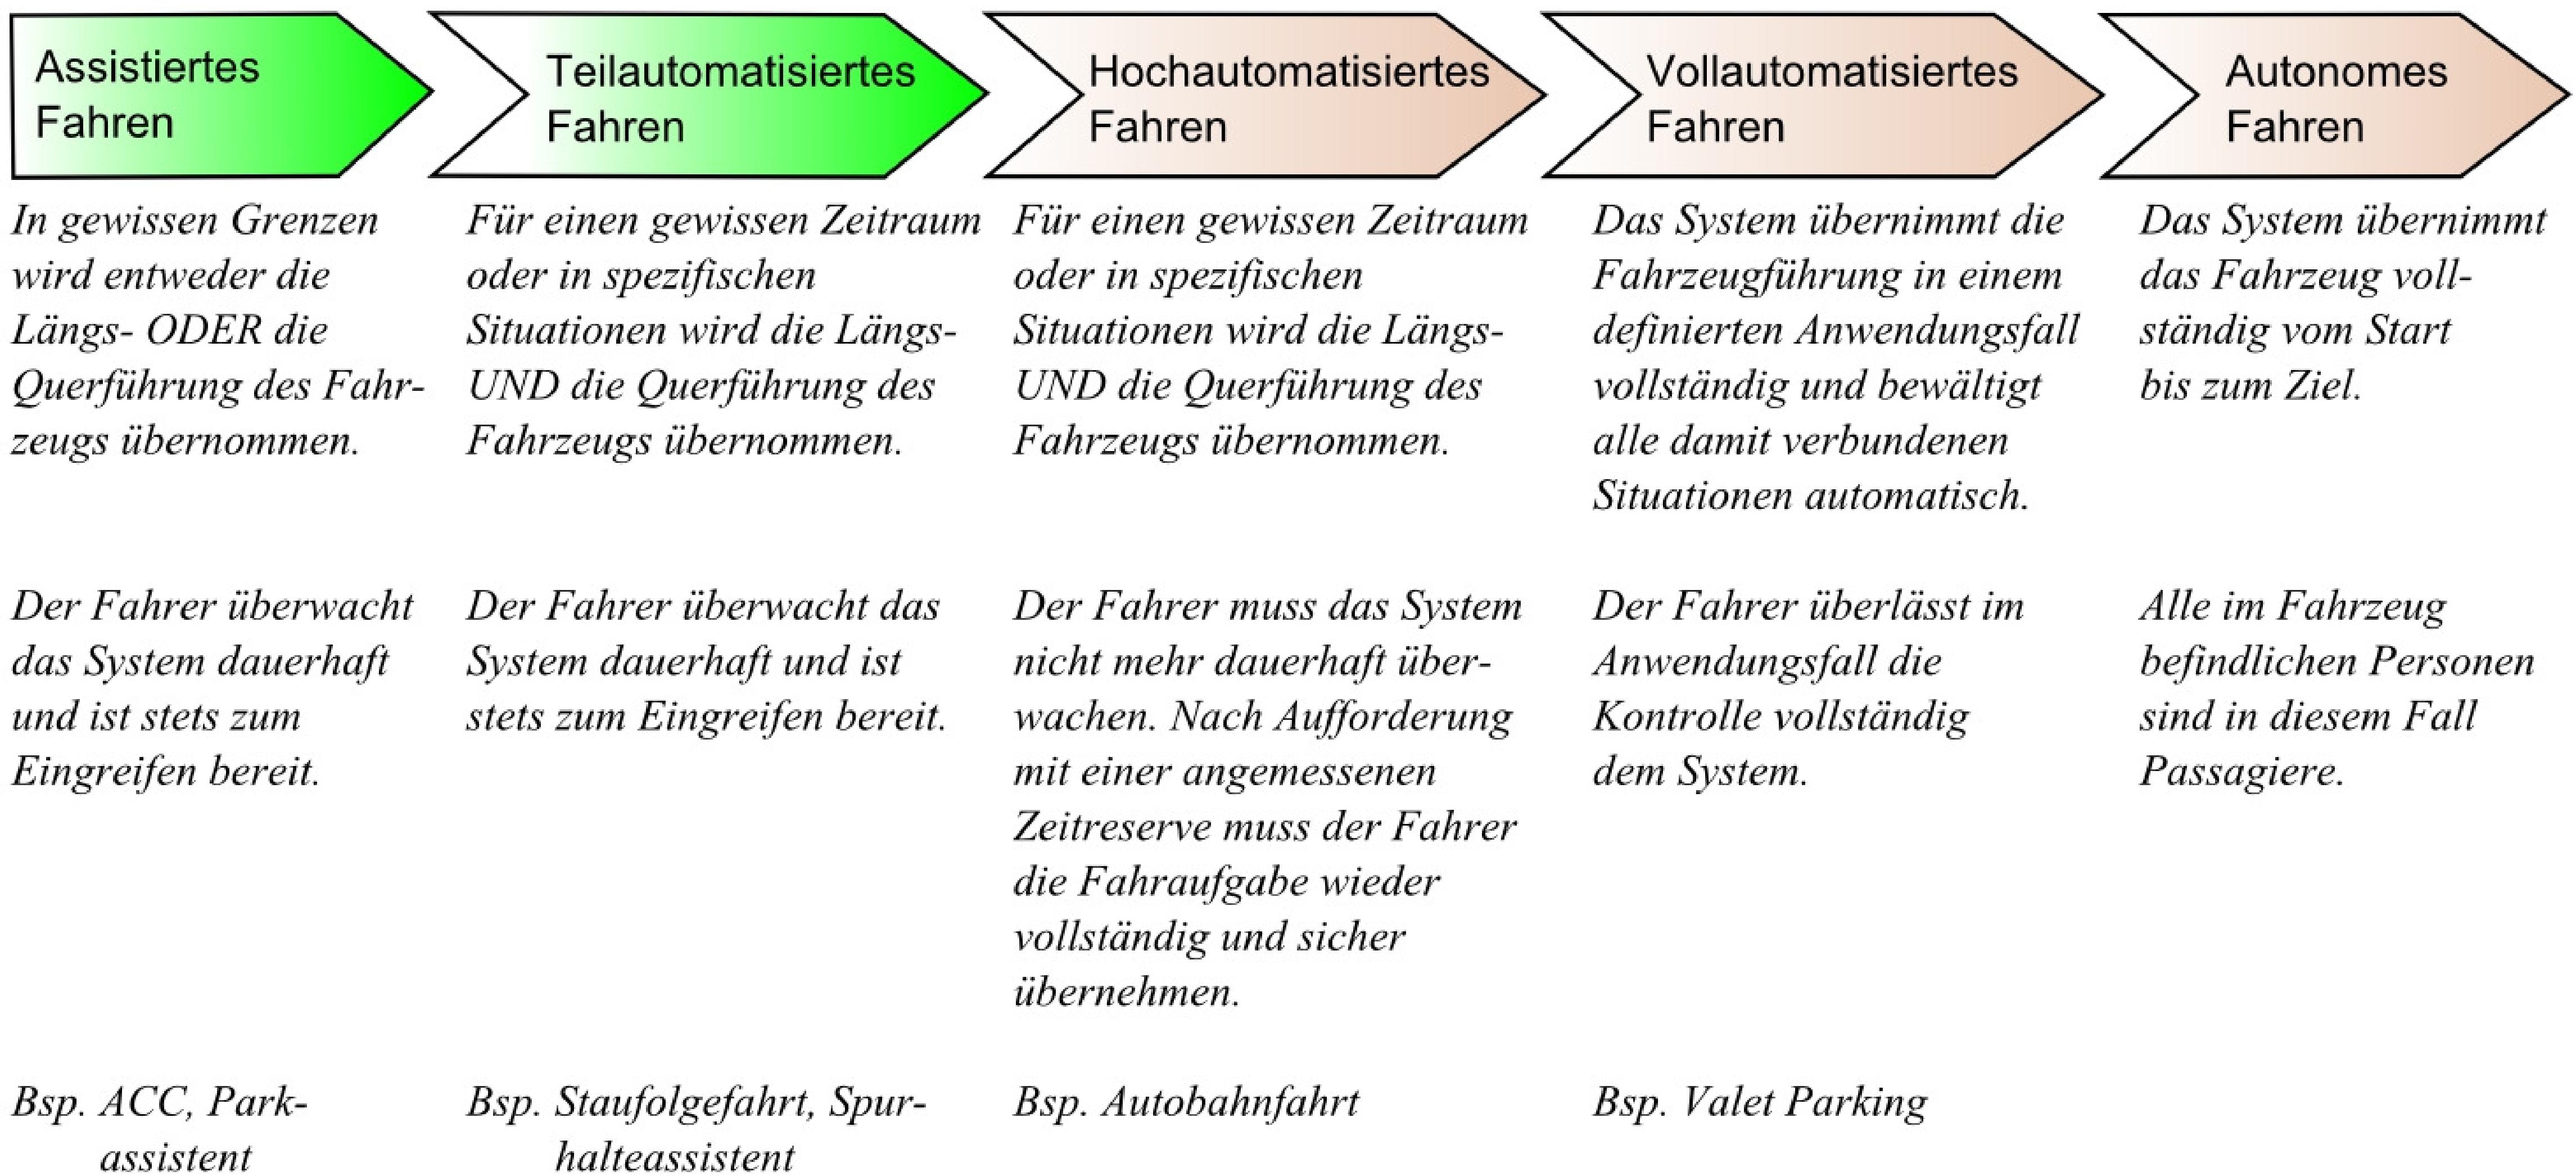
Efficient Statistical Validation of Machine Learning Systems for Autonomous Driving (Invited Paper)

Weijing Shi¹, Mohamed Baker Alawieh¹, Xin Li¹, Huafeng Yu², Nikos Arechiga³ and Nobuyuki Tomatsu³
¹ECE Department, Carnegie Mellon University, Pittsburgh, PA 15213
²Boeing Research and Technology, Huntsville, AL 35758
³TOYOTA InfoTechnology Center, Mountain View, CA 94043
{weijings, malawieh, xinli}@cmu.edu, huafeng.yu@boeing.com, {narechiga, ntomatsu}@us.toyota-itc.com

Quelle: IEEE/ACM ICCAD 2016

Maschinelle Lernverfahren und automatisiertes Fahren

Stufen des automatisierten Fahrens



Maschinelle Lernverfahren und automatisiertes Fahren

Potenziale des automatisierten Fahrens

- Erhöhung der Verkehrssicherheit
 - Heute sind mehr als 90 % der Unfälle mit Toten und Schwerverletzten auf menschliches Fehlverhalten zurückzuführen*
 - Reduzierung des Faktors Mensch wird die Anzahl der Unfälle reduzieren
- Steigerung der Verkehrseffizienz
 - Verkehrsprognose des BMVI für das Jahr 2030: Zuwachs um 13 % beim Personenverkehr und um 38 % beim Güterverkehr*
 - Verbesserter Verkehrsfluss durch automatisiertes Fahren
- Reduzierung der verkehrsbedingten Emissionen
 - Reduzierung des Kraftstoffverbrauchs durch Verkehrsflussoptimierung
 - Vermeidung des Parkplatzsuchverkehrs
- Erhöhung des Fahrkomforts
 - Fahrer wird zum Insassen und hat Zeit für andere Tätigkeiten
 - Personen die ein Fahrzeug nicht mehr führen können werden wieder mobil

*Quelle: Position – Zukunft automatisiertes Fahren – Rechtliche Hürden beseitigen vbw – März 2017

Maschinelle Lernverfahren und automatisiertes Fahren

Warum maschinelles Lernen für automatisiertes Fahren?

Komplexität im Straßenverkehr!

- Wahrnehmung
 - ⇒ Sensoren und Beschreibung von Objekte, Straßenzustand, Infrastruktur
- Interpretation der Situation
 - ⇒ Verhalten der anderen Verkehrsteilnehmer unvorhersehbar und nur durch Kontextwissen probabilistisch zu beschreiben
- Planung und Regelung der Trajektorie
 - ⇒ Finden einer sicheren, fahrbaren Trajektorie in jeder Verkehrssituation



Maschinelle Lernmethoden eignen sich sehr gut um mit hoher Komplexität umzugehen, wenn ausreichend viele Daten vorhanden sind

Inhalt

Maschinelle Lernverfahren und automatisiertes Fahren

Deep-Learning und Ensemble-Methoden

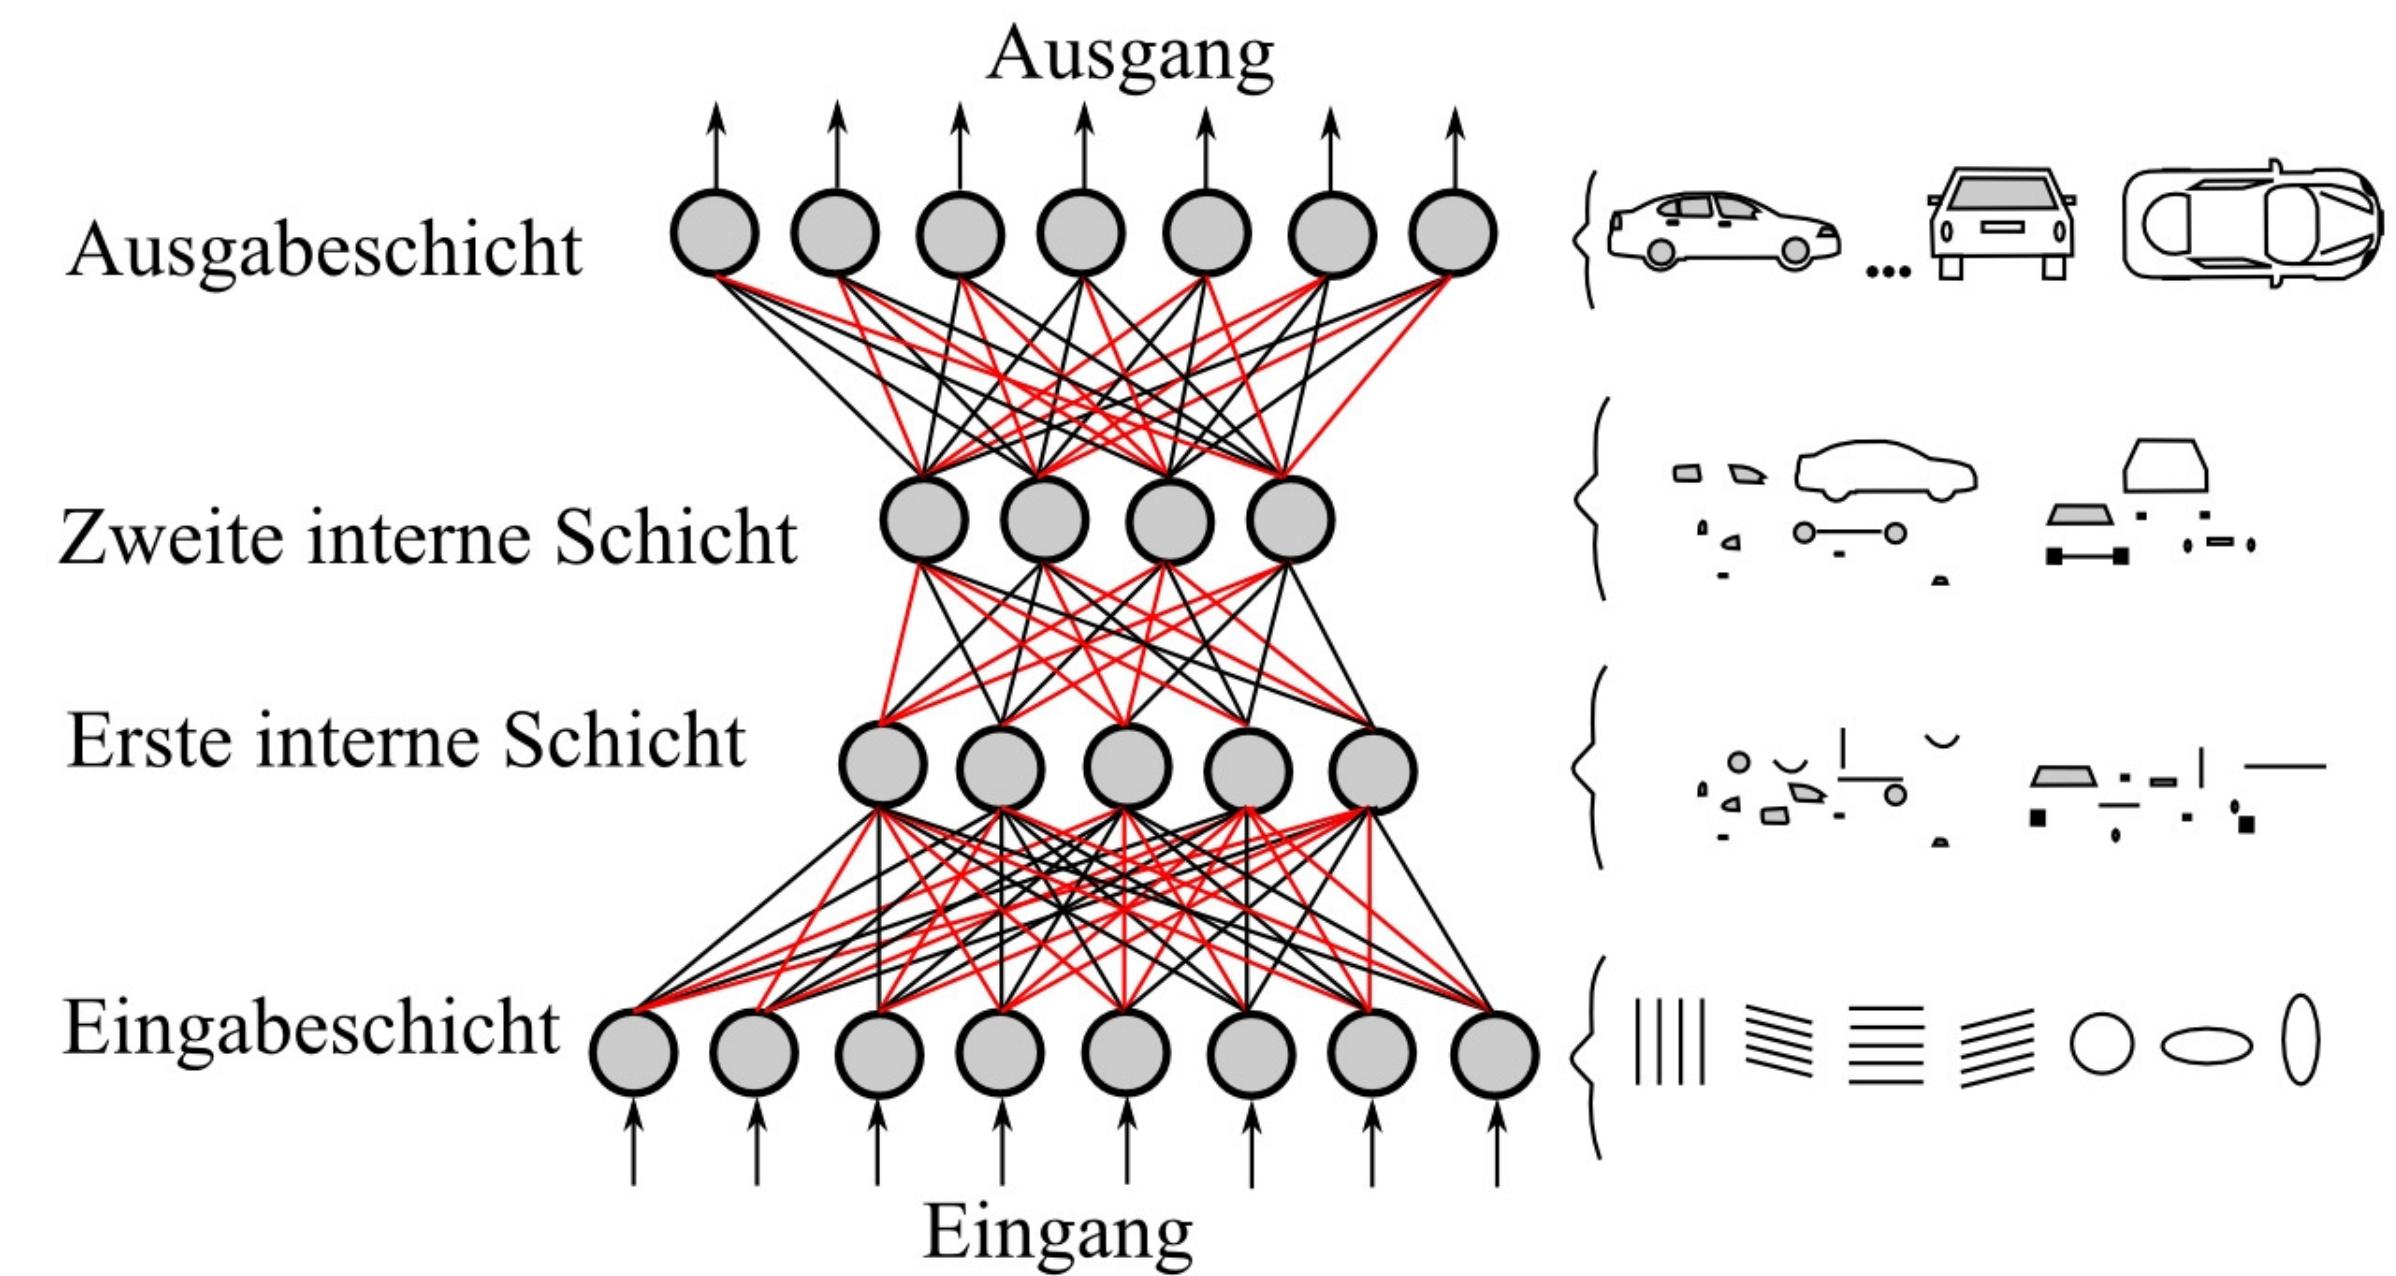
Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung
für autonome Fahrzeuge

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

Deep-Learning und Ensemble-Methoden

Deep Learning

- „Deep Learning“ bezeichnet einen Bereich der Mustererkennung in dem der Lernprozess auf viele Verarbeitungsebenen verteilt wird (hierarchisches Lernen)
- Entfall der aufwändigen händischen Merkmalsextraktion
- Beispiel: *Deep Neural Net (DNN)*



Deep-Learning und Ensemble-Methoden

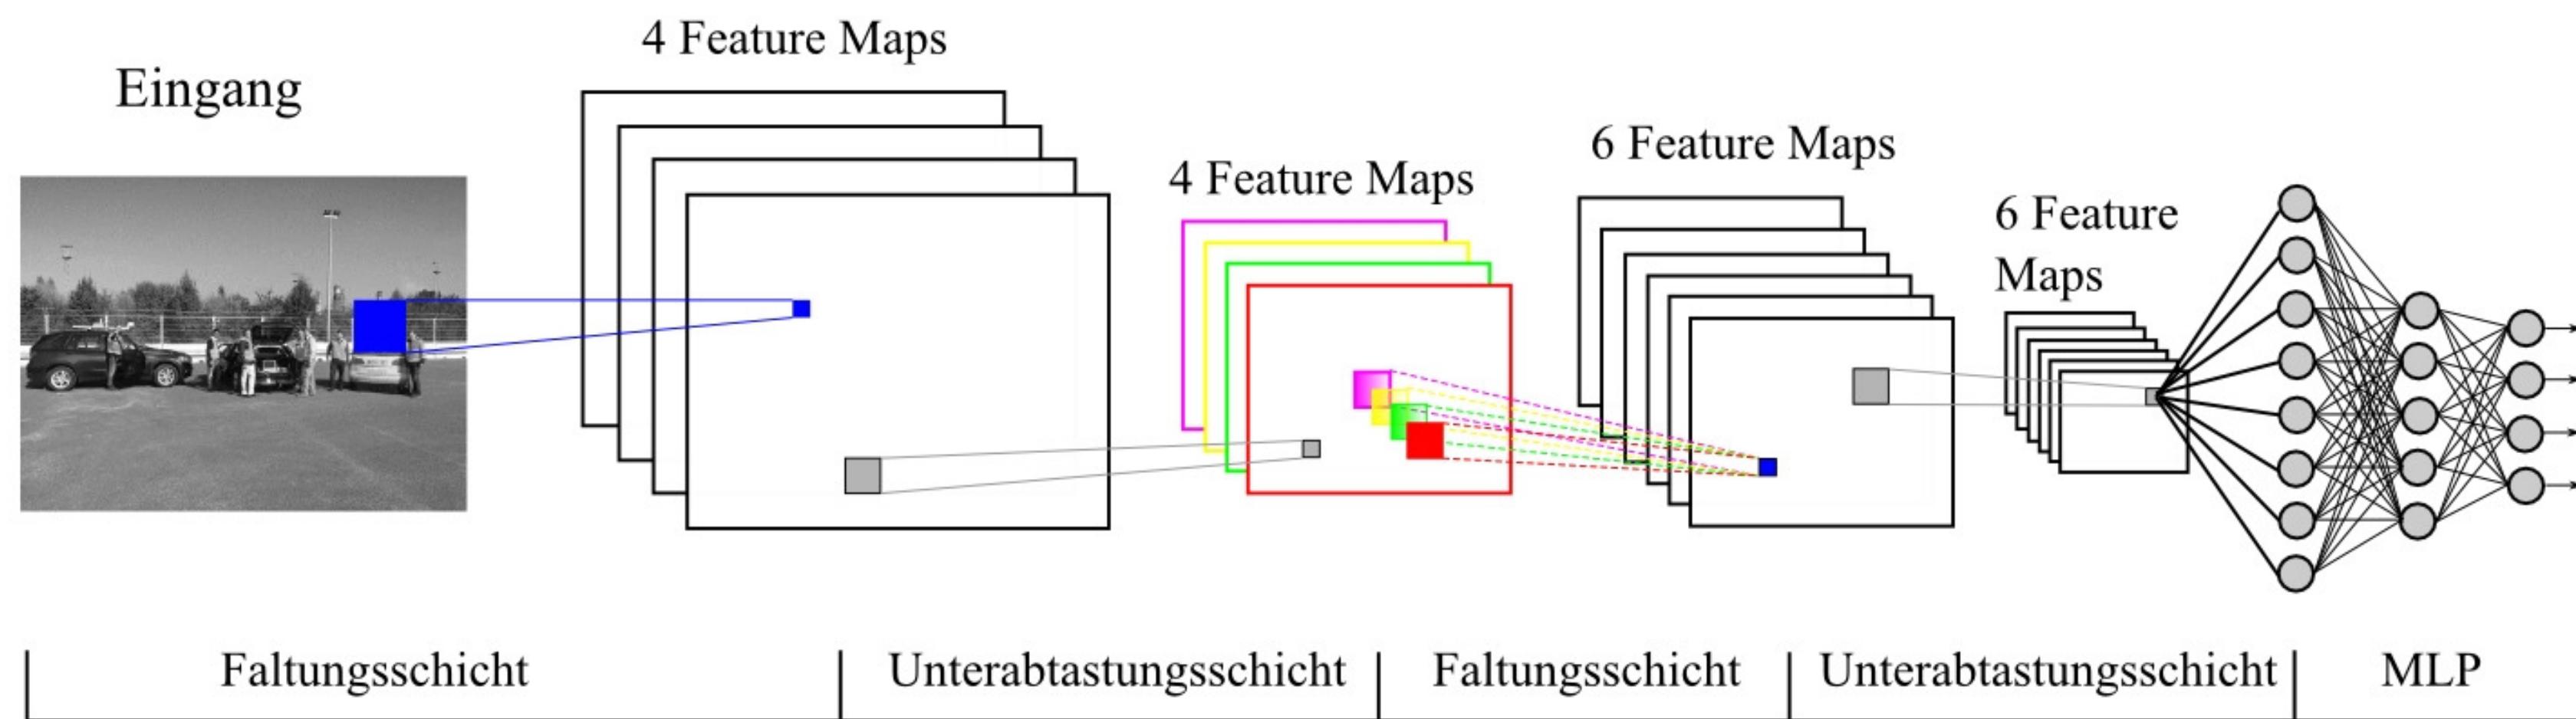
Deep Learning

- Wccftech:
„Tesla’s Autopilot, powered by Mobileye, is the world’s first DNN deployed on the road“
- Yann LeCun (Director of AI Research, Facebook) zum Begriff „Deep Learning“:
“My least favorite description is, ‘It works just like the brain.’ I don’t like people saying this because, while Deep Learning gets an inspiration from biology, it’s very, very far from what the brain actually does. And describing it like the brain gives a bit of the aura of magic to it, which is dangerous. It leads to hype; people claim things that are not true. **AI has gone through a number of AI winters because people claimed things they couldn’t deliver.**”

Deep-Learning und Ensemble-Methoden

Deep Learning

- Deep Neural Networks: statt 1 oder 2 interne Schichten werden 5 – 20 interne Schichten verwendet
- Für Bild- oder Sprachdaten sind *Convolutional Neural Nets* (CNN) sehr erfolgreich



- Die Faltungs- und Unterabtastungsschichten realisieren eine automatisierte „Merkmalsextraktion“ durch **Optimierung** mittels stochastischem Gradientenverfahren

Deep-Learning und Ensemble-Methoden

Deep Learning

Optimierung mittels stochastischem Gradientenverfahren

- Ein **Trainingsdatensatz** ist gegeben

$$D = \{(\nu_1, z_1), (\nu_2, z_2), \dots, (\nu_M, z_M)\}$$

- Finden der Abbildung g durch Minimierung des **empirischen Risikos** $R_{emp}(g, D)$

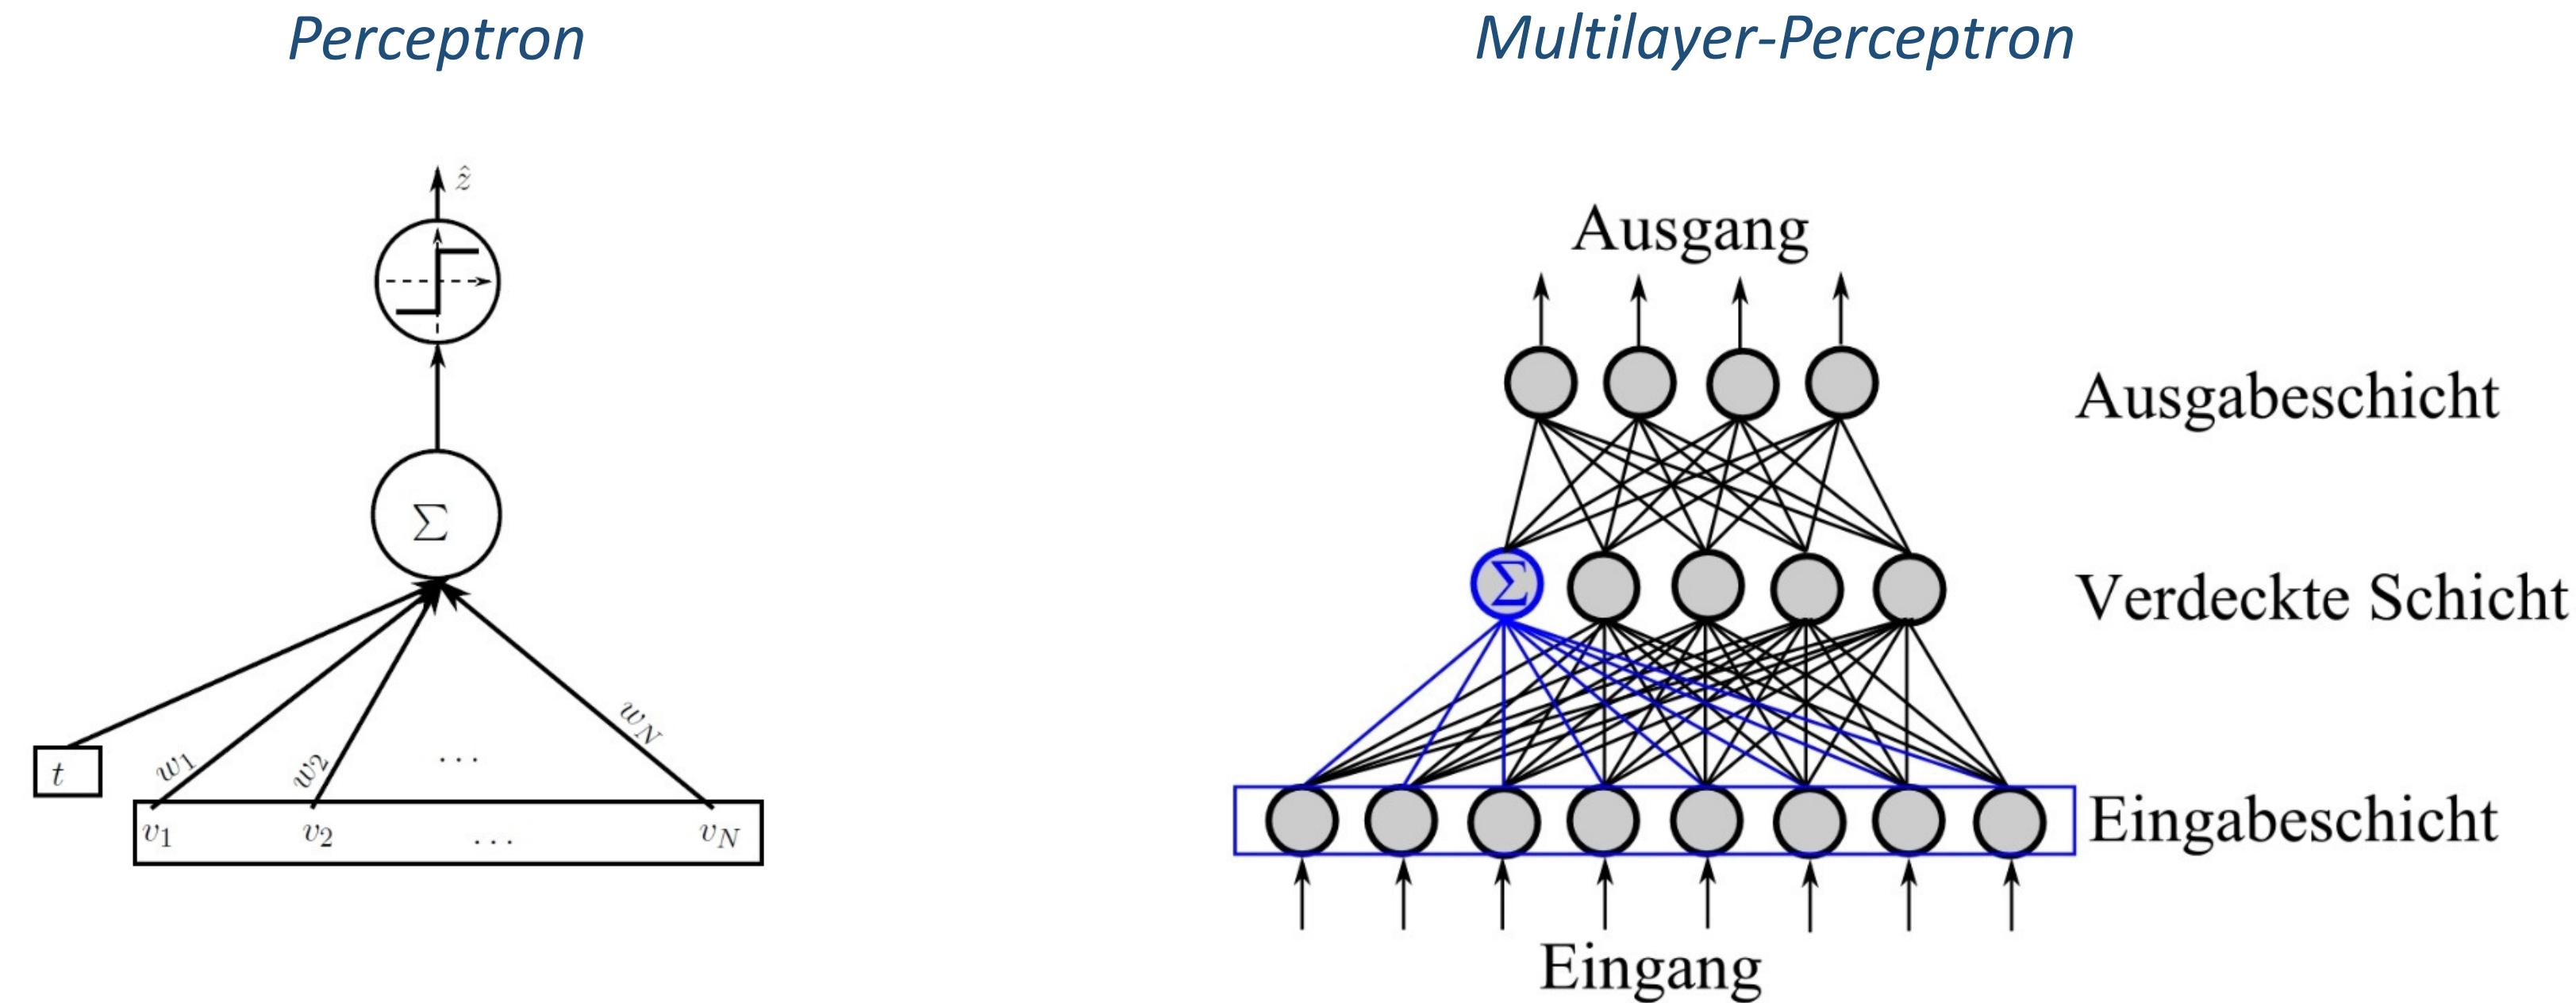
$$R_{emp}(g, D) = \frac{1}{M} \sum_{m=1}^M L(z_m, g(\nu_m)),$$

wobei L eine Kostenfunktion ist, die den Unterschied zwischen dem Trainingsziel z_m und dem Ausgang $g(\nu_m)$ der Abbildung g für den Eingang ν_m „bestraft“

Deep-Learning und Ensemble-Methoden

Deep Learning

- „Multilayer-Perceptron“-NN mit nur einer verdeckten Schicht ist ein universeller Funktionsapproximator

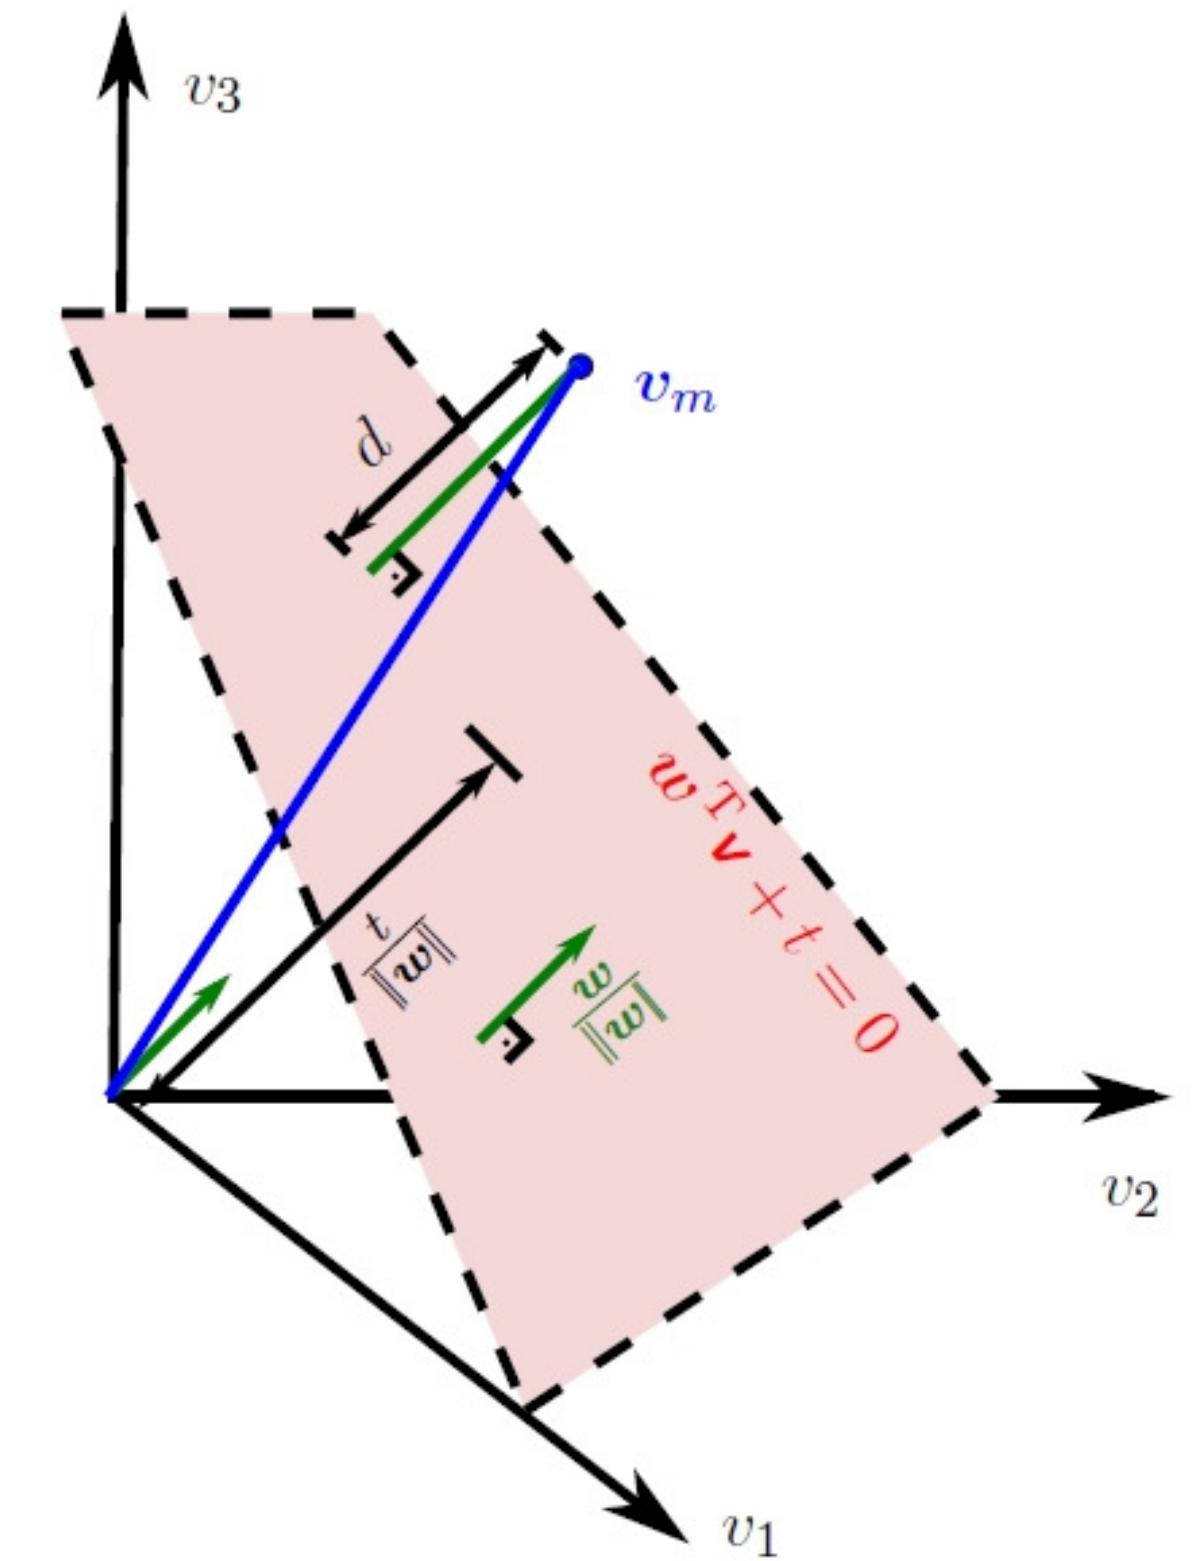
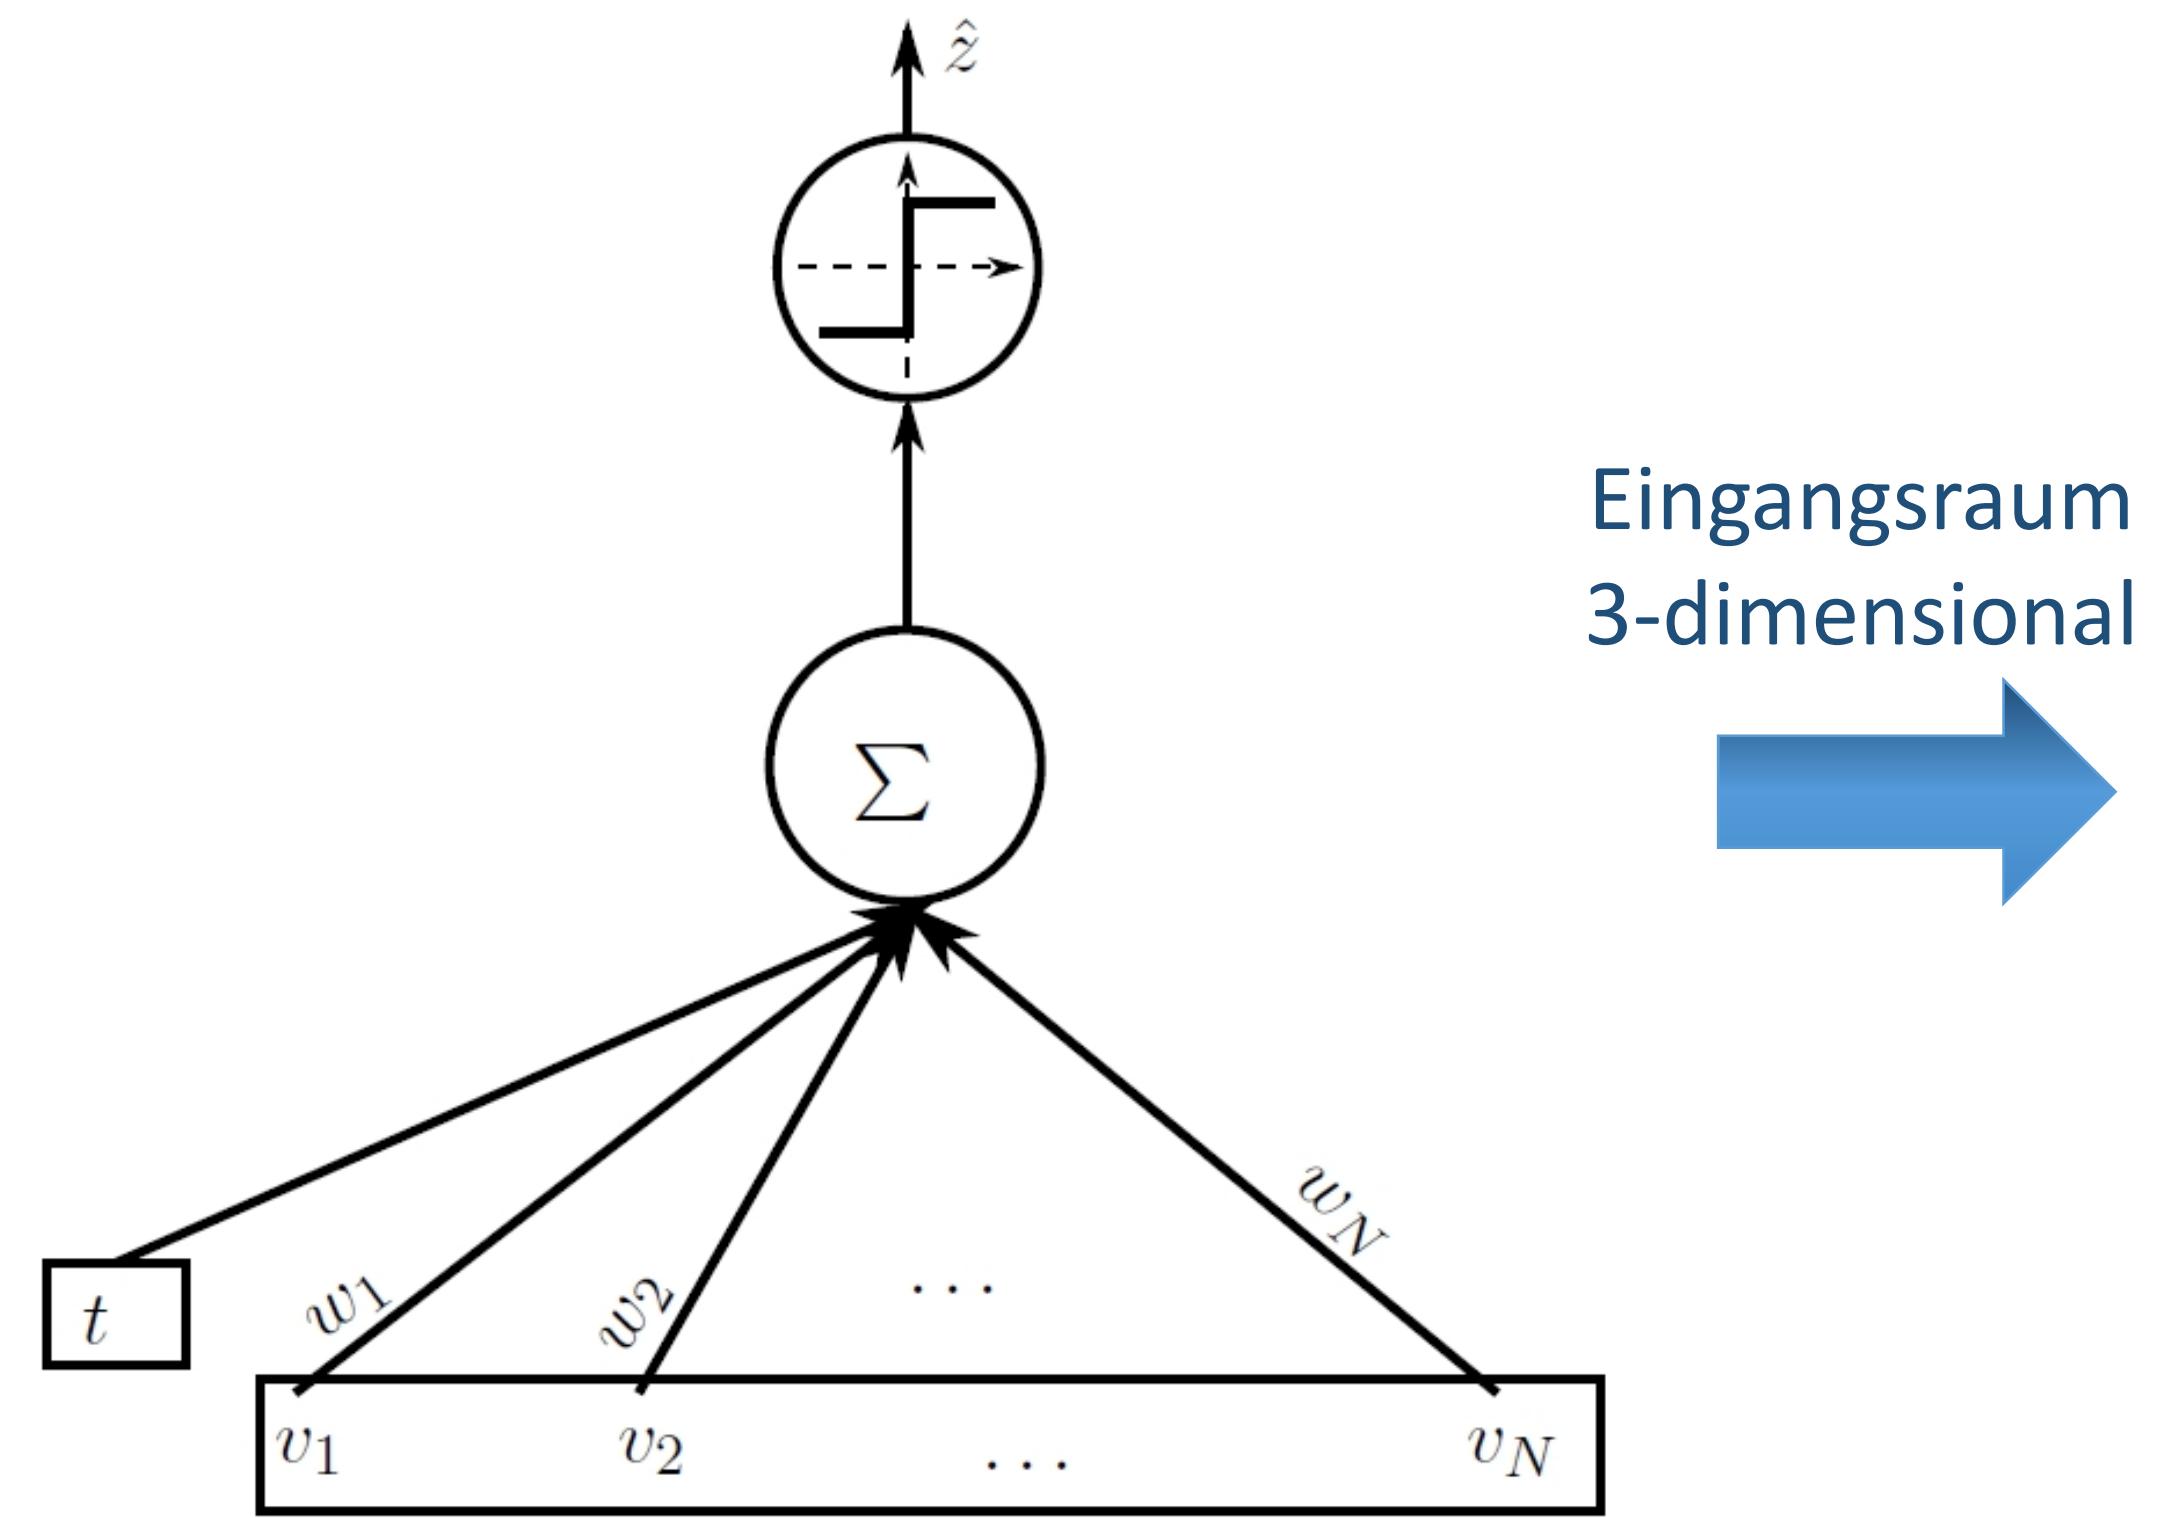


- „Lernen“ entspricht dem Finden der Gewichte durch Lösen einer Optimierungsaufgabe mittels stochastischem Gradientenverfahren (Backpropagation)

Deep-Learning und Ensemble-Methoden

Deep Learning

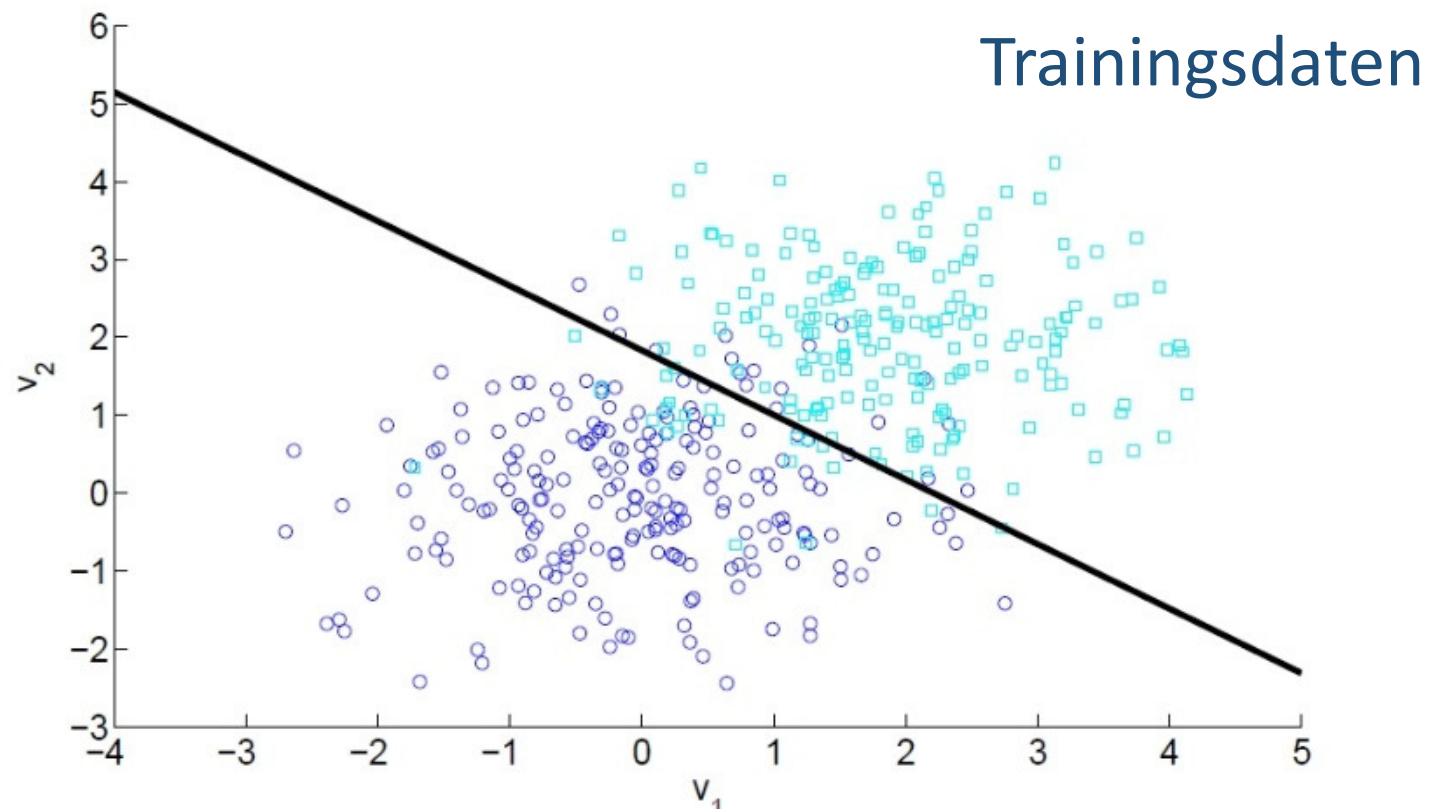
Perceptron



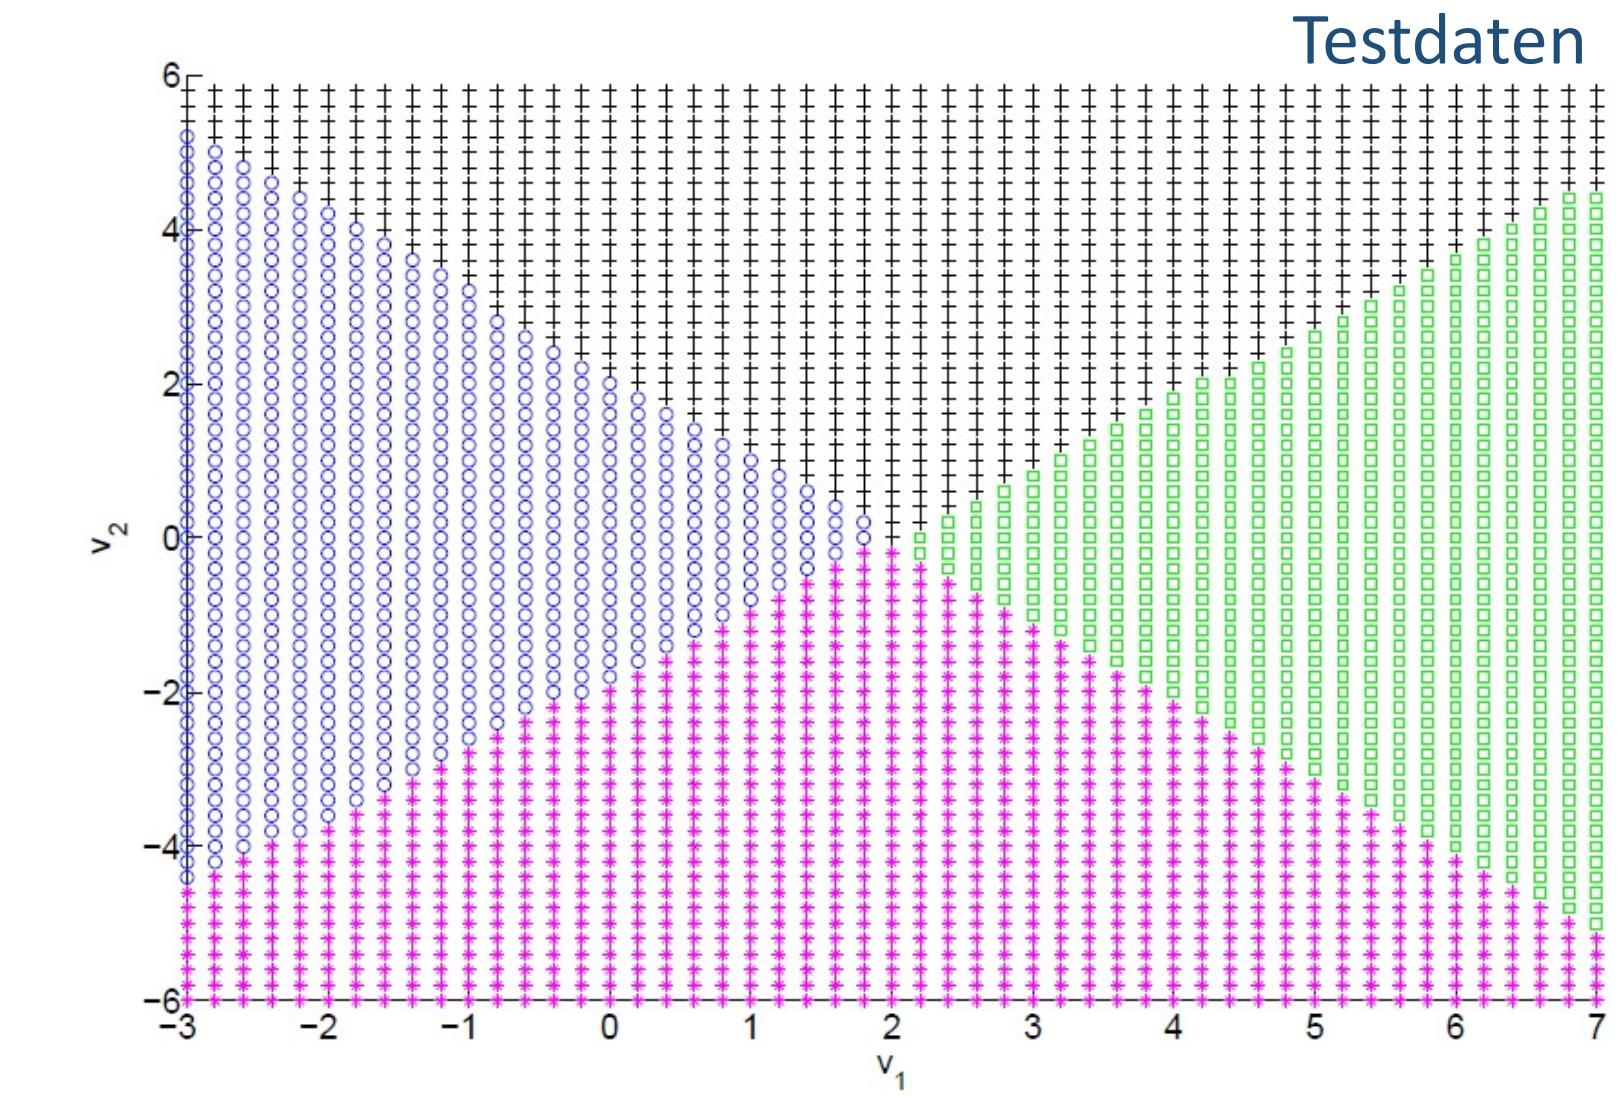
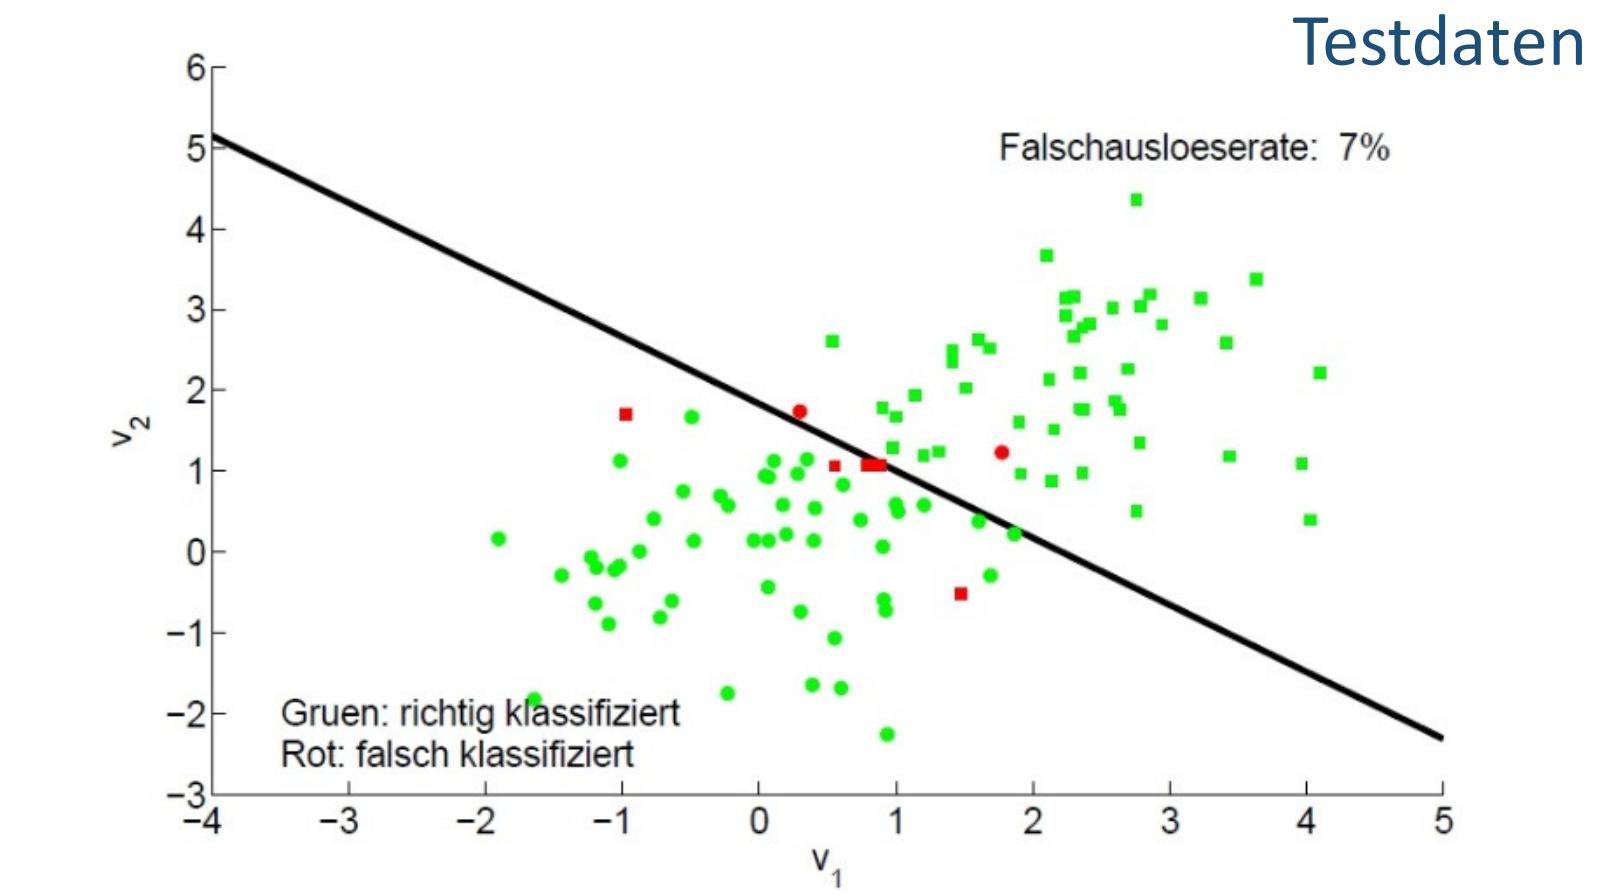
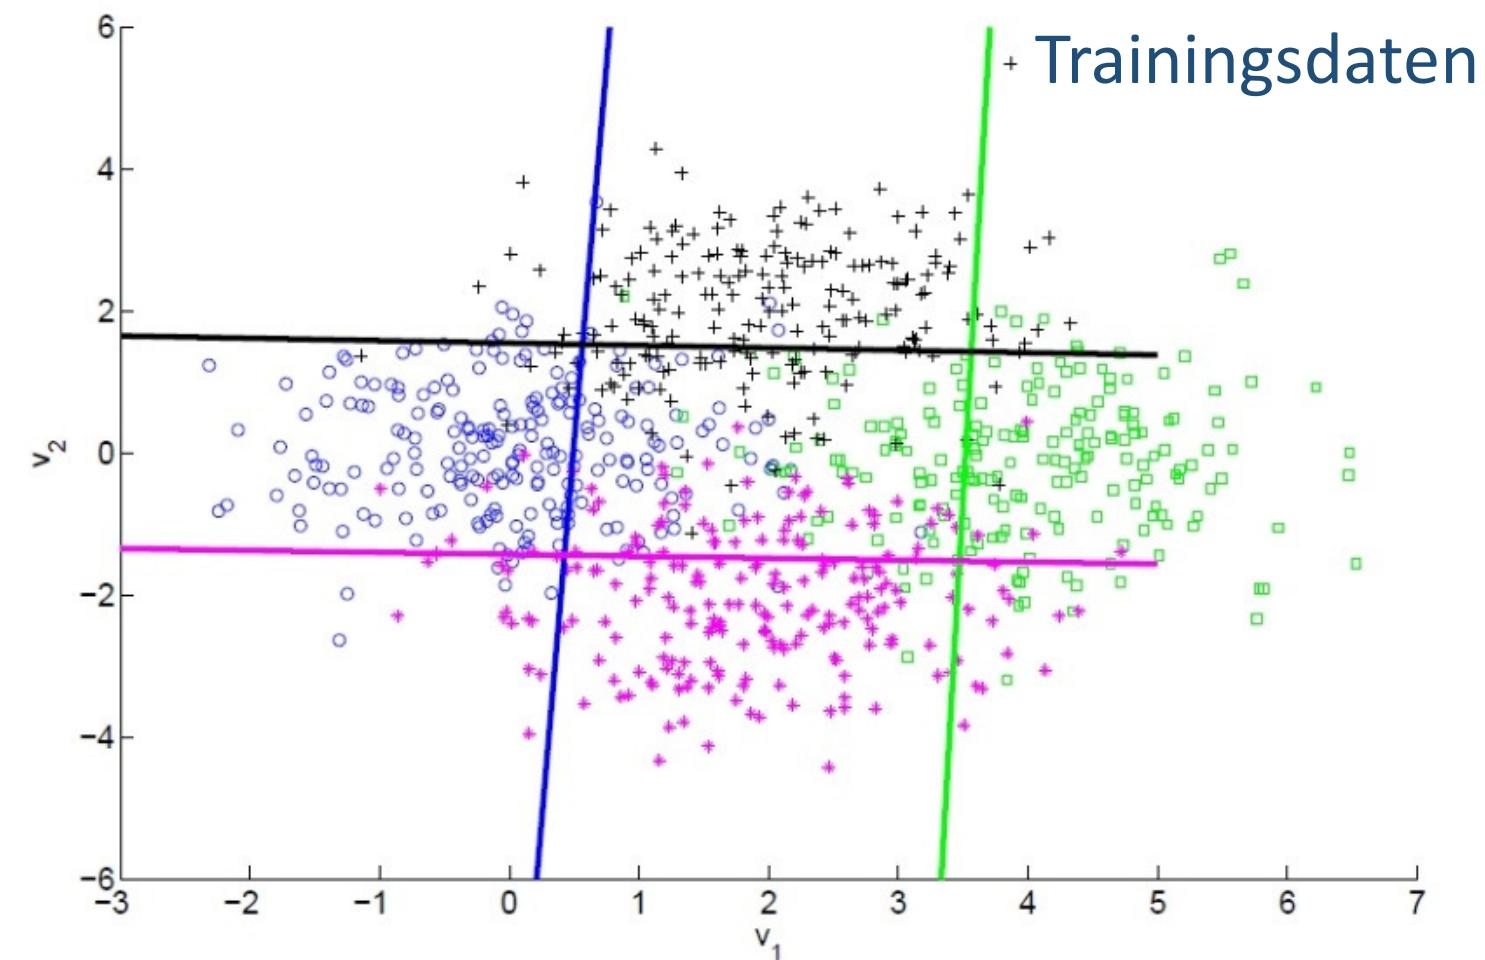
Deep-Learning und Ensemble-Methoden

Deep Learning

- 2-Klassen,
Eingangsraum 2D,
ein Perceptron



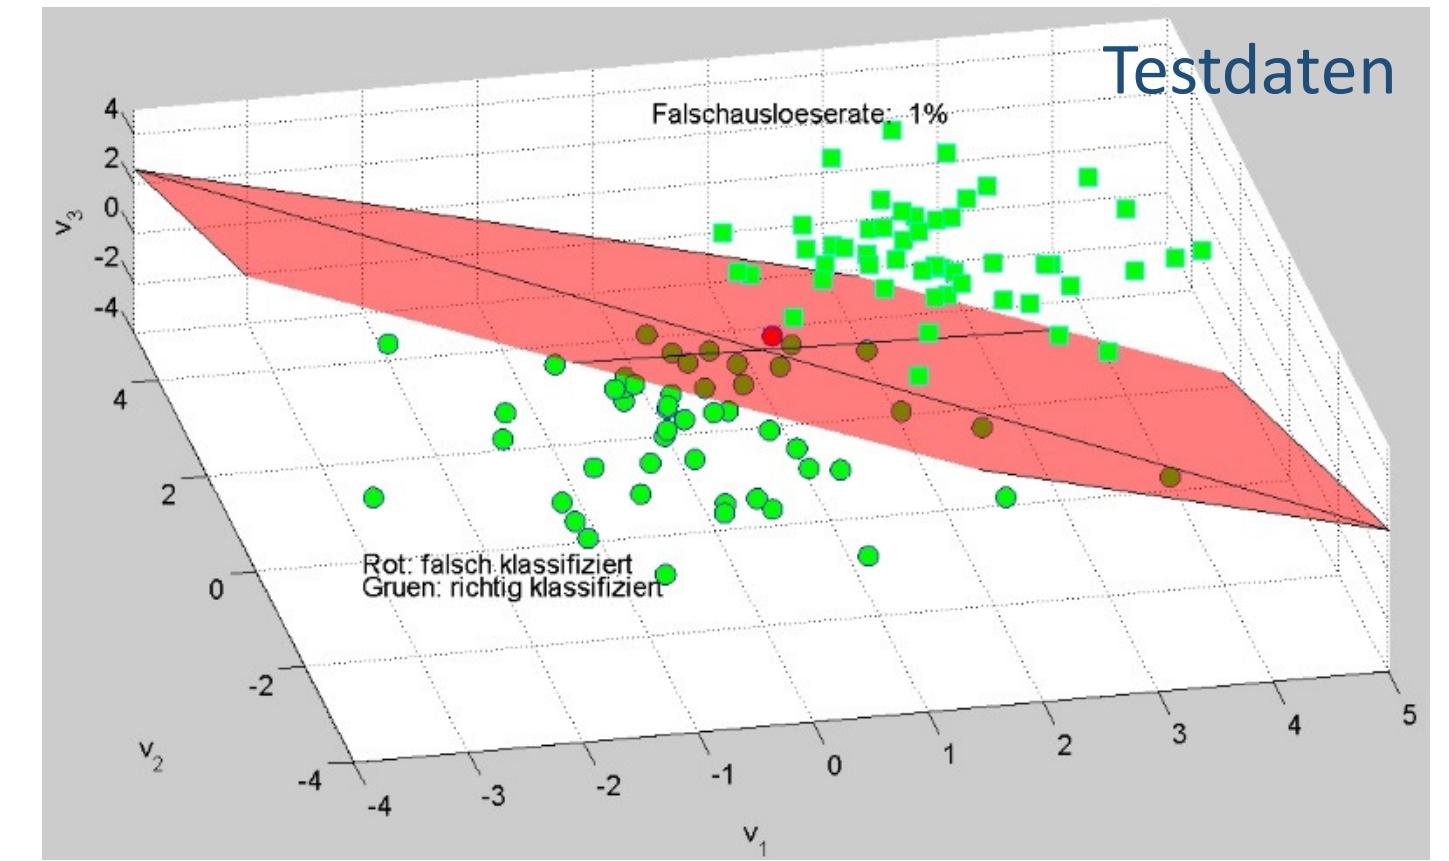
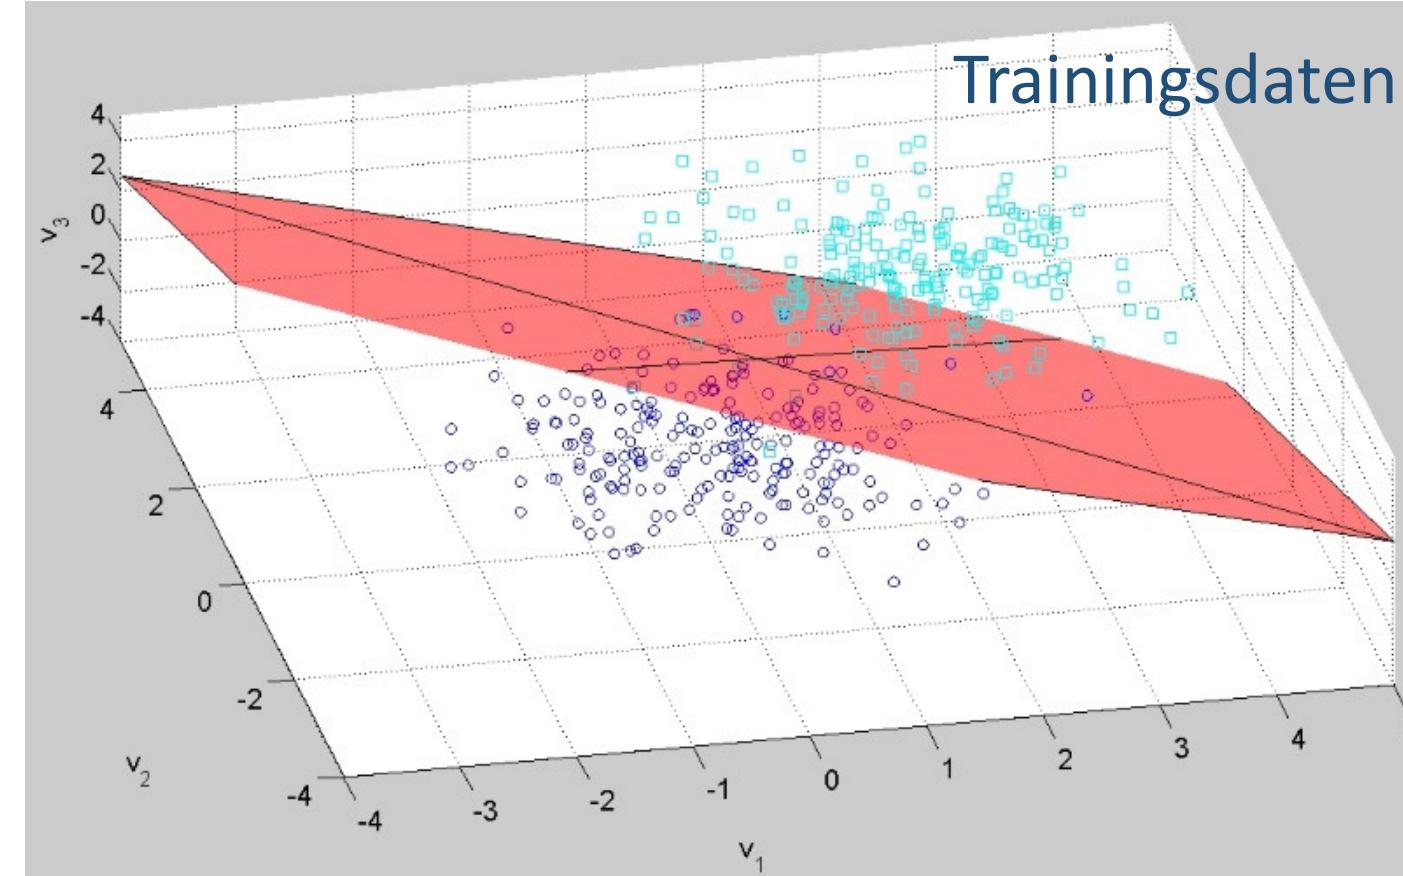
- 4 Klassen,
Eingangsraum 2D,
vier Perceptrons



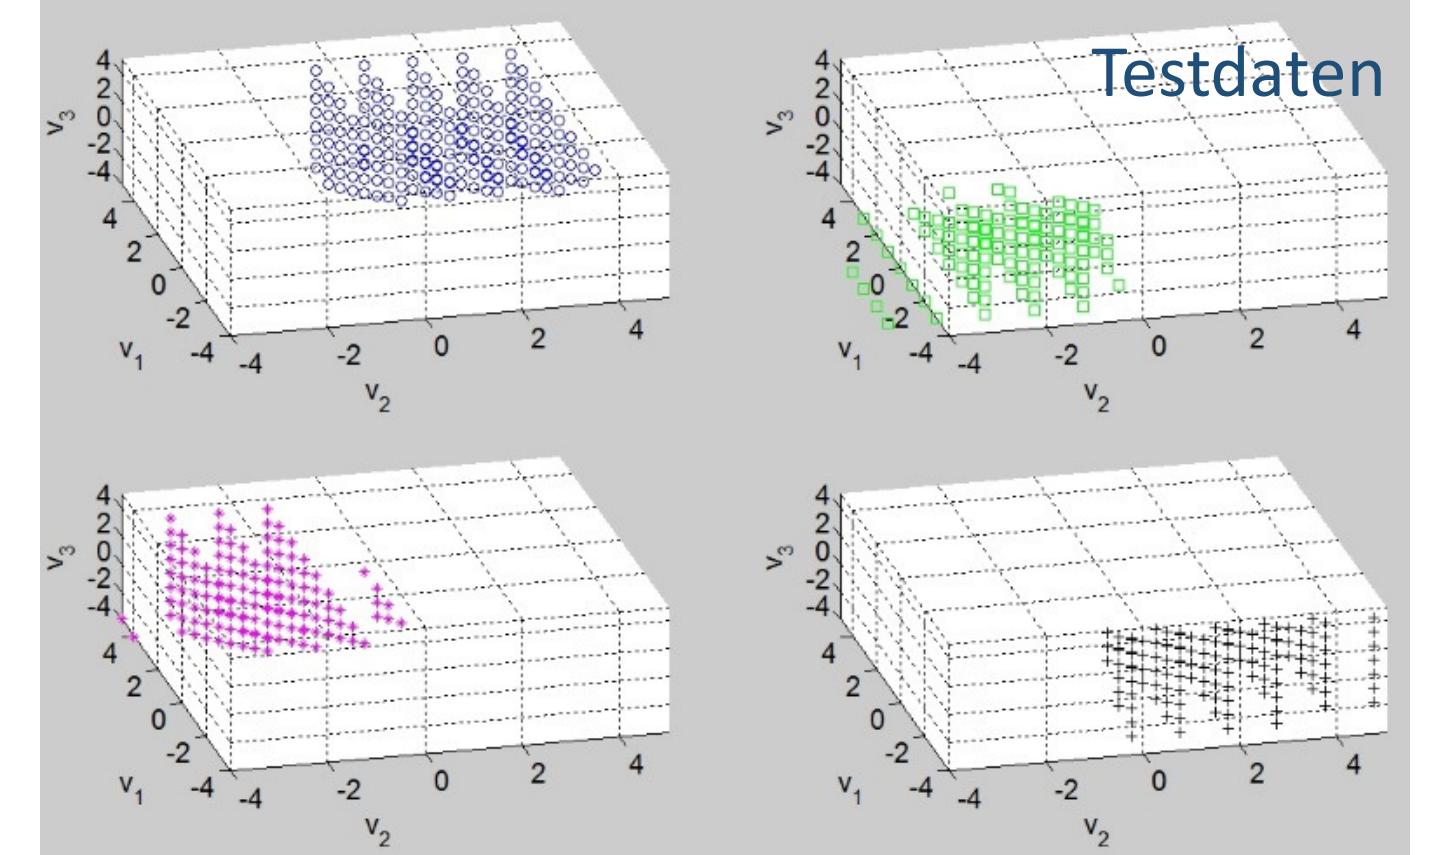
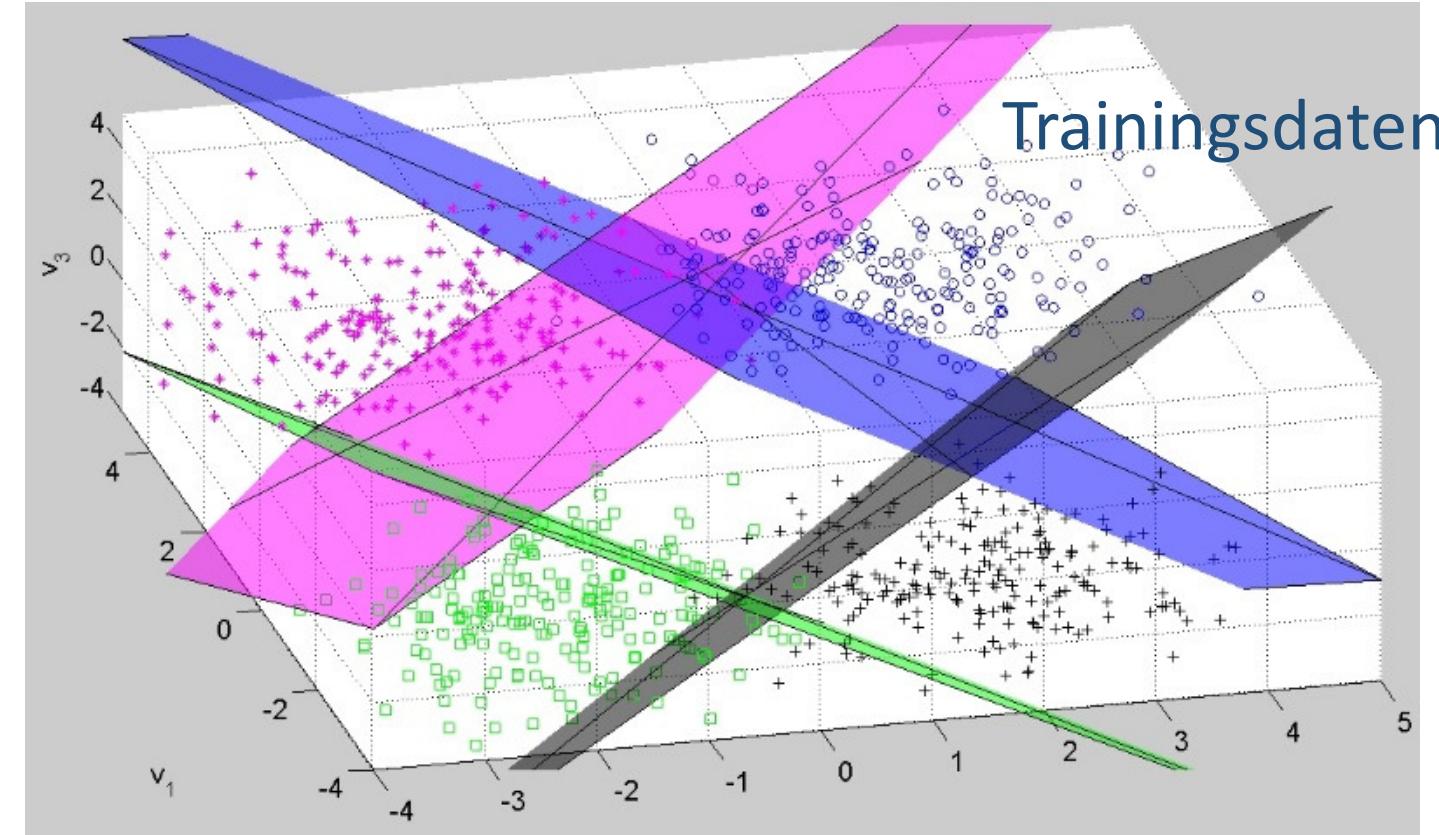
Deep-Learning und Ensemble-Methoden

Deep Learning

- 2-Klassen,
Eingangsraum 3D,
ein Perceptron



- 4 Klassen,
Eingangsraum 3D,
vier Perceptrons



Deep-Learning und Ensemble-Methoden

Ensemble Methoden

- Grundidee: Kombination der Ergebnisse einer endlichen Menge verschiedener Lernalgorithmen, um besser zu sein als nur mit einem Lernalgorithmus

Beispiel

- Annahmen:
 - Alle Klassifikationsalgorithmen in einem Ensemble haben die Fehlerrate $e = 0.4$
 - Alle Klassifikationsalgorithmen sind voneinander unabhängig
 - Ensemble besteht aus 50 Klassifikationsalgorithmen
- Fehlerrate bei einer Mehrheitsentscheidung (d. h. 26 Falschentscheidungen)

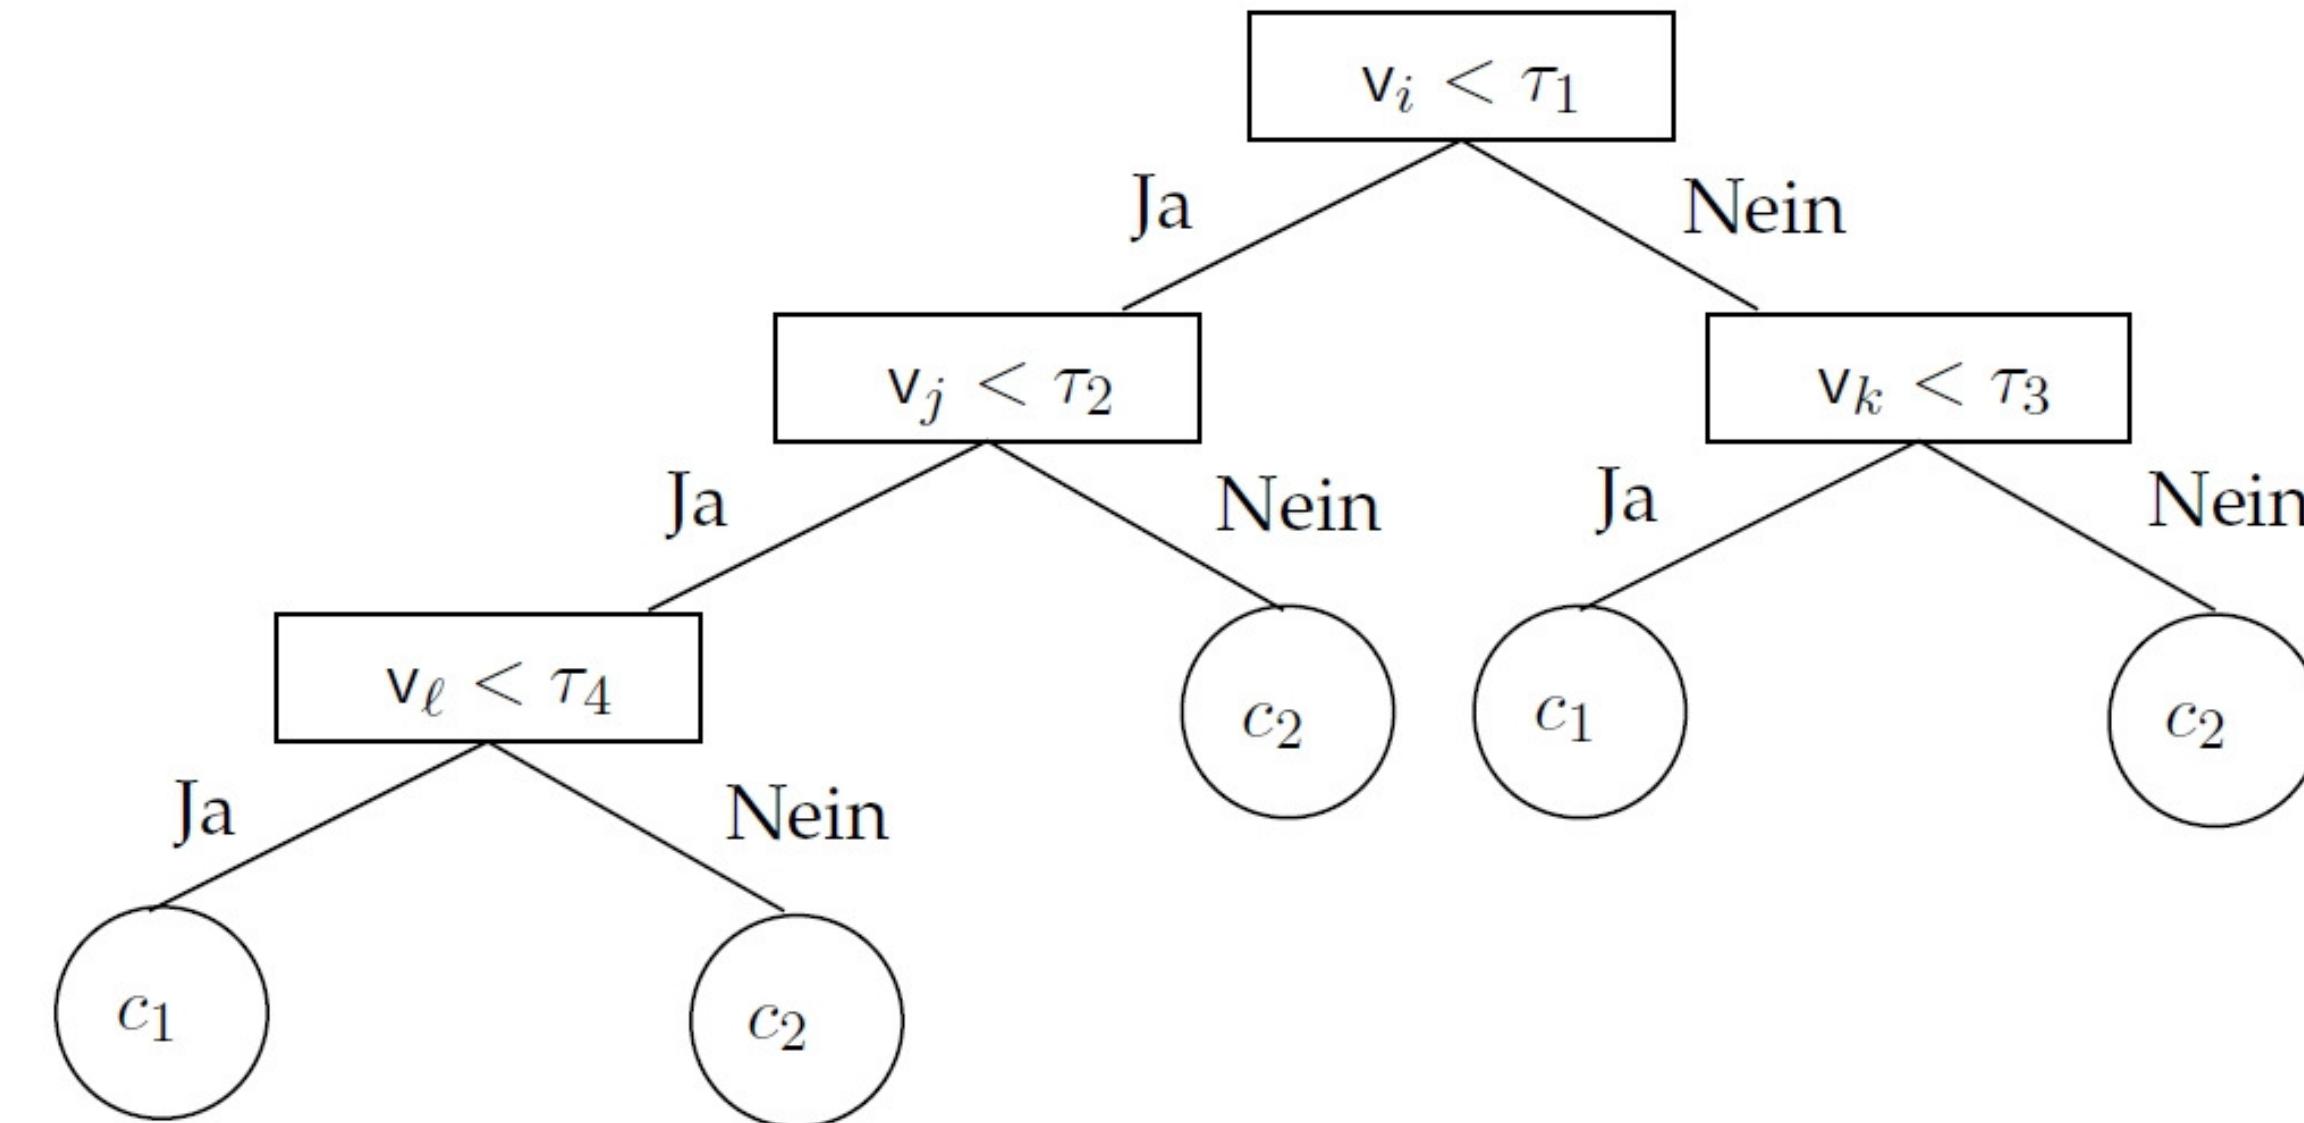
$$e_{\text{Ensemble}} = \sum_{b=26}^{50} \binom{50}{b} e^b (1 - e)^{50-b} = 0,0573 \ll e$$

Deep-Learning und Ensemble-Methoden

Ensemble aus Entscheidungsbäumen

Ein Entscheidungsbau

- Ein Entscheidungsbau ist ein mehrstufiges Klassifikationsverfahren, in dem bei jeder Stufe eine binäre „Ja/Nein“-Entscheidung gefällt wird
- Beispiel eines Entscheidungsbauums für 2-Klassen c_1 und c_2

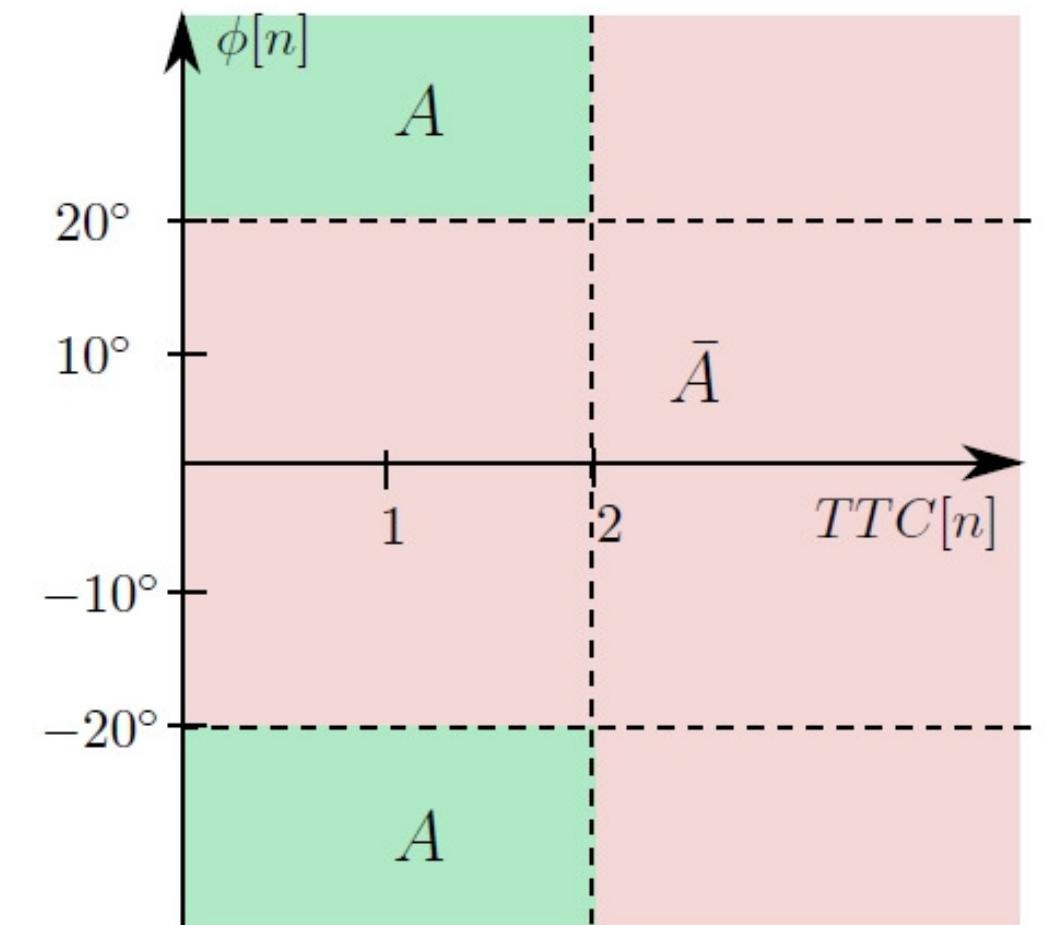
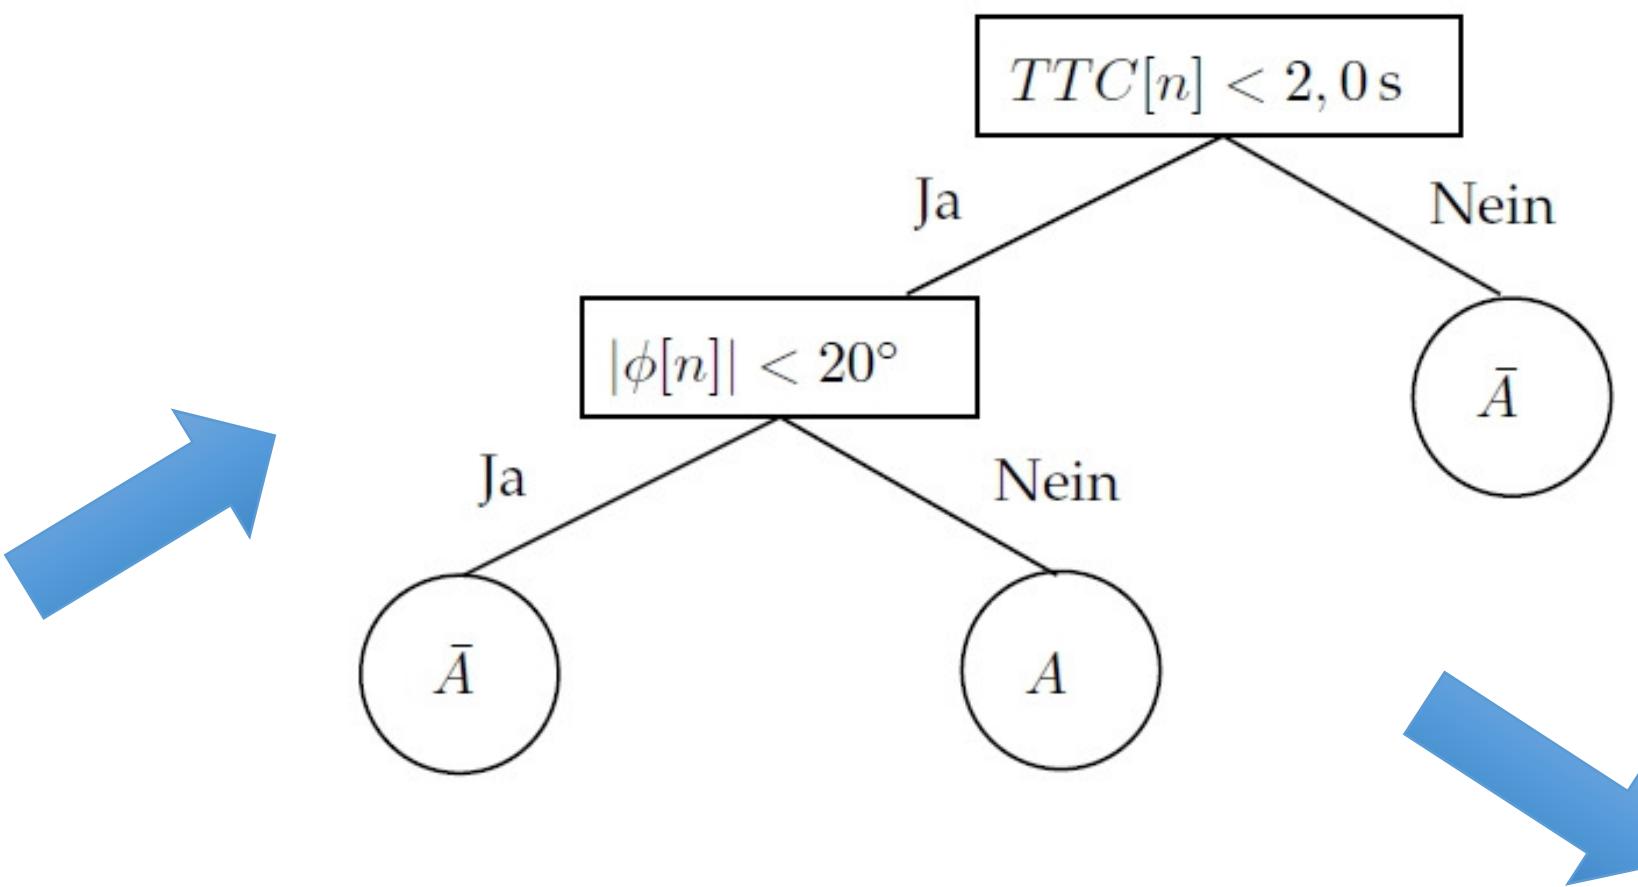
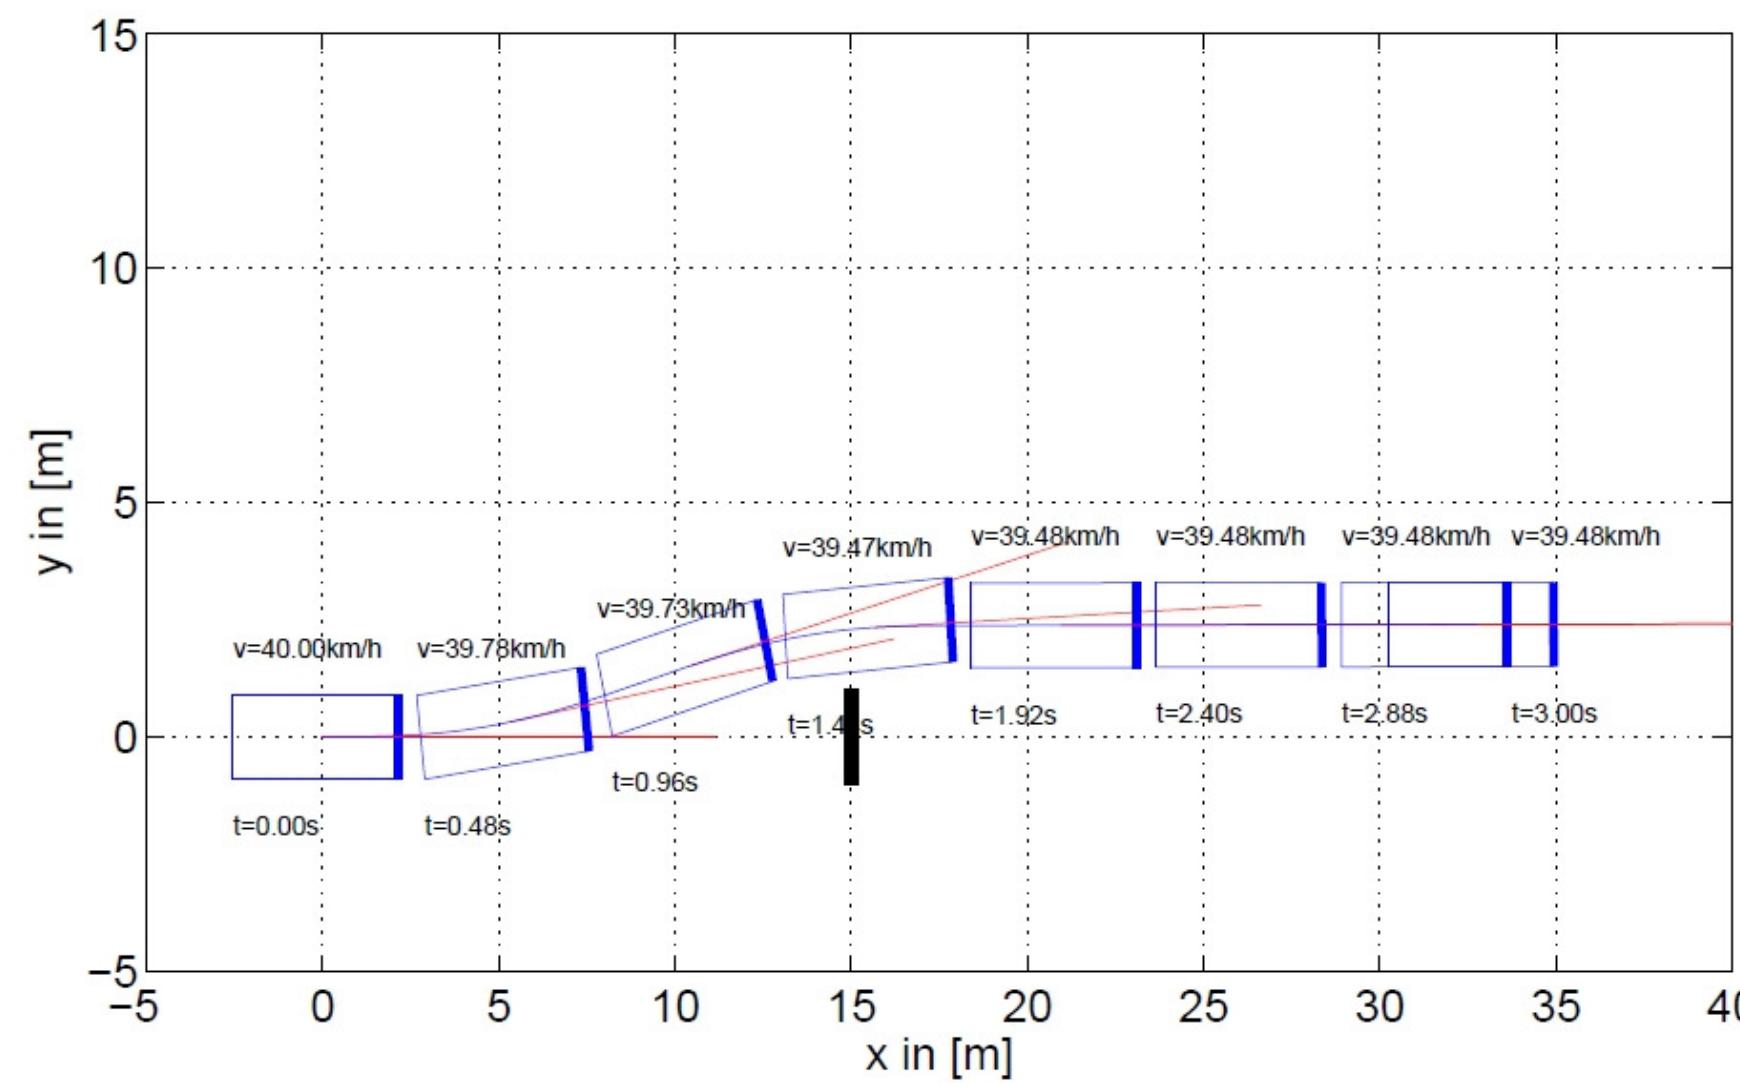


Deep-Learning und Ensemble-Methoden

Ensemble aus Entscheidungsbäumen

Ein Entscheidungsbaum

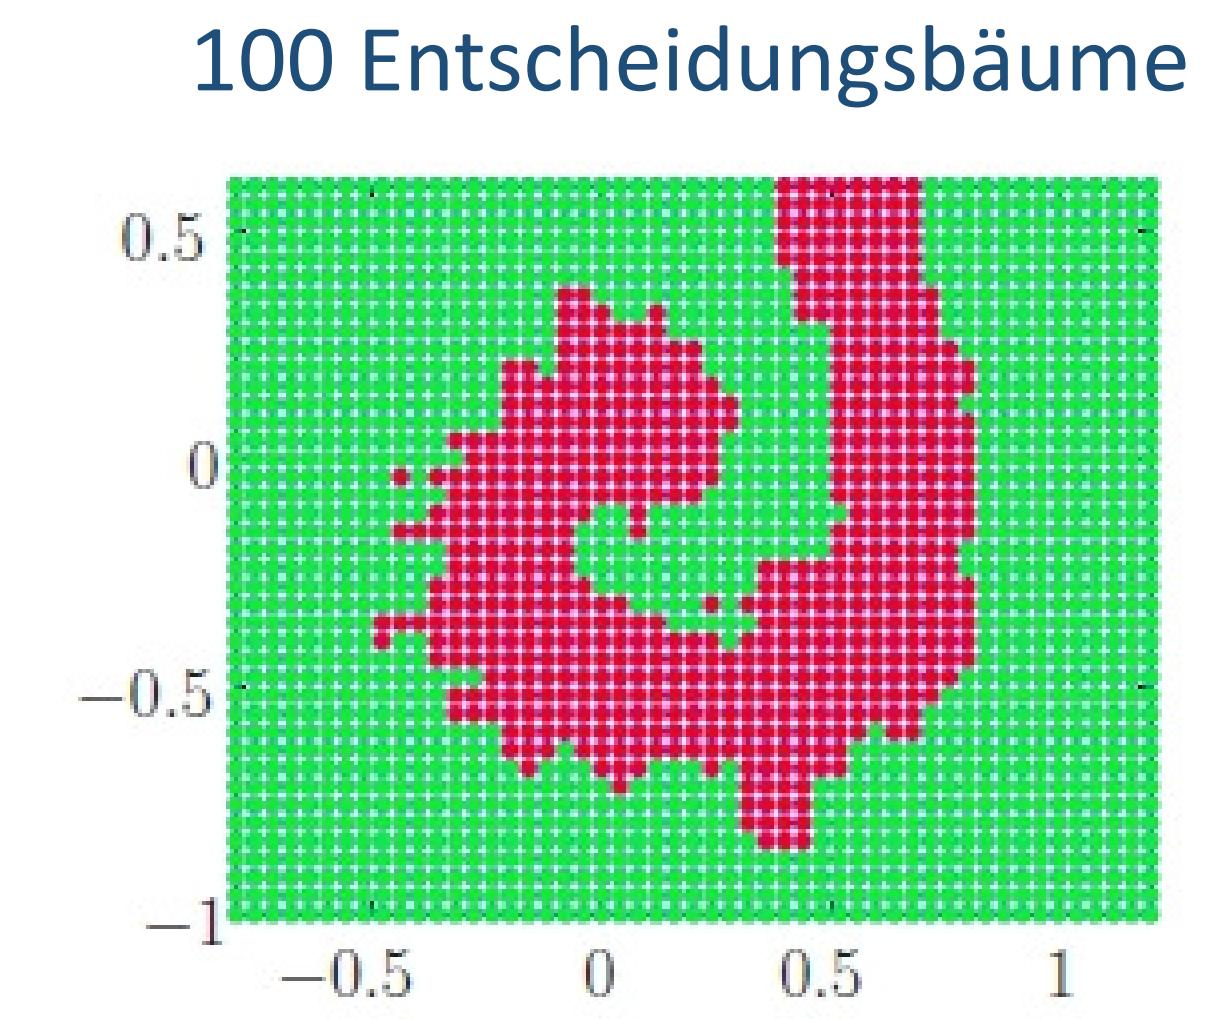
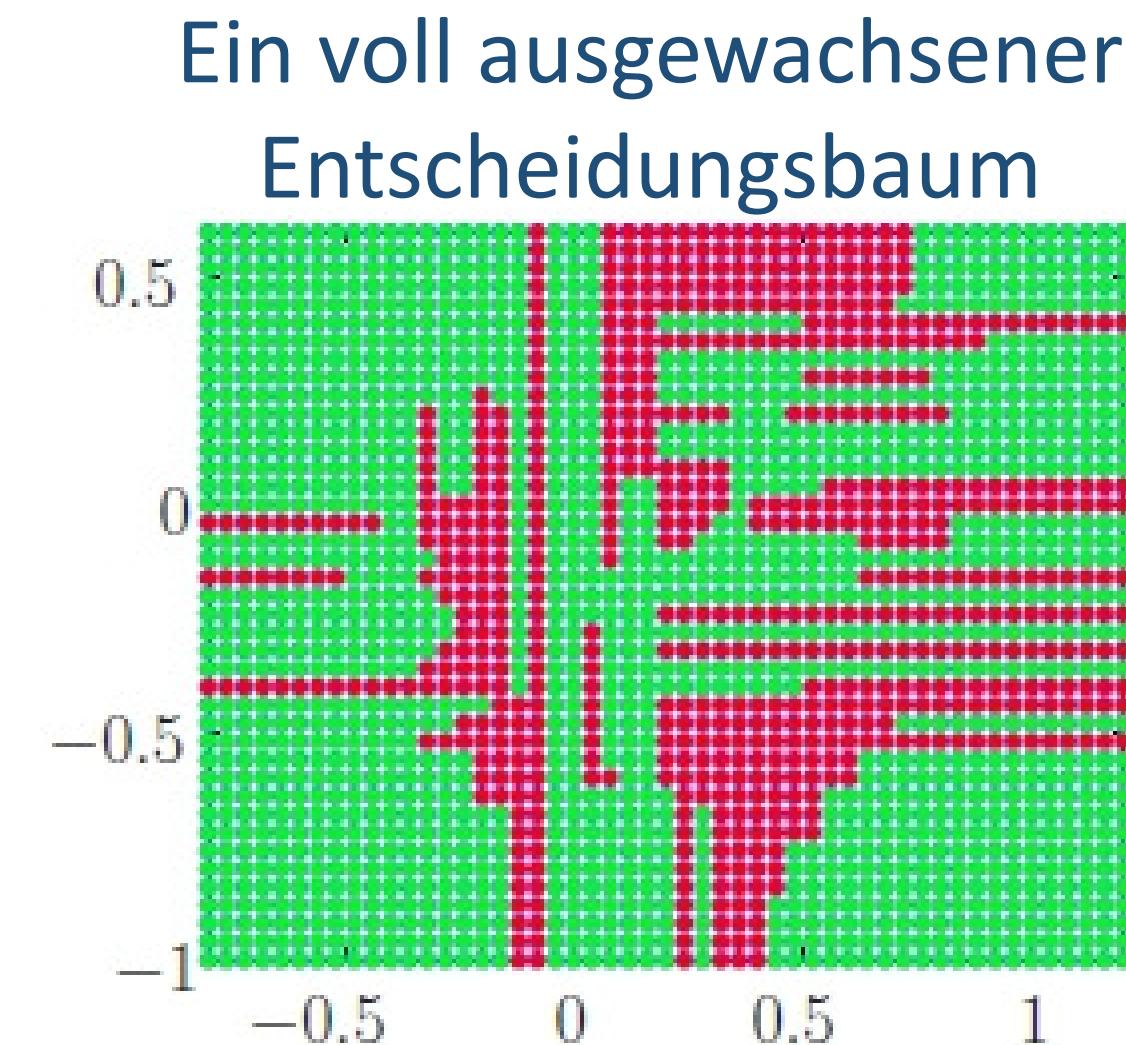
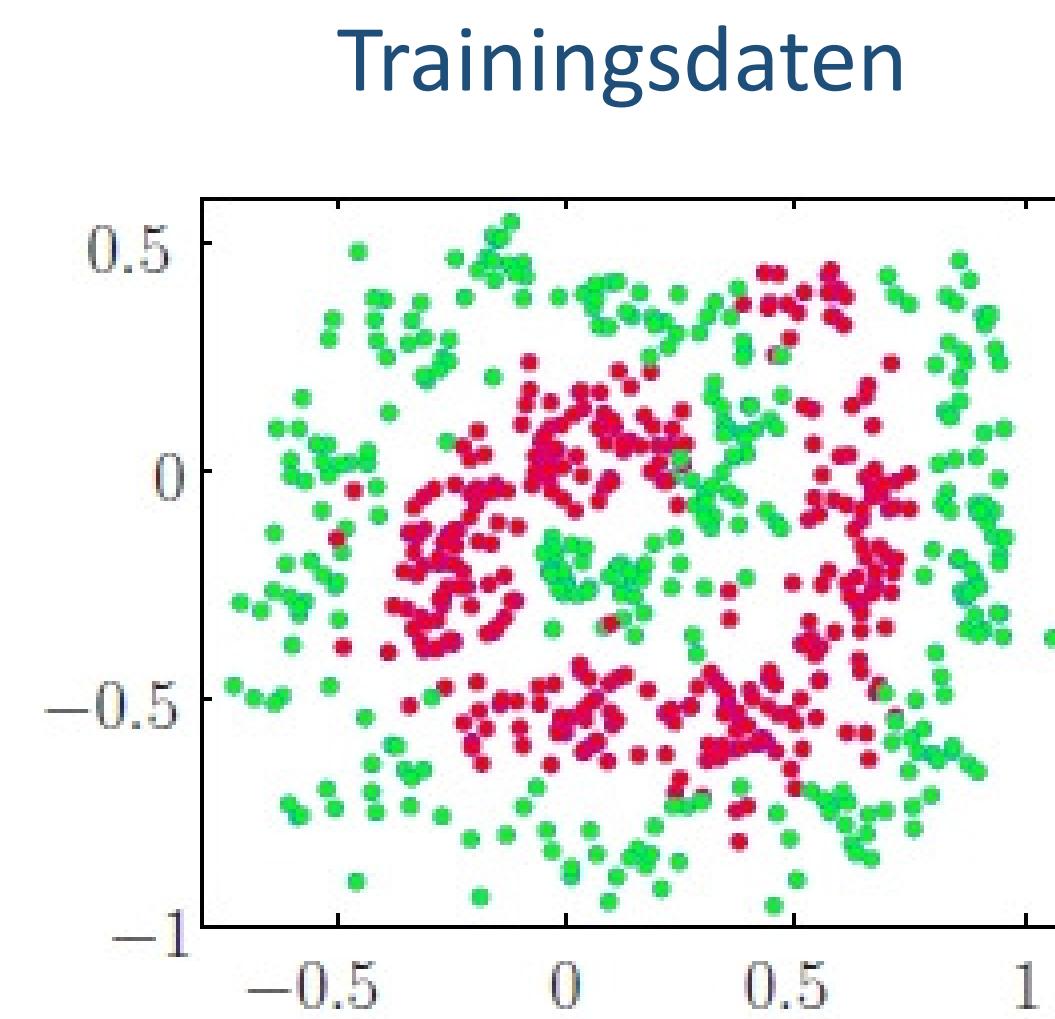
- Beispiel: Hat der Fahrer ein Ausweichmanöver gestartet?



Deep-Learning und Ensemble-Methoden

Ensemble aus Entscheidungsbäumen

- Ensemble von voll ausgewachsenen Entscheidungsbäumen (*Random Forest* \equiv RF)
- Beispiel: Rot soll von Grün getrennt werden („Spiralenstruktur“)



- Unabhängigkeit der einzelnen Entscheidungsbäume im RF
 - Bootstrap
 - Zufällige Auswahl eines Merkmals pro Verzweigung

Inhalt

Maschinelle Lernverfahren und automatisiertes Fahren

Deep-Learning und Ensemble-Methoden

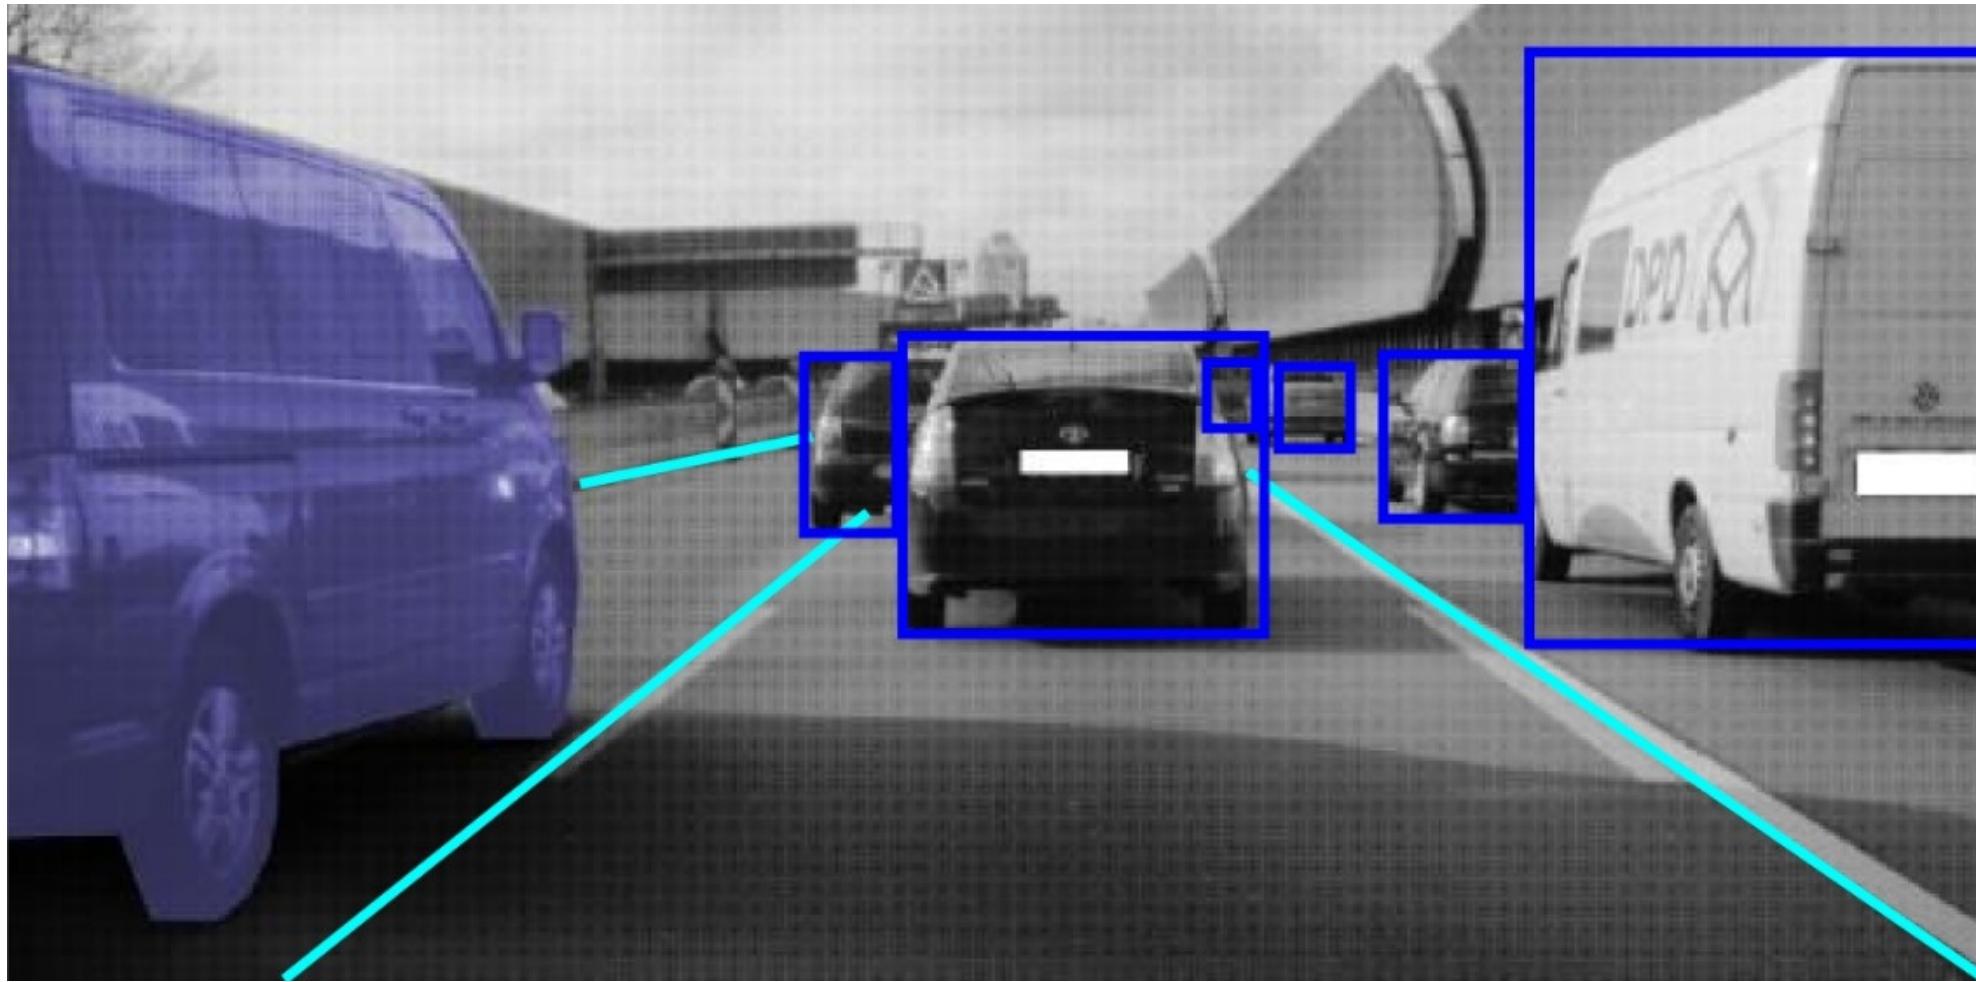
Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung
für autonome Fahrzeuge

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

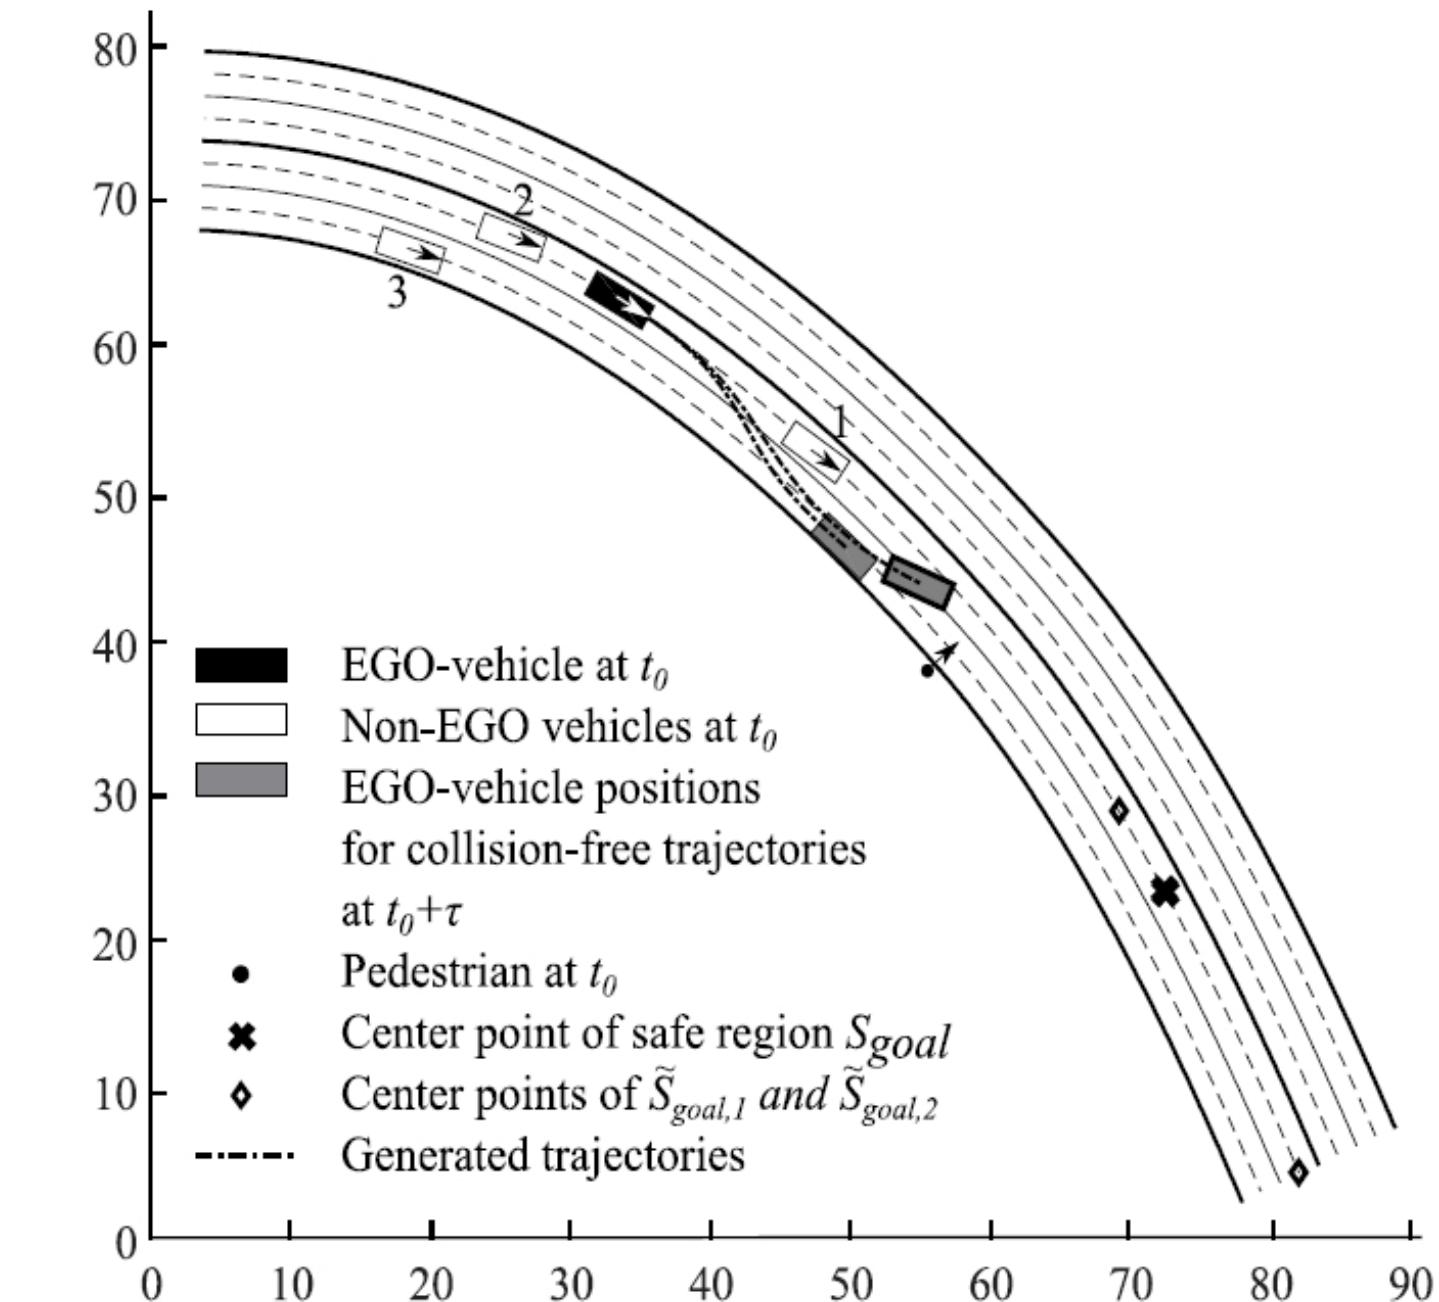
Verwendung maschinellder Lernverfahren für autonome Fahrzeuge

1. Umfeldwahrnehmung



Quelle: M. Reichel, M. Botsch, R. Rauschecker, K. Siedersberger und M. Maurer, „Situation aspect modelling and classification using the Scenario Based Random Forest algorithm for convoy merging situations,“ *IEEE International Conference on Intelligent Transportation Systems*, 2010.

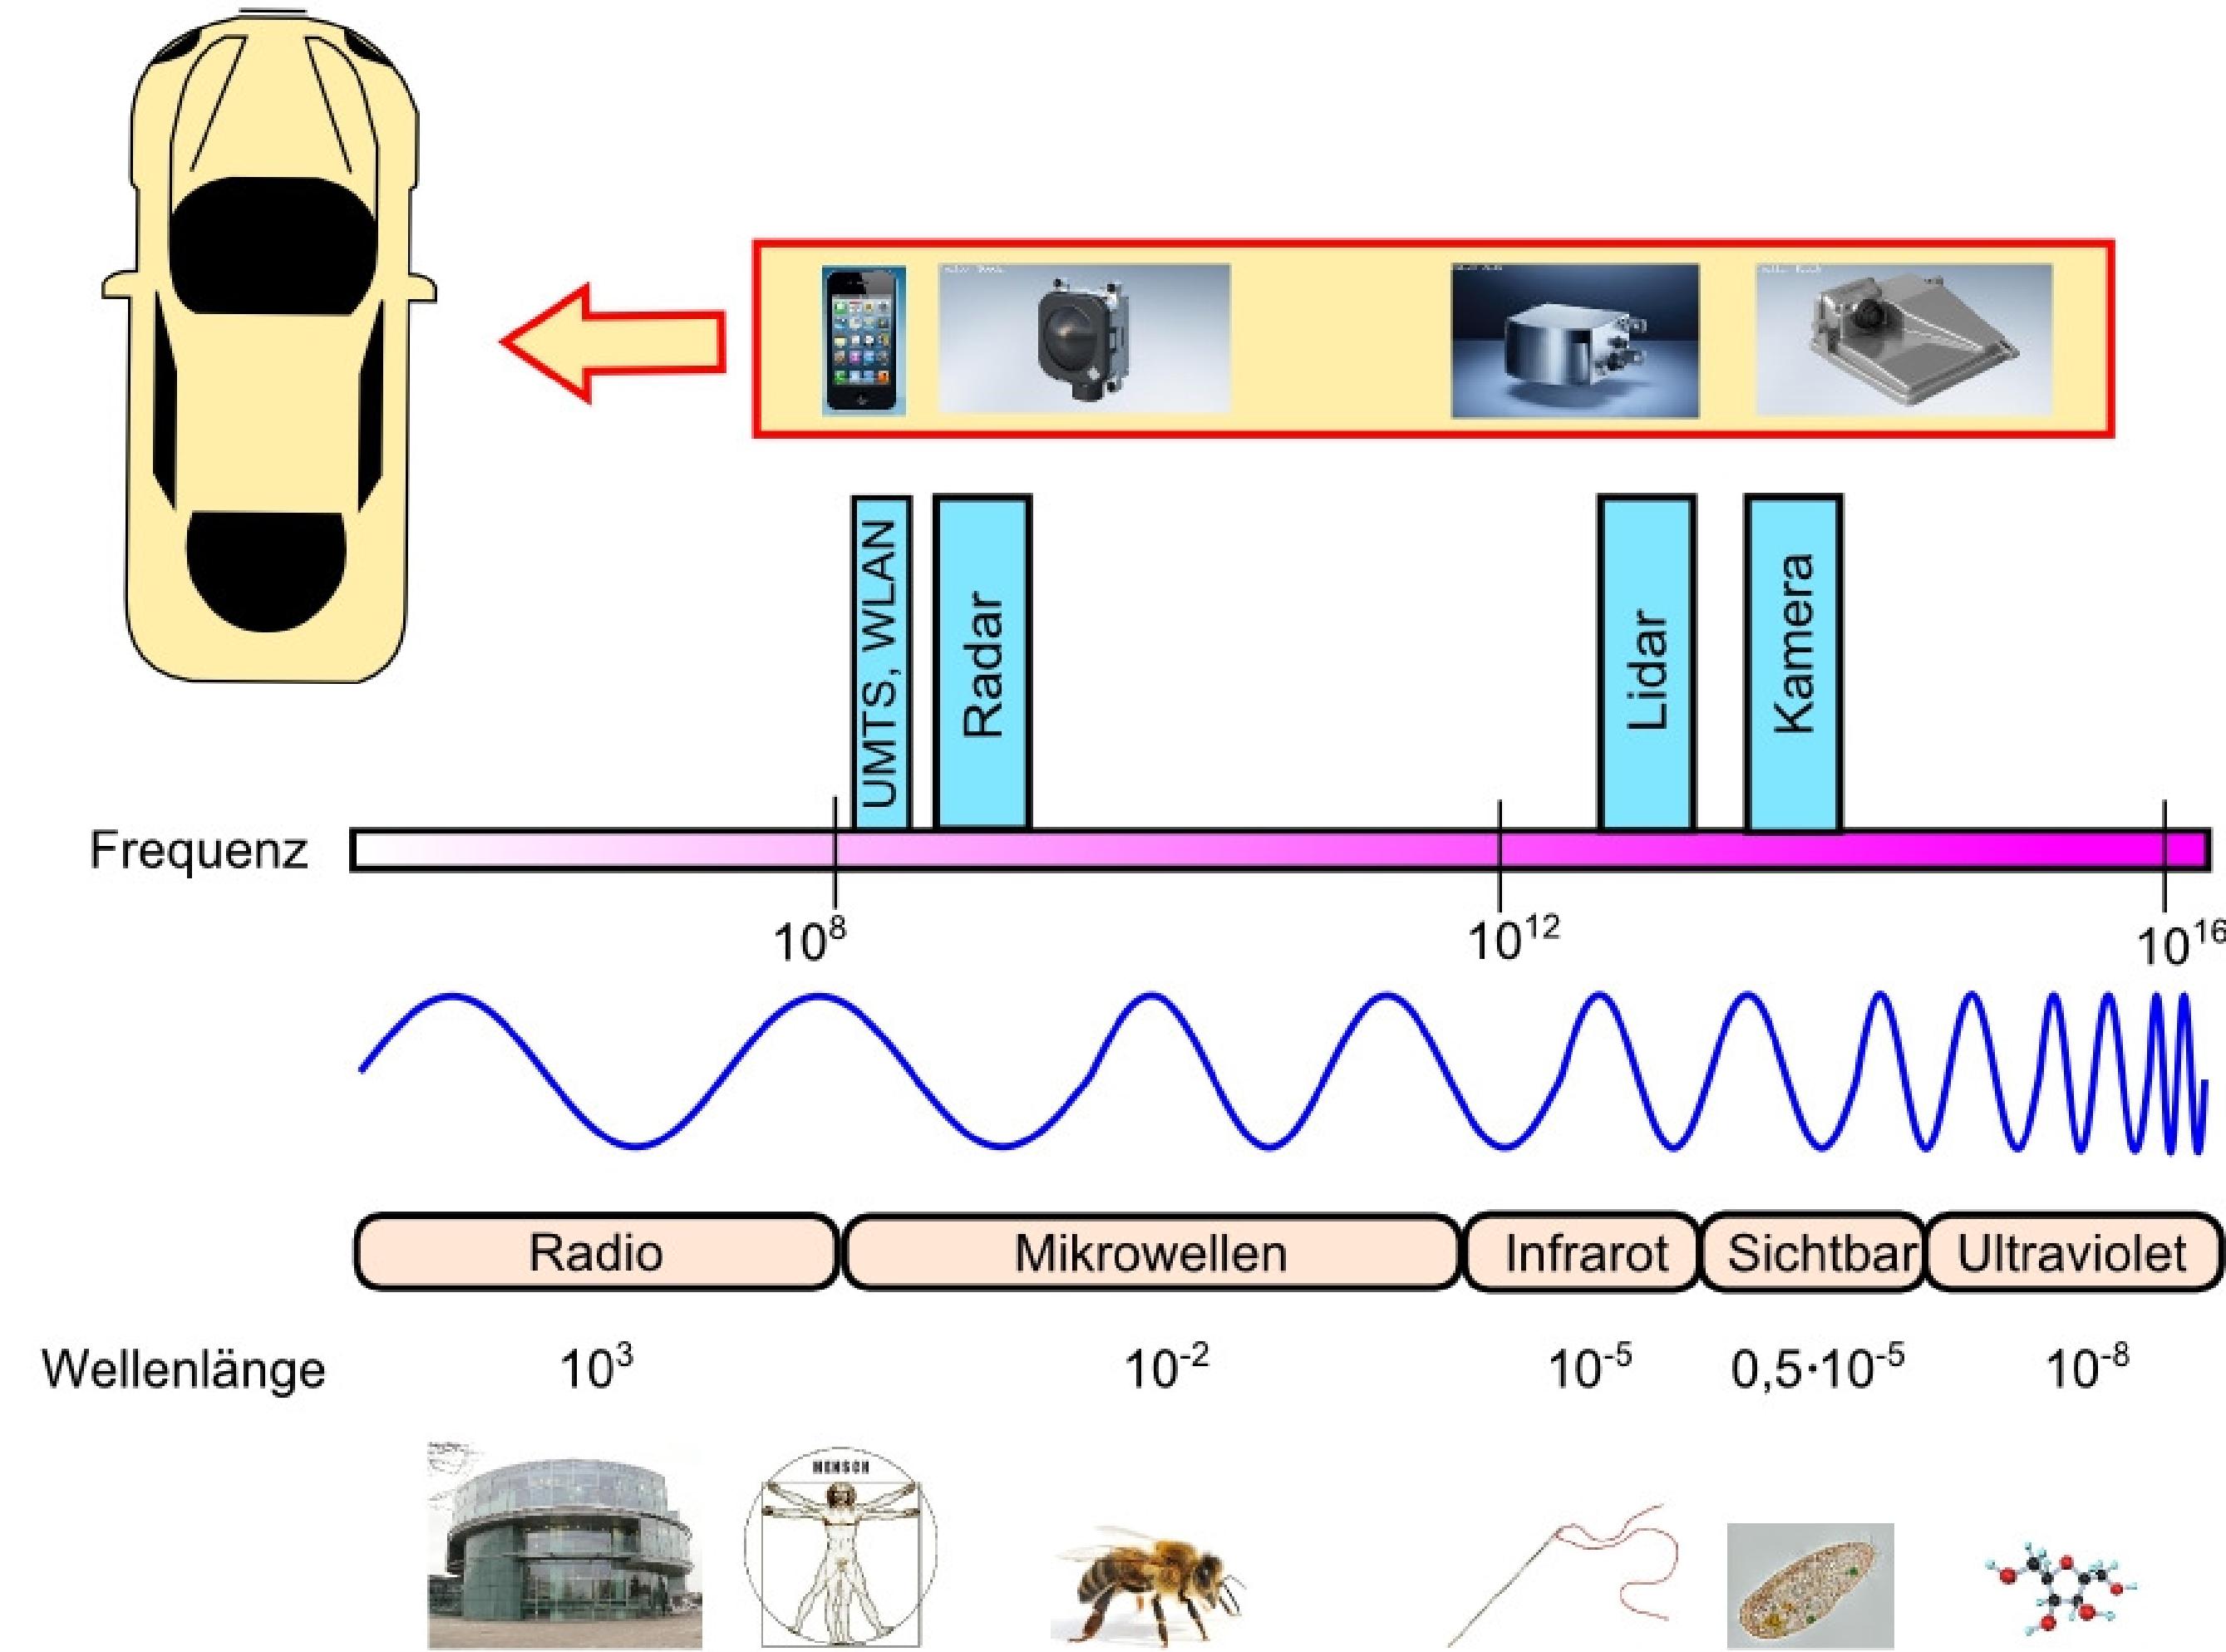
2. Fahrverhalten / Trajektorienplanung



Quelle: Chaulwar, M. Botsch, T. Krueger und T. Miehling, “Planning of safe trajectories in dynamic multi-object traffic-scenarios”, *Journal of Traffic and Logistics Engineering*, Vol.4, no.2, 2016

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

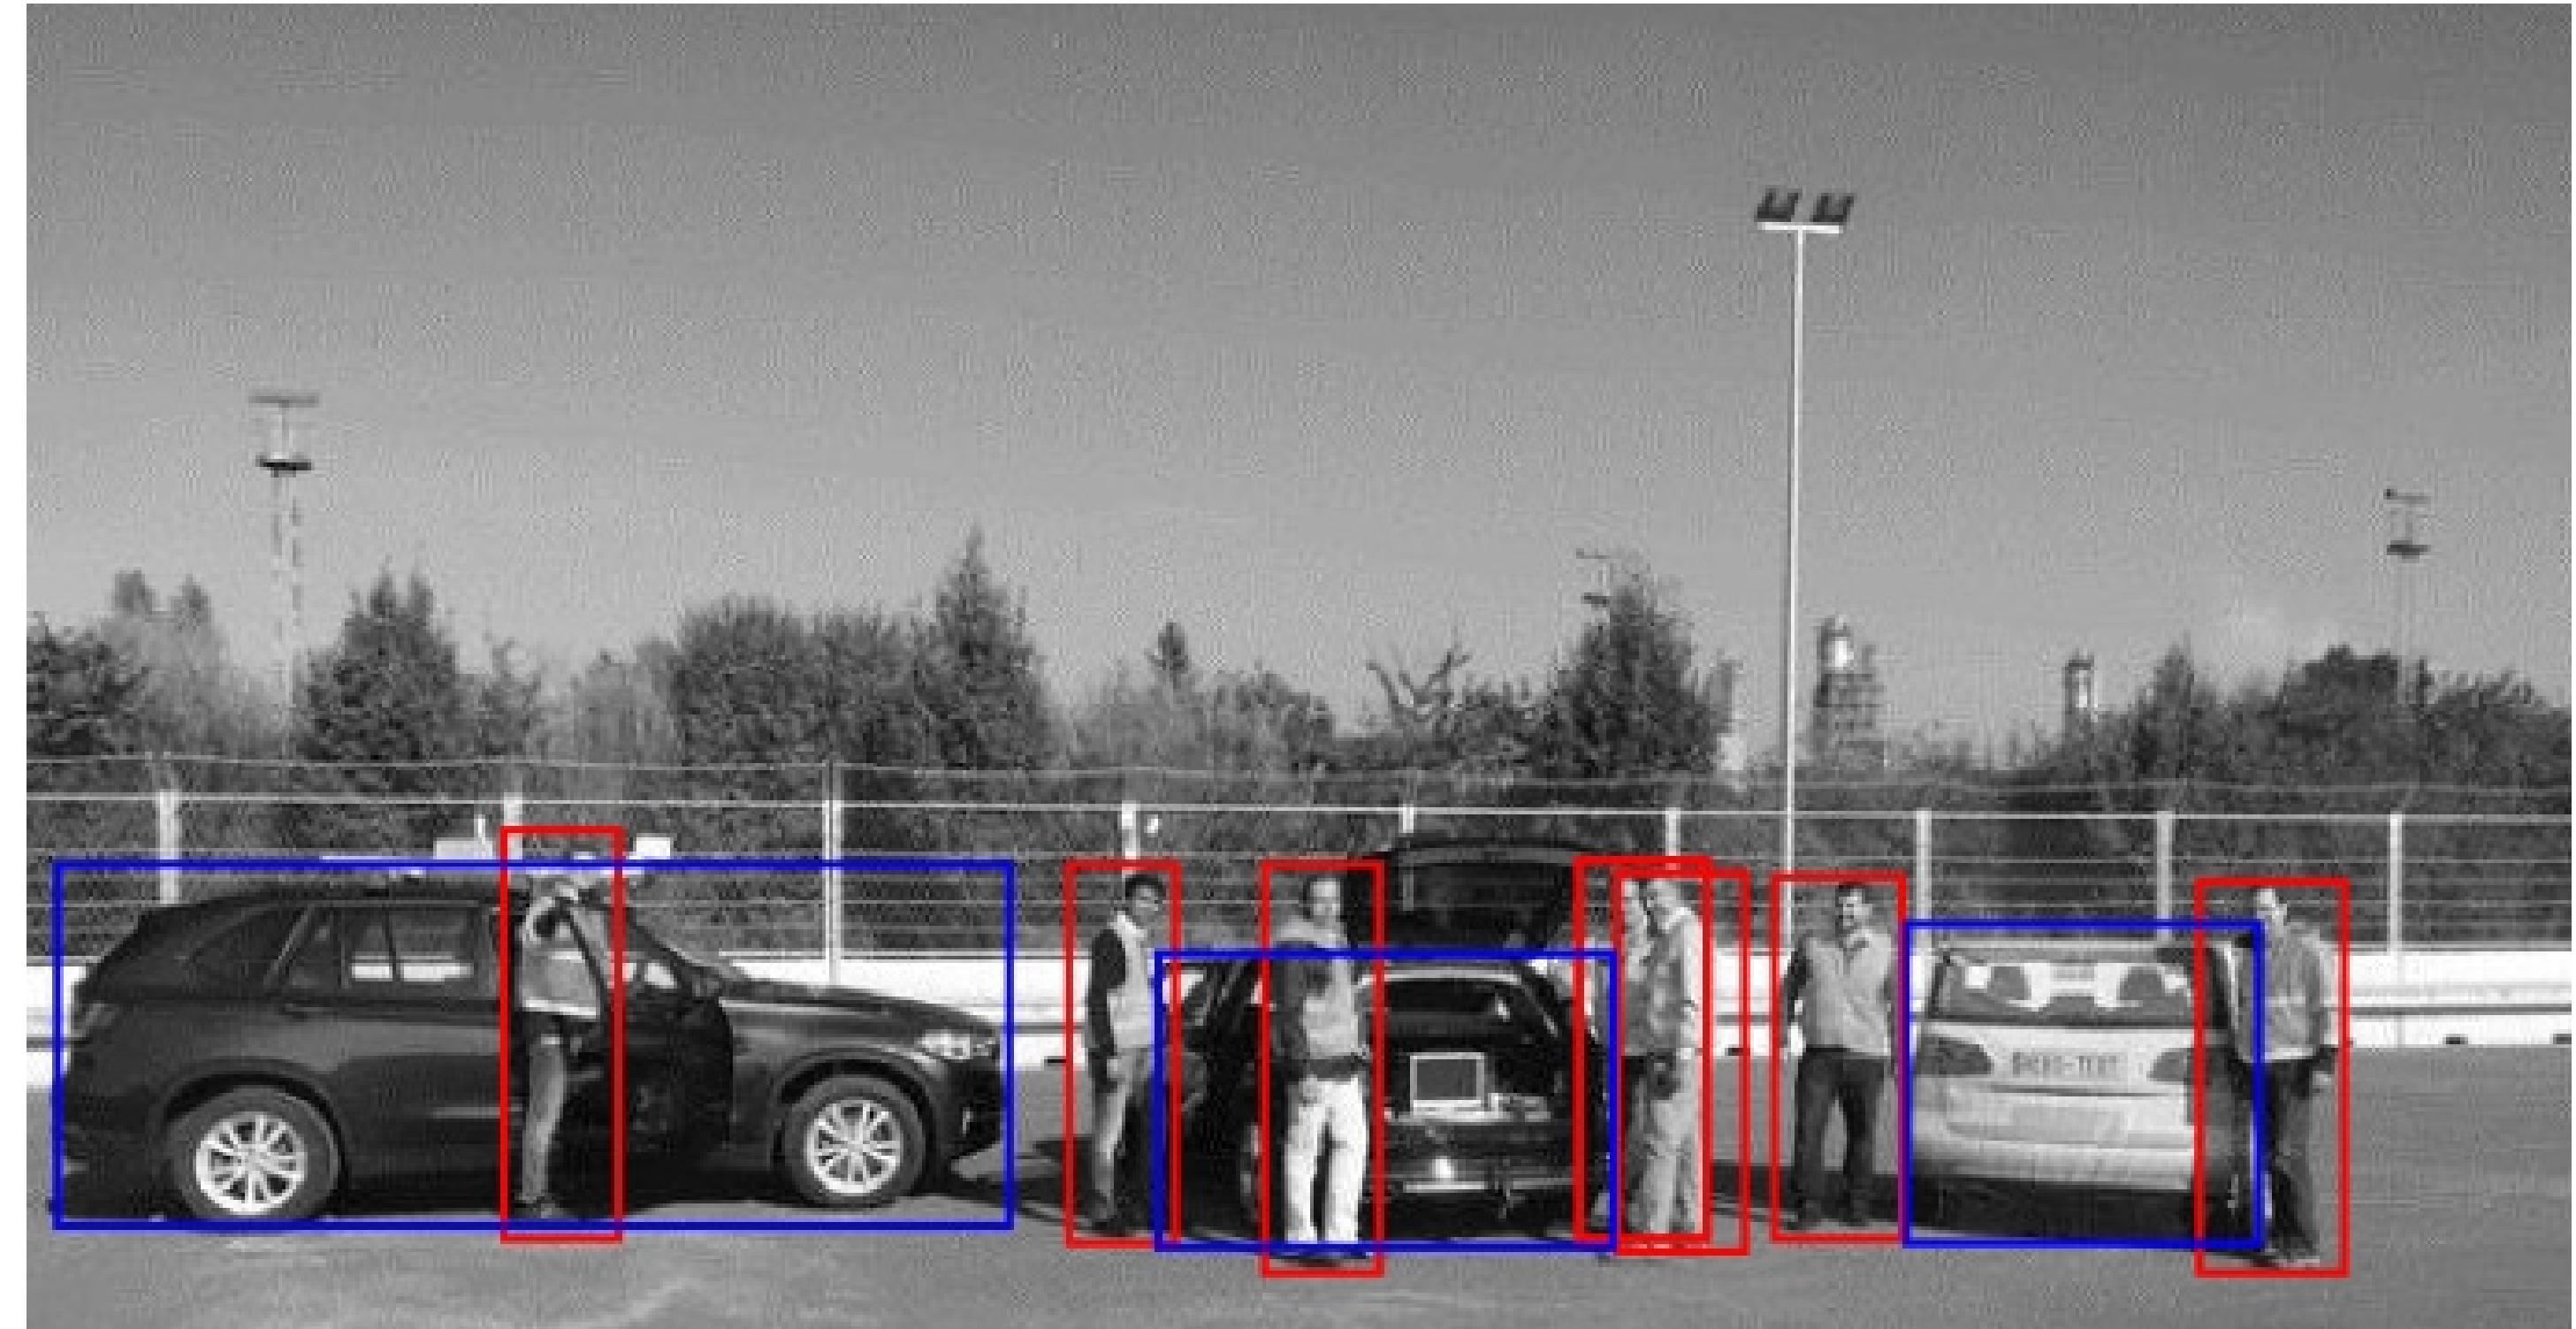
Umfeldwahrnehmung: vorausschauende Sensoren im Fahrzeug



Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

Umfeldwahrnehmung: Klassifikation von Objekten

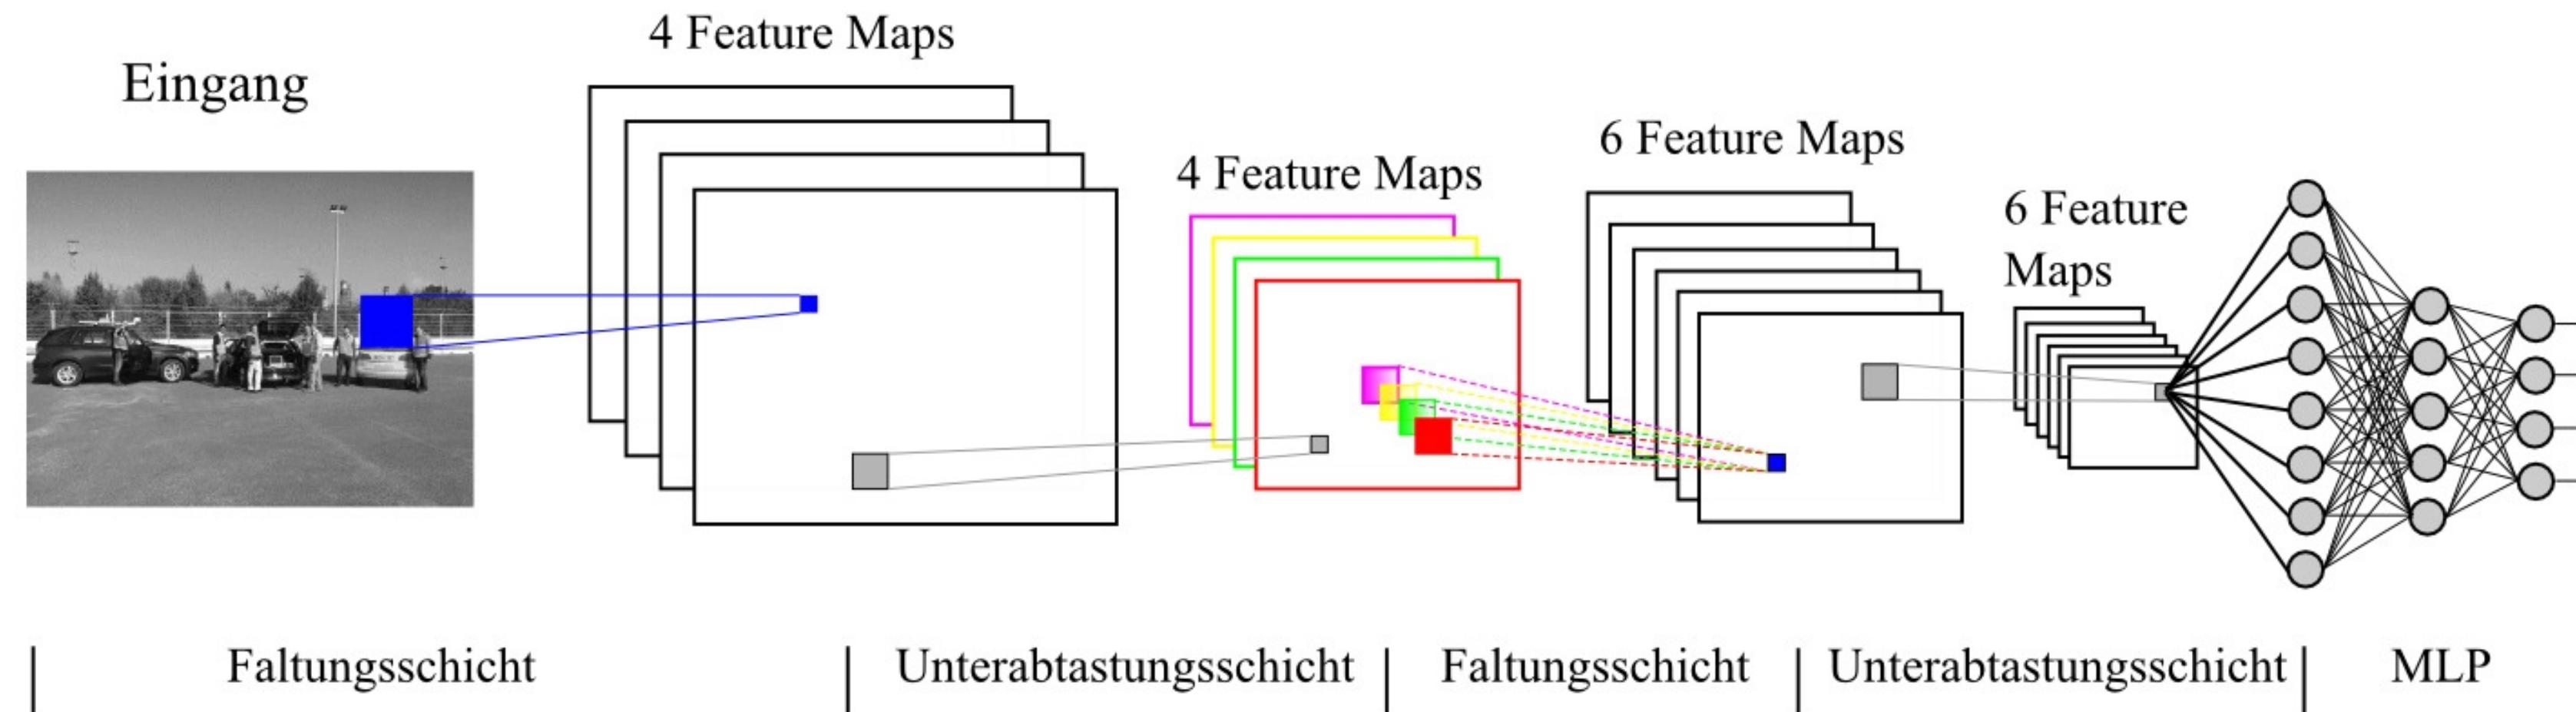
- Kameras sind heute Bestandteil von Fahrerassistenzsystemen
- Zentrale Aufgabe bei der Nutzung von Kameras: Objektklassifikation
 - Fahrzeug
 - Fußgänger
 - Spur / Bordstein
 - Verkehrszeichen
 - etc.



Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

Umfeldwahrnehmung: Klassifikation von Objekten

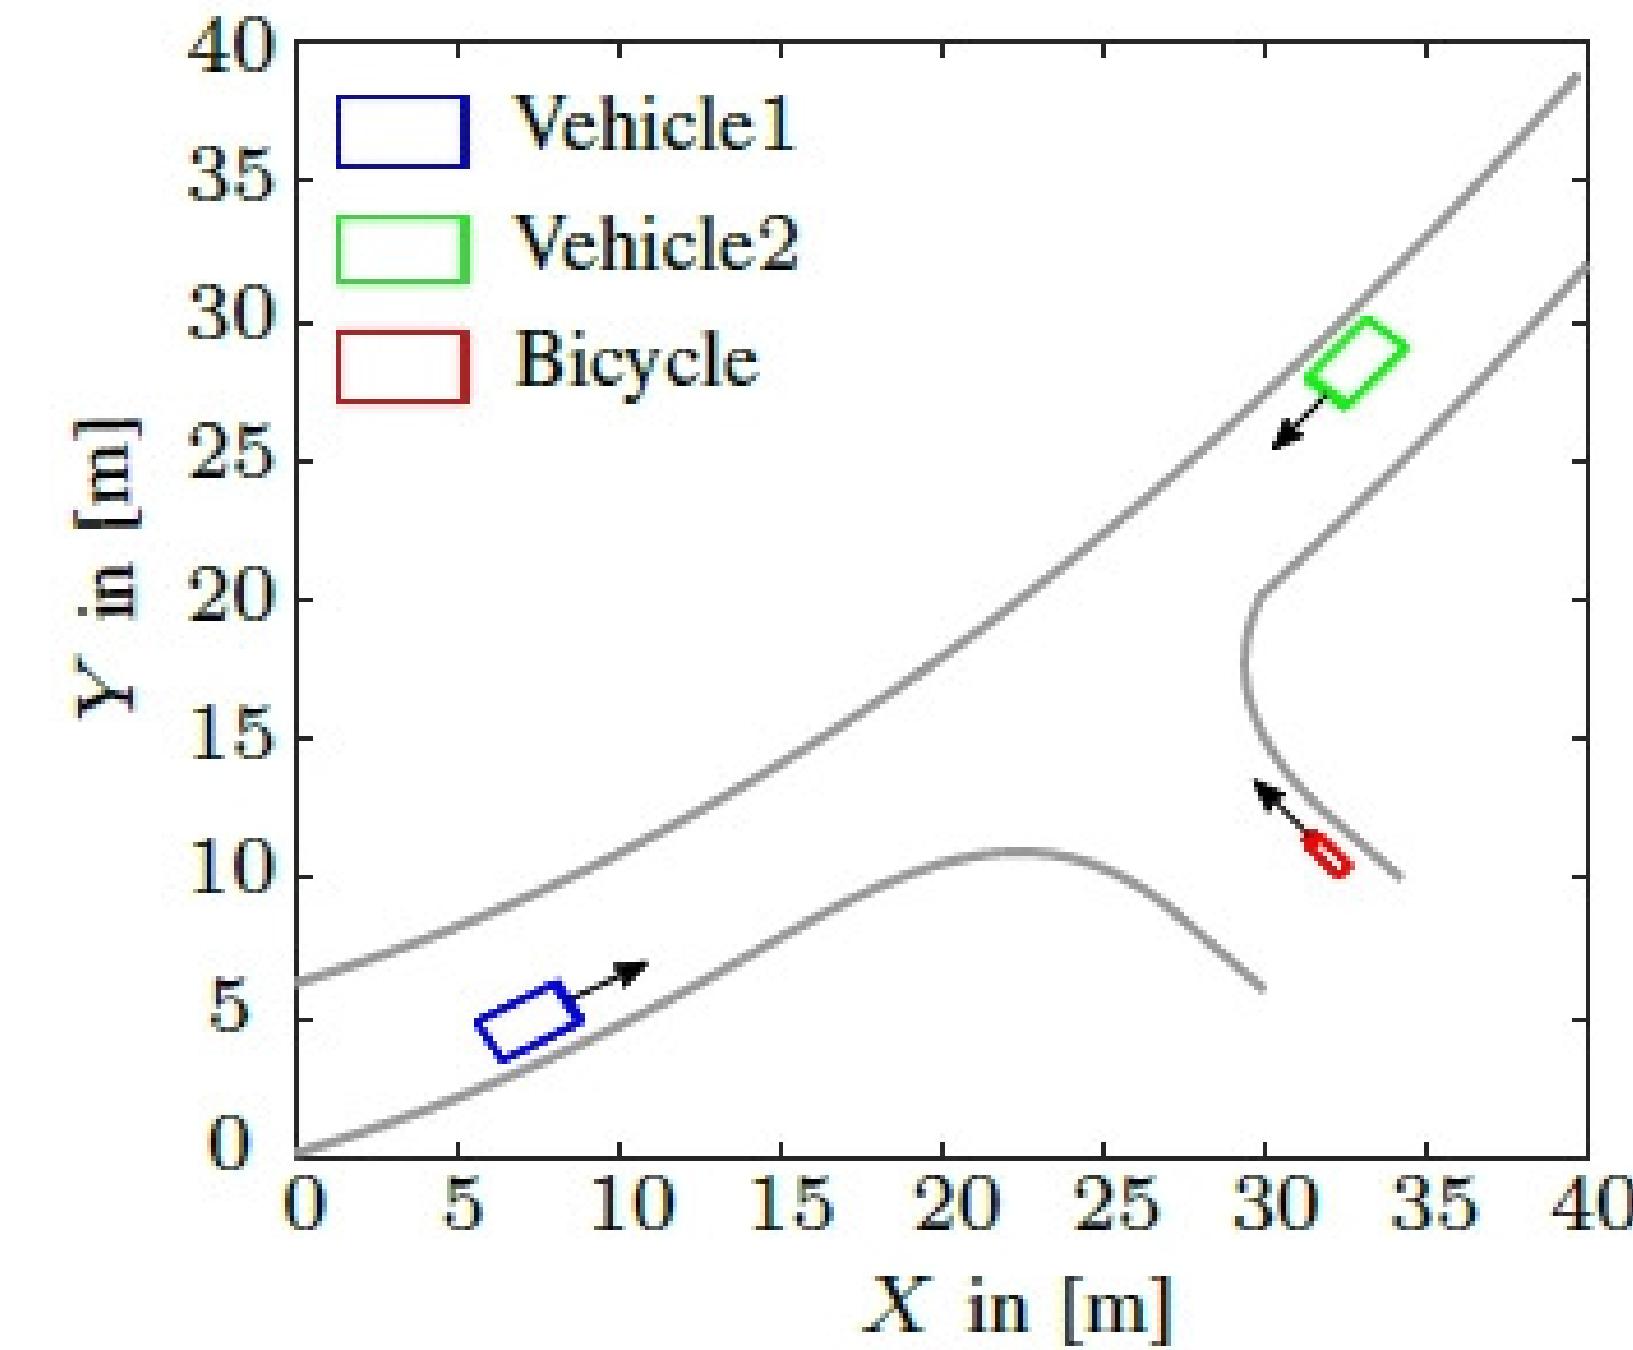
- Benötigt für das Training
 - Große Anzahl an Daten aus dem Straßenverkehr
 - Daten müssen „gelabelt“ werden \Rightarrow zum Großteil ein manueller Vorgang
 - Rechenleistung für das Optimieren
- Nach dem Training führen die angelernten Algorithmen ihre Klassifika-tions-aufgabe in Echtzeit aus und ändern sich „im Betrieb“ nicht mehr



Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

Umfeldwahrnehmung: kompakte Repräsentation der Umwelt zu jedem Zeitpunkt

- Befahrbarer und nicht befahrbar Raum
- Fahrspuren
- Eigenschaften für jeden Verkehrsteilnehmer in Sichtweite des *EGO*-Fahrzeugs
 - Objektklasse
 - Position
 - Geschwindigkeit
- Verkehrsschilder
- Ampelzustand
- Zustand des Fahrers
- etc.



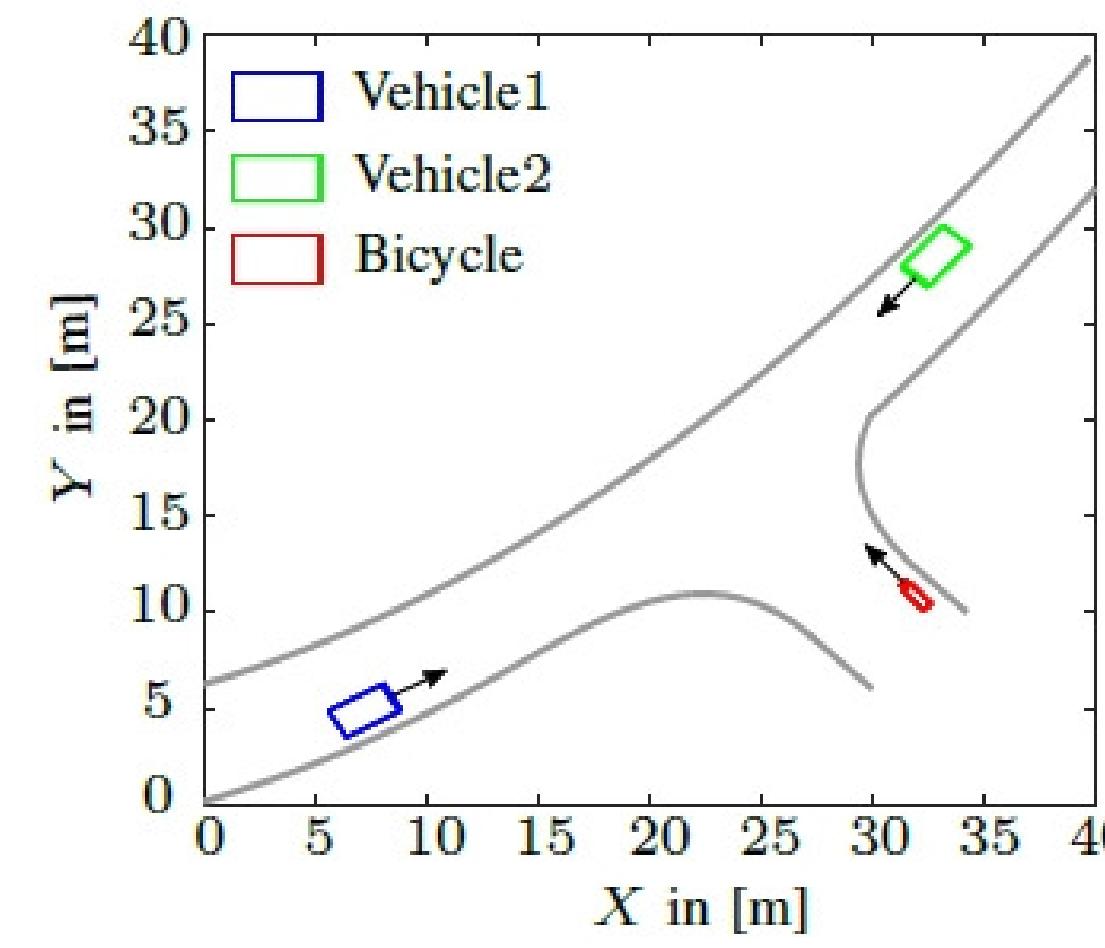
Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

Trajektorienplanung: Entscheidung **wohin** das Fahrzeug fahren soll und **wie** es hinfahren soll (Längs- und Querdynamik)

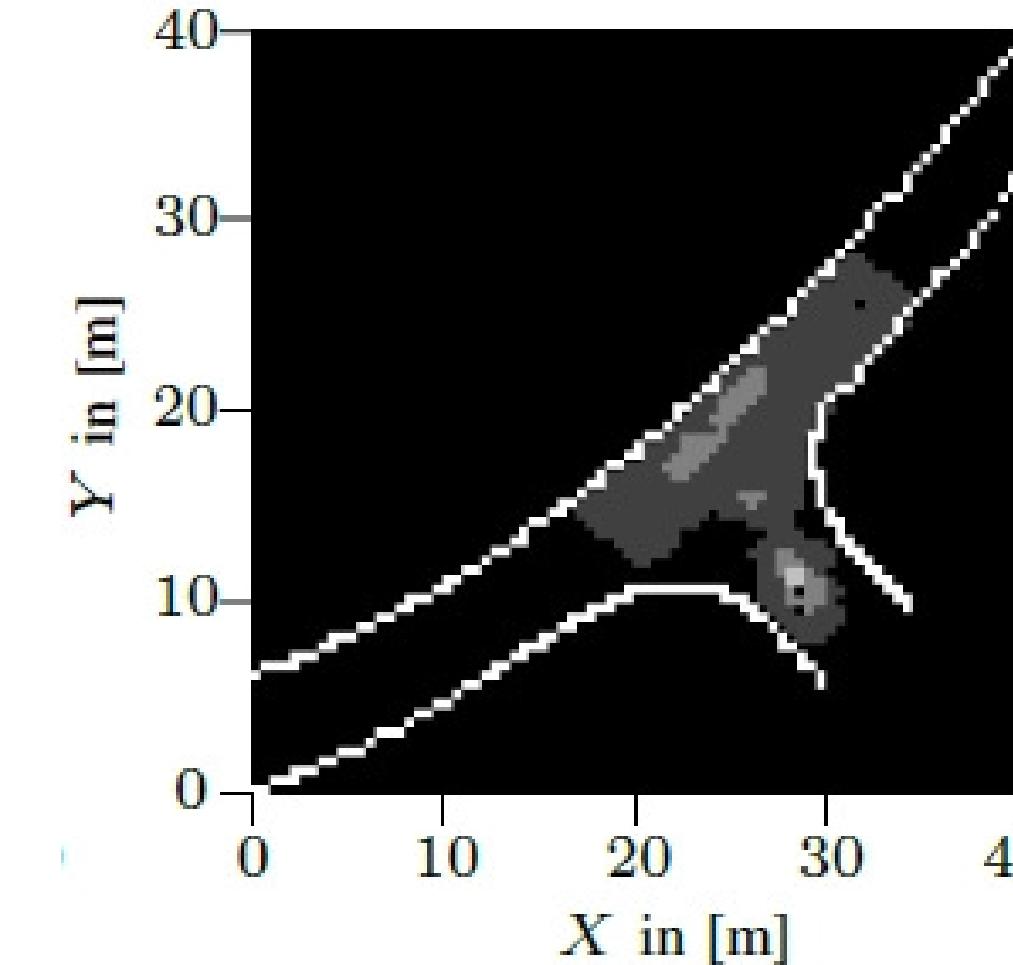
- Interpretation der Situation

- Verwendung von Kontextwissen
- Kurz- und mittelfristige Prädiktion der Bewegung der anderen Verkehrsteilnehmer
- Kritikalitätsschätzung

Festlegung des kurz- bzw. mittelfristigen Fahrziels



Prädiktion
Belegung
mittels RF
in 2 Sek.

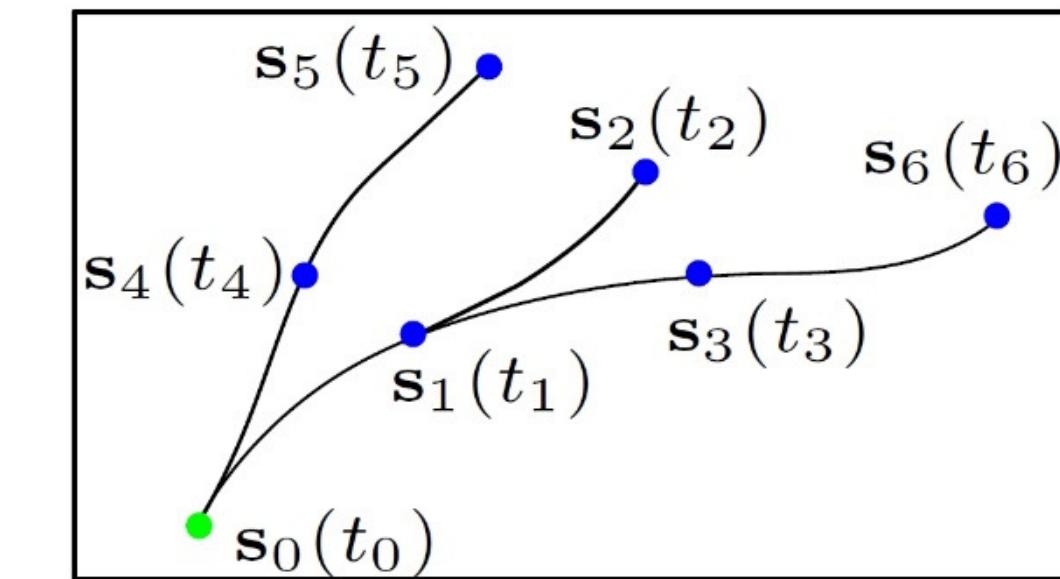
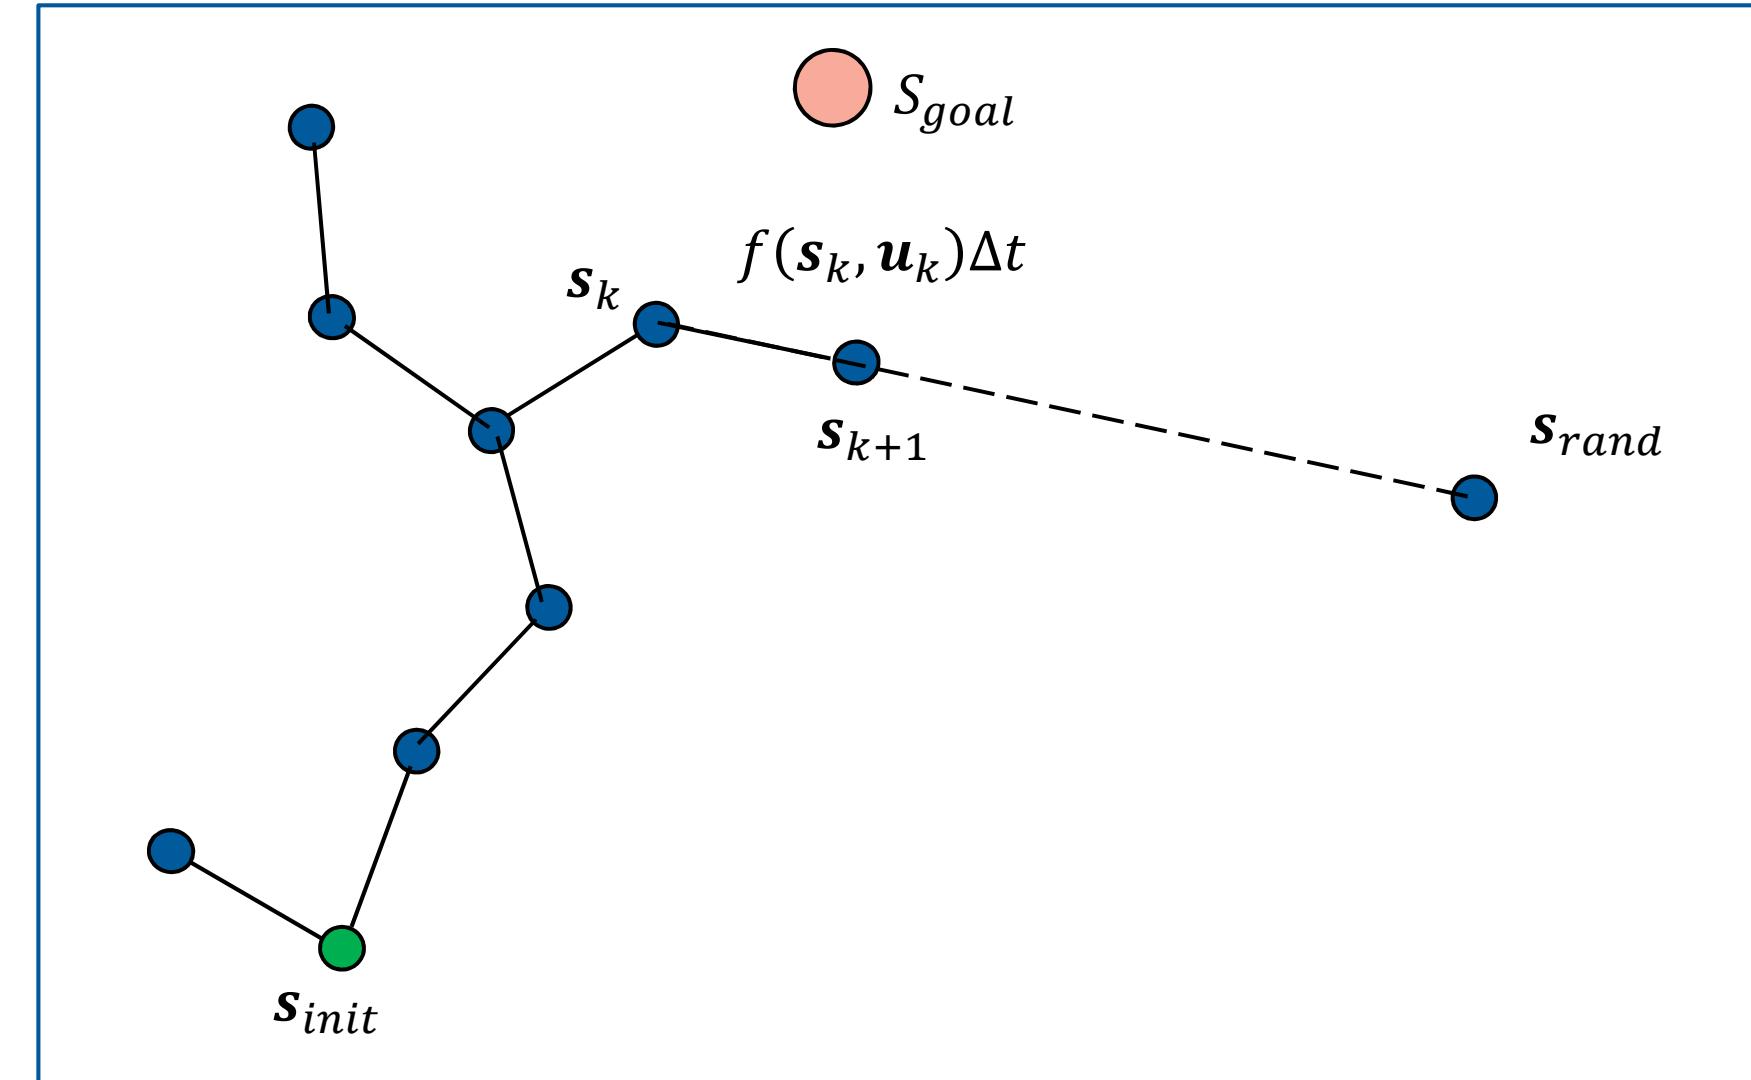


Quelle: P. Nadarajan; M. Botsch, "Probability Estimation for Predicted-Occupancy Grids in Vehicle Safety Applications Based on Machine Learning", IEEE Intelligent Vehicles Symposium, 2016

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

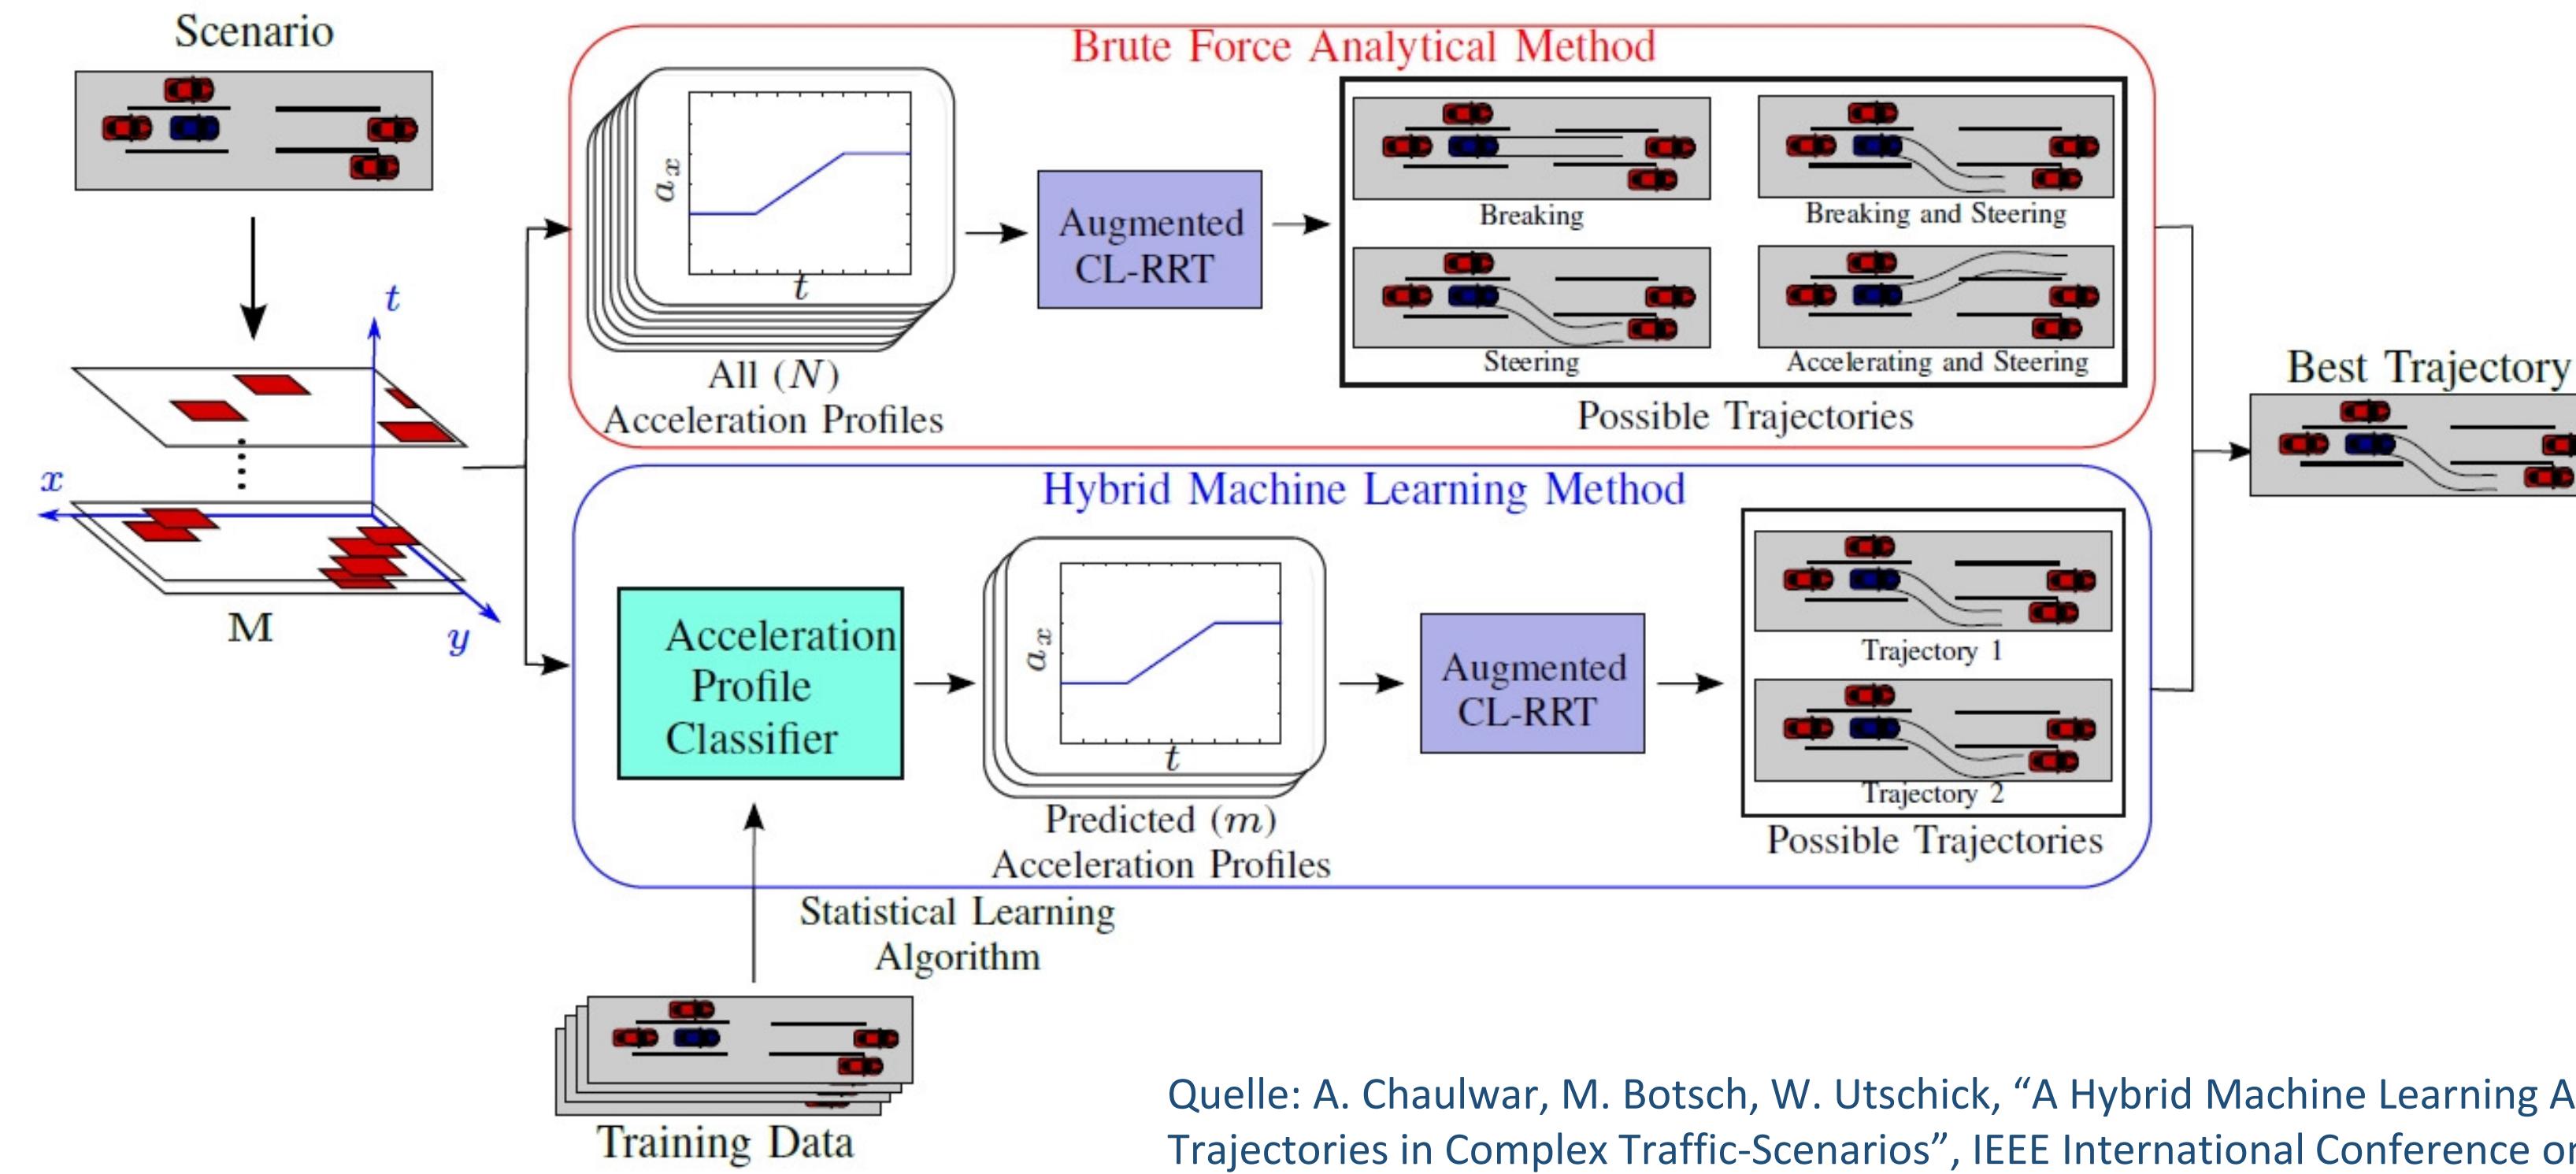
Trajektorienplanung: Entscheidung wohin das Fahrzeug fahren soll und **wie** es hinfahren soll (Längs- und Querdynamik)

- Trajektorienplanung
 - Potenzialfeldmethoden
 - Gitterbasierte Algorithmen (A* oder D*)
 - Algorithmen die auf zufälligem Sampeln beruhen (**RRT**)
 - Maschinelle Lernverfahren
 - etc.



Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

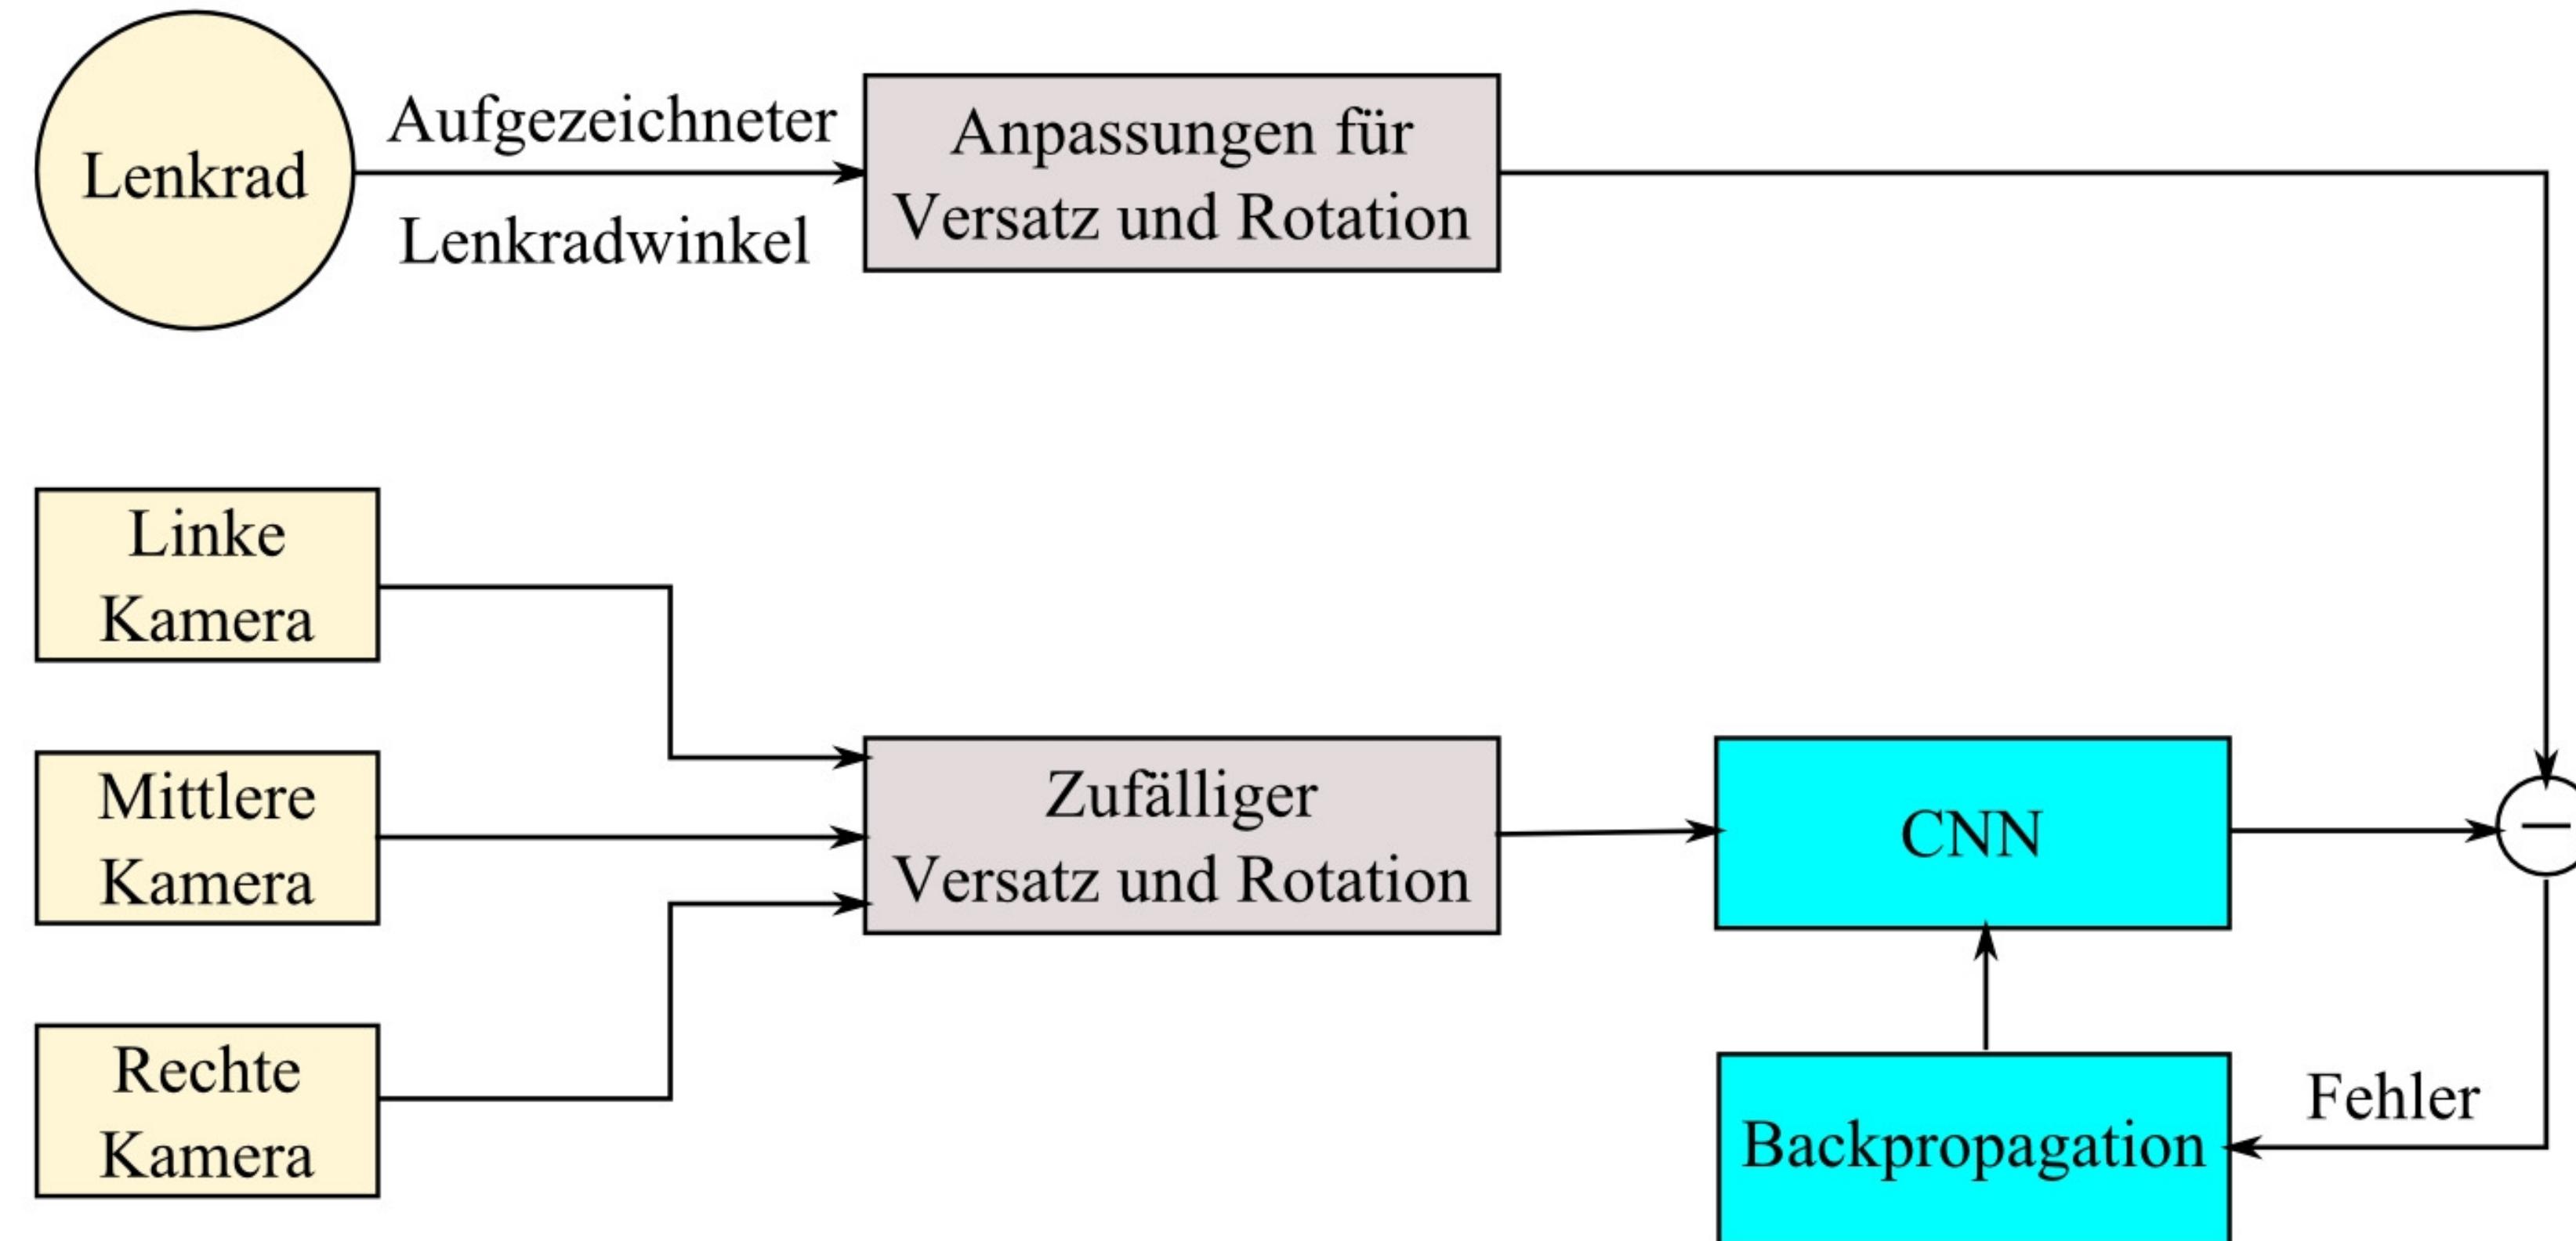
- RRT Algorithmus ist probabilistisch vollständig d. h. es kann sehr lange dauern bis eine Trajektorie gefunden wird
- Verwendung von maschinellen Lernverfahren um den RRT-Algorithmus zu beschleunigen durch Vorschläge für geeignete Lenk- und Beschleunigungsprofile



Quelle: A. Chaulwar, M. Botsch, W. Utschick, "A Hybrid Machine Learning Approach for Planning Safe Trajectories in Complex Traffic-Scenarios", IEEE International Conference on Machine Learning and Applications, 2016

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung für autonome Fahrzeuge

Trajektorienplanung: End-To-End Learning



Idee vorgestellt in: M. Bojarski, D. D. Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, J. Zhang, X. Zhang, J. Zhao und K. Zieba,
„End to End Learning for Self- Driving Cars,“ in arXiv.org e-Print archive: 1604.07316, 2016

Inhalt

Maschinelle Lernverfahren und automatisiertes Fahren

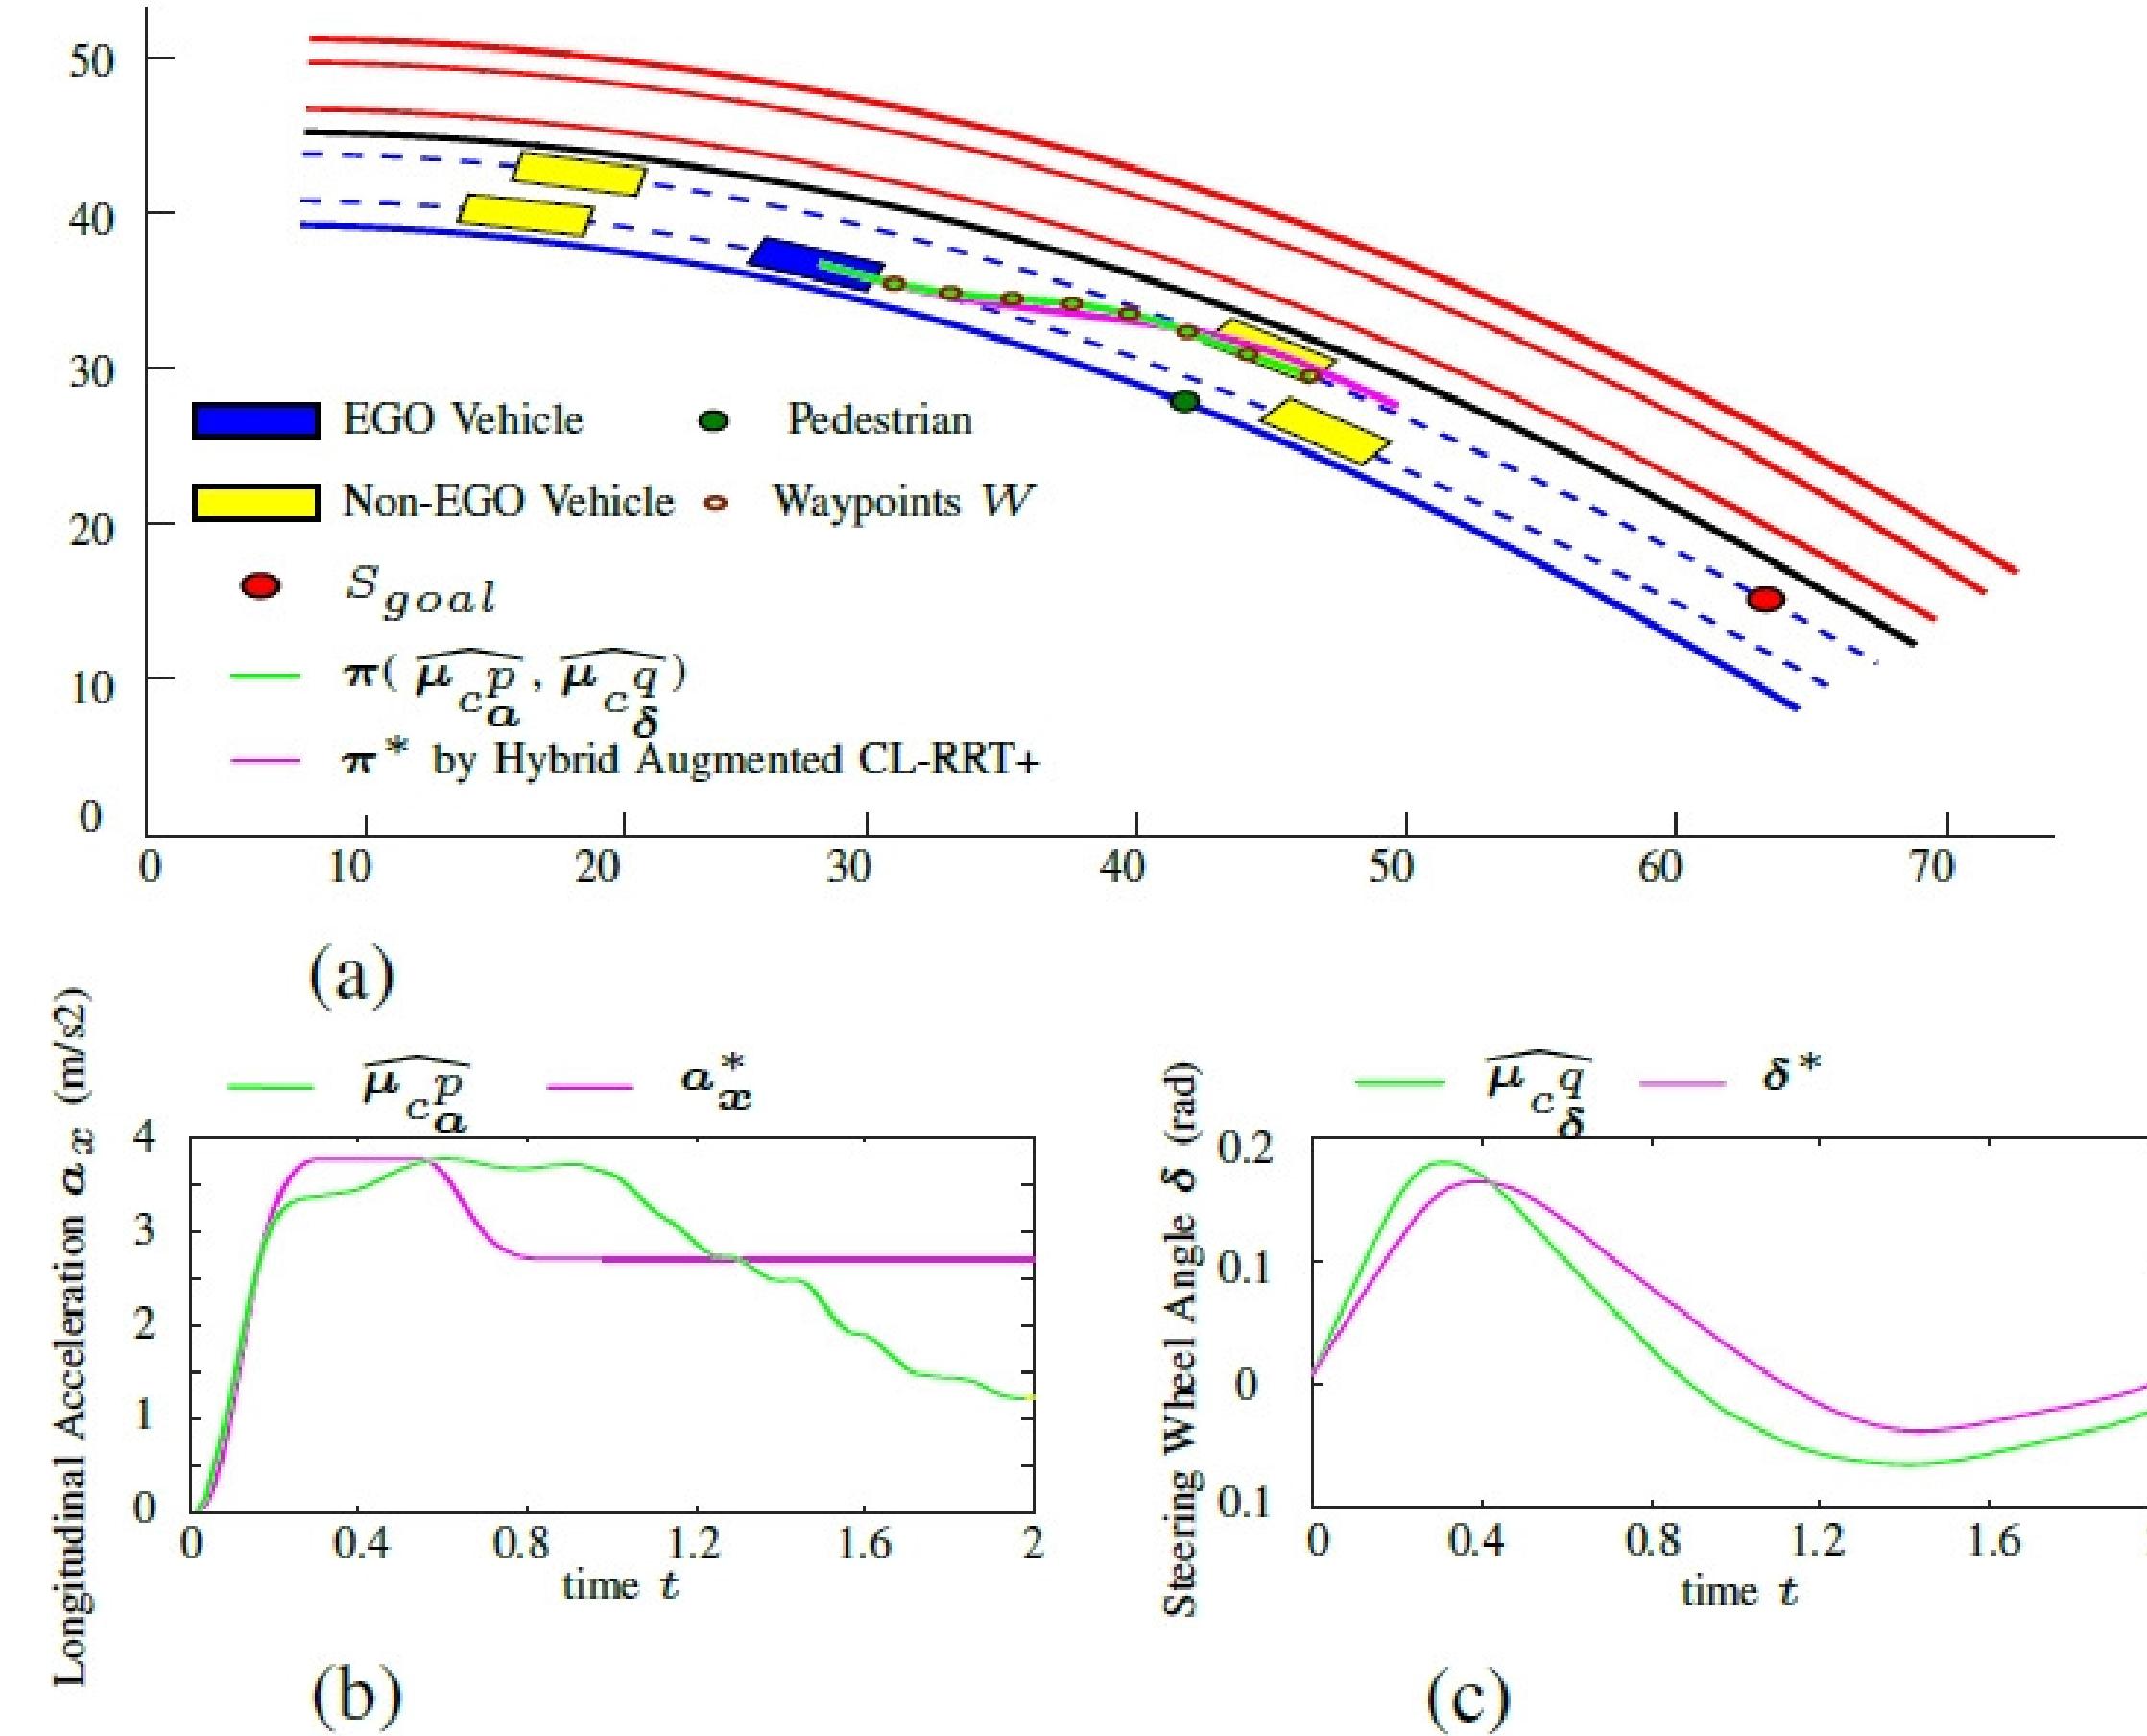
Deep-Learning und Ensemble-Methoden

Maschinelle Lernverfahren in der Umfeldwahrnehmung und Trajektorienplanung
für autonome Fahrzeuge

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

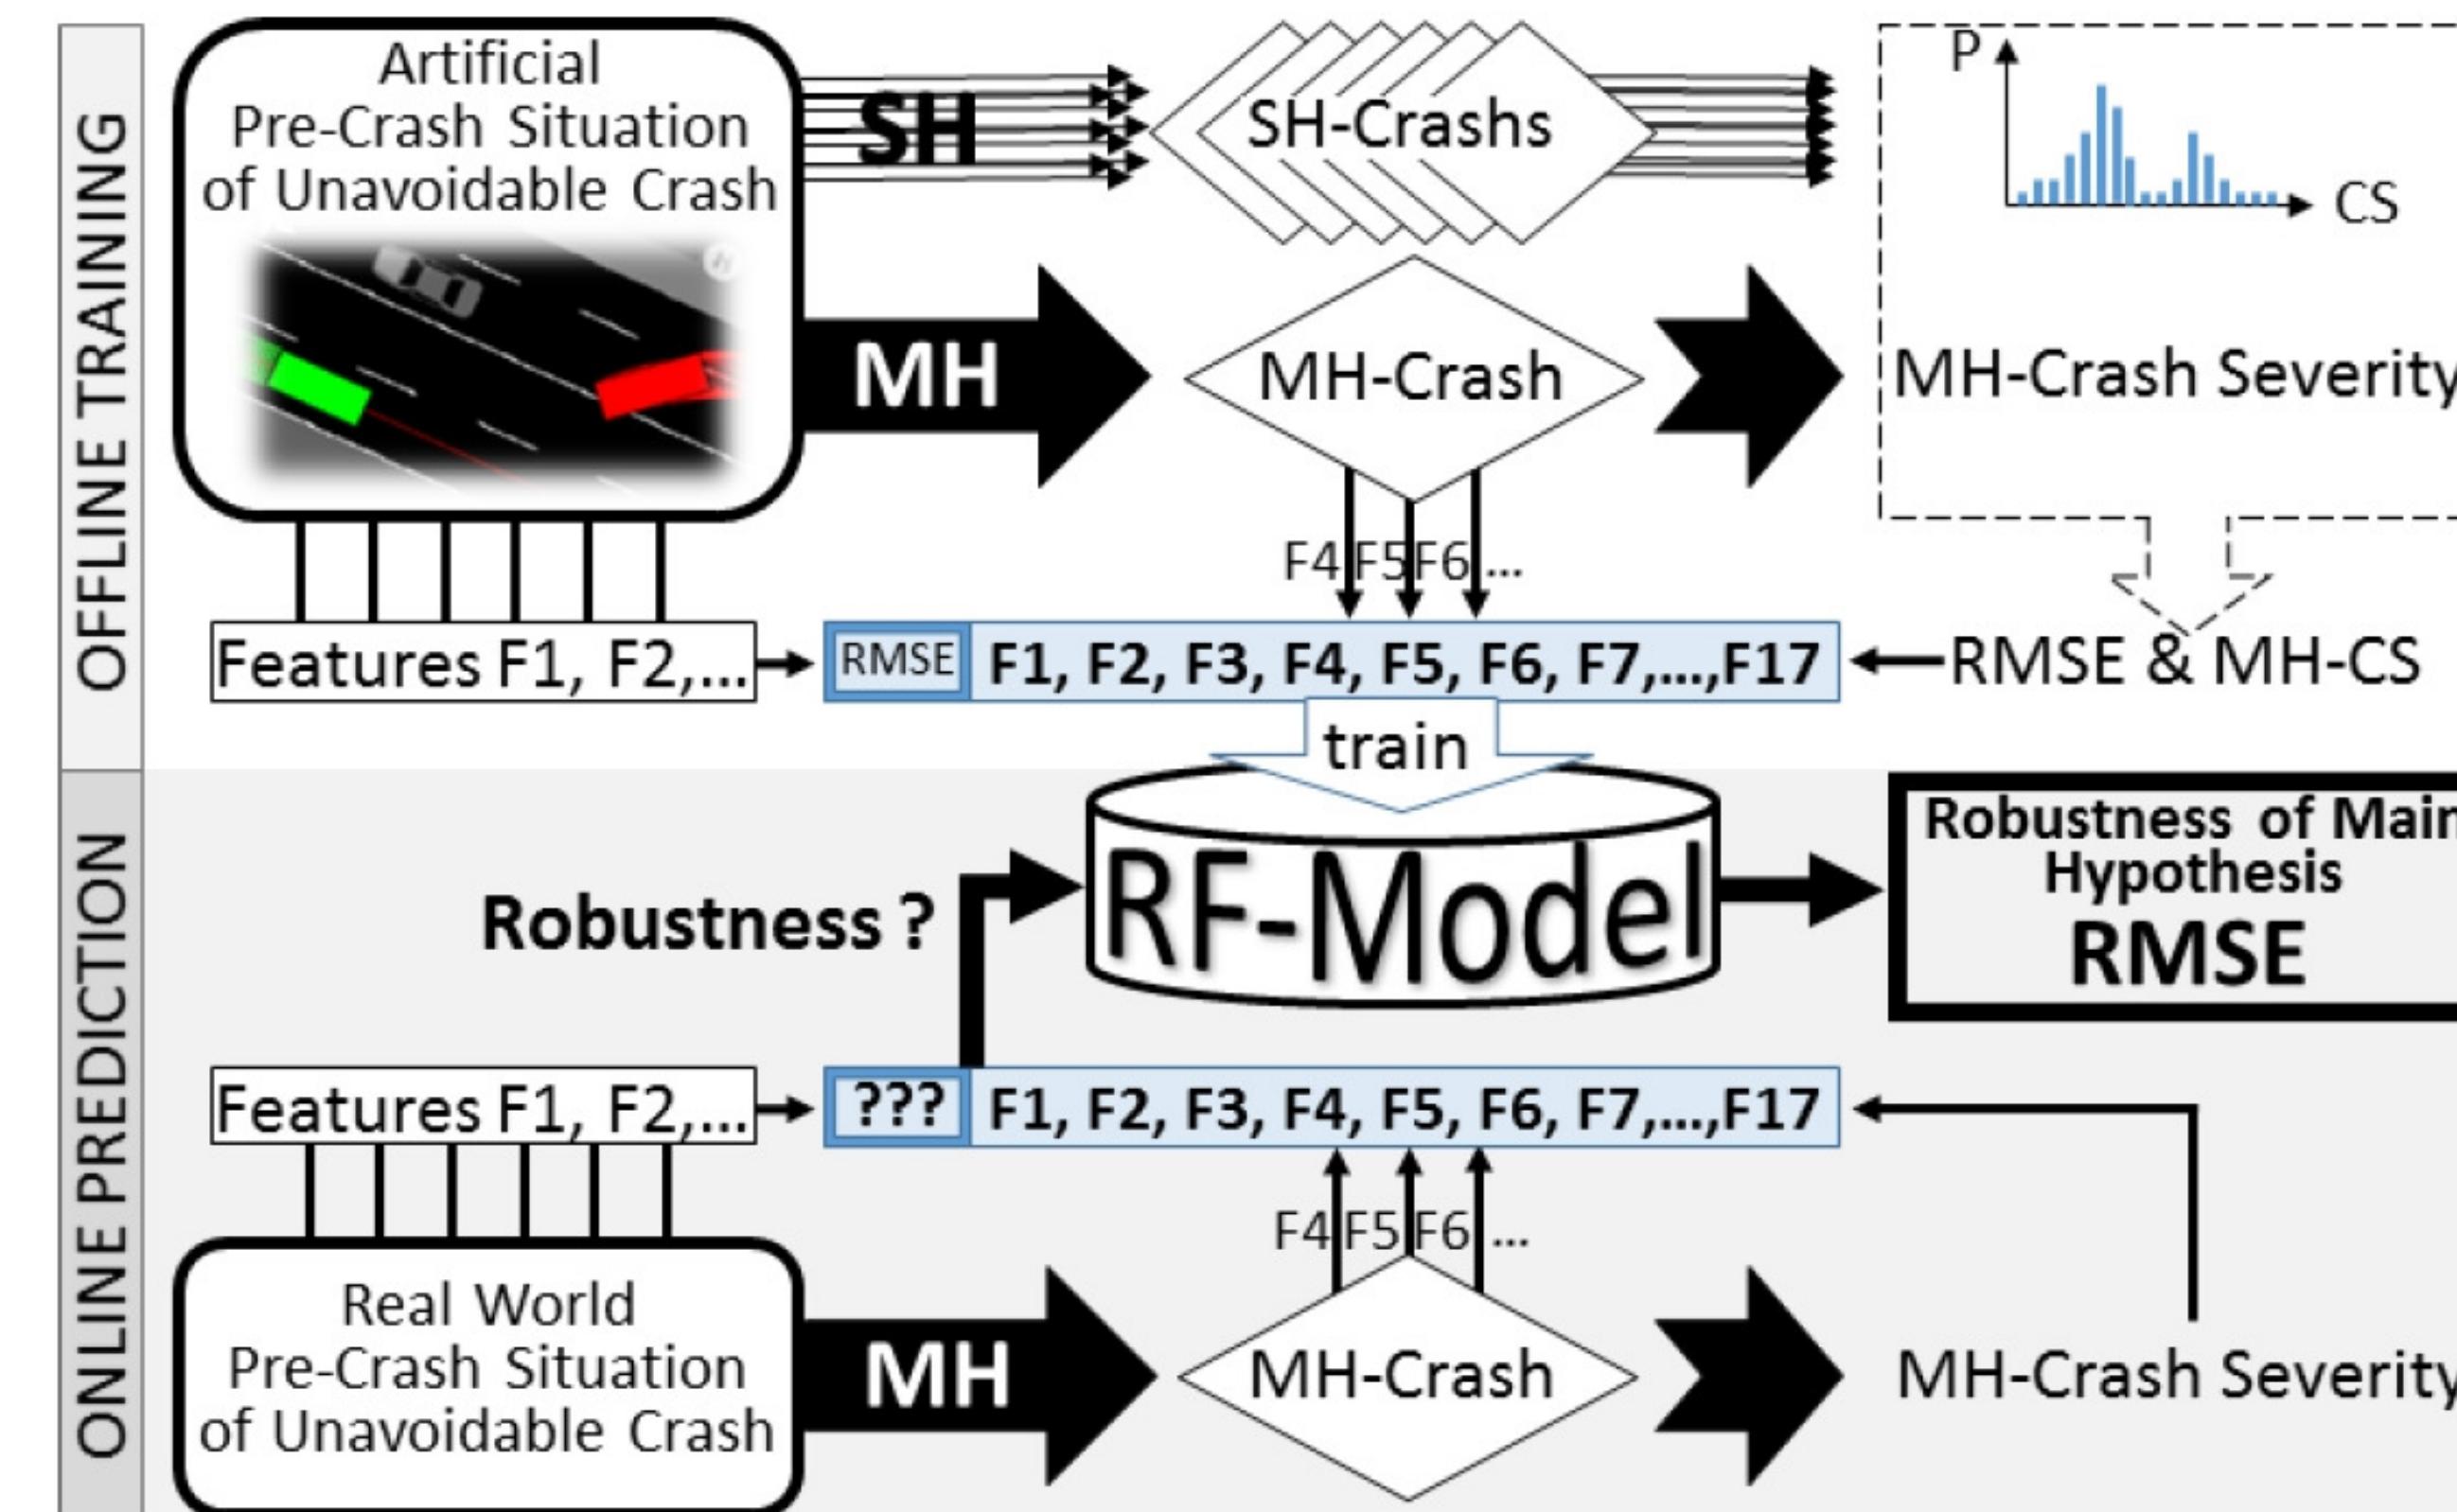
Planung Ausweichmanöver in kritischen Verkehrssituationen



Quelle: A. Chaulwar, M. Botsch, W. Utschick, "A Machine Learning based Biased-Sampling Approach for Planning Safe Trajectories in Complex, Dynamic Traffic-Scenarios", IEEE Intelligent Vehicles Symposium, 2017

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

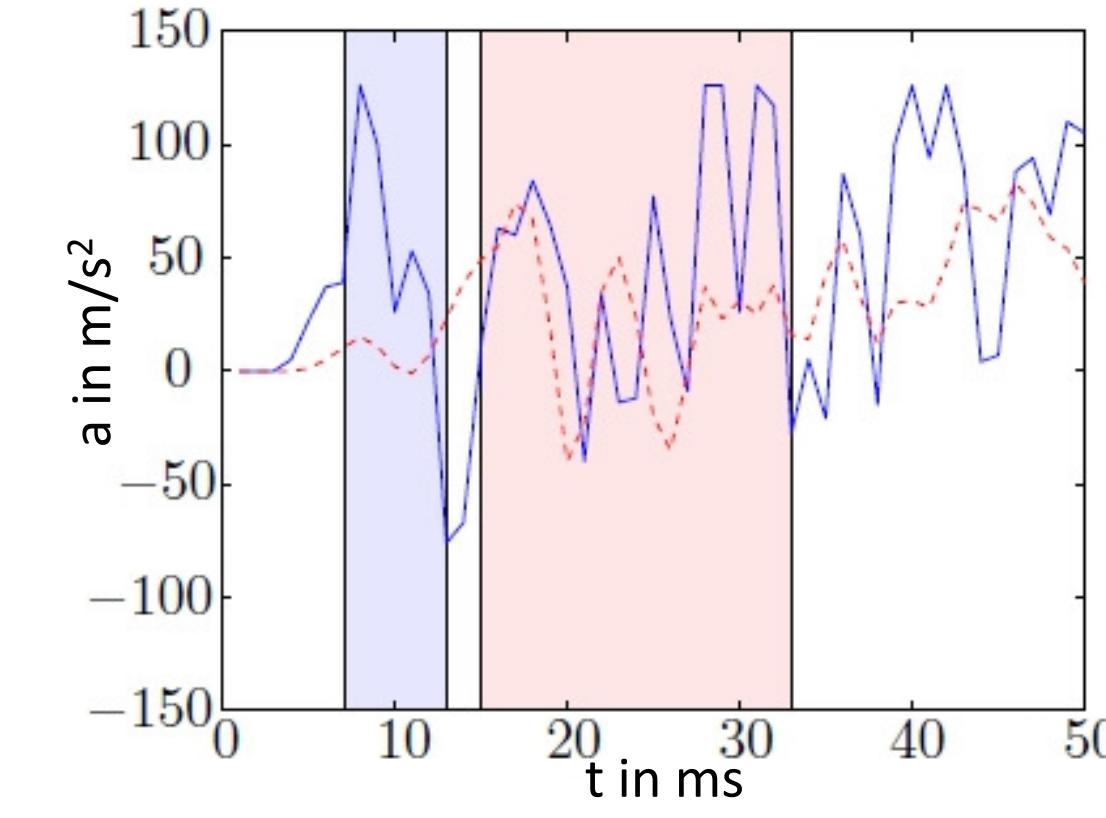
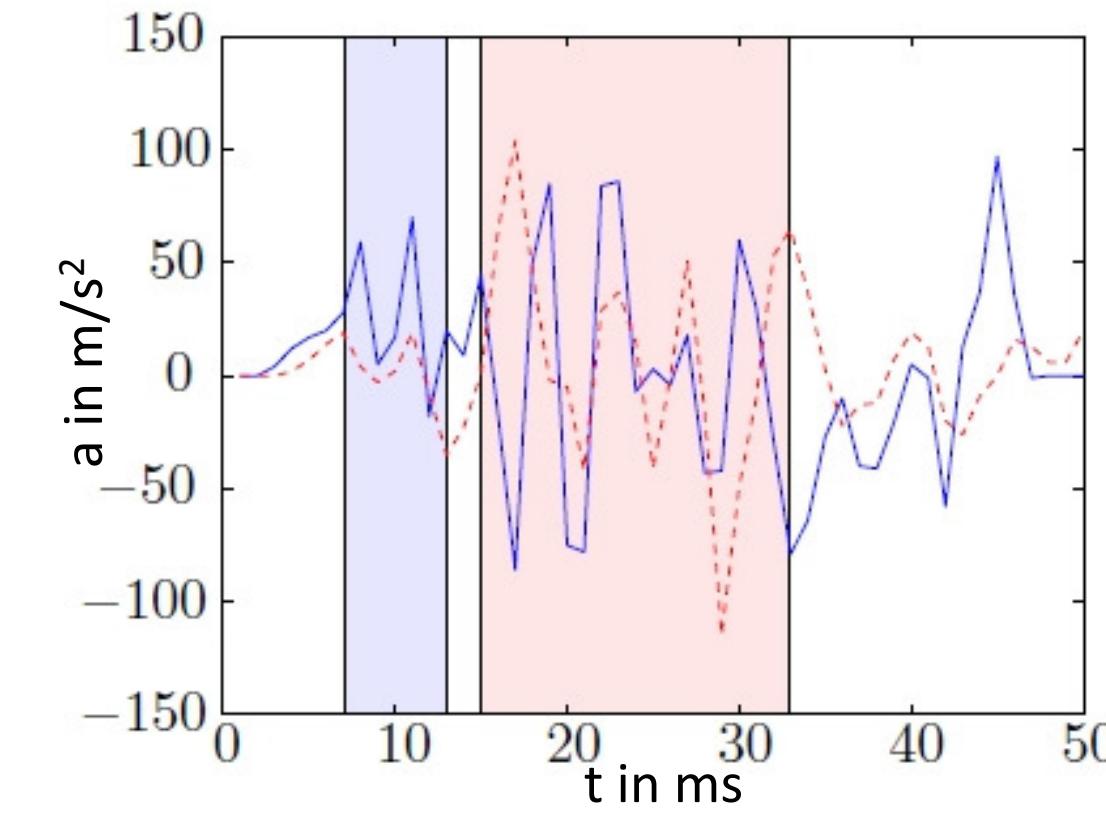
Prädiktion der Crashschwere und der Robustheit der Vorhersage bevor es zur ersten Berührung kommt



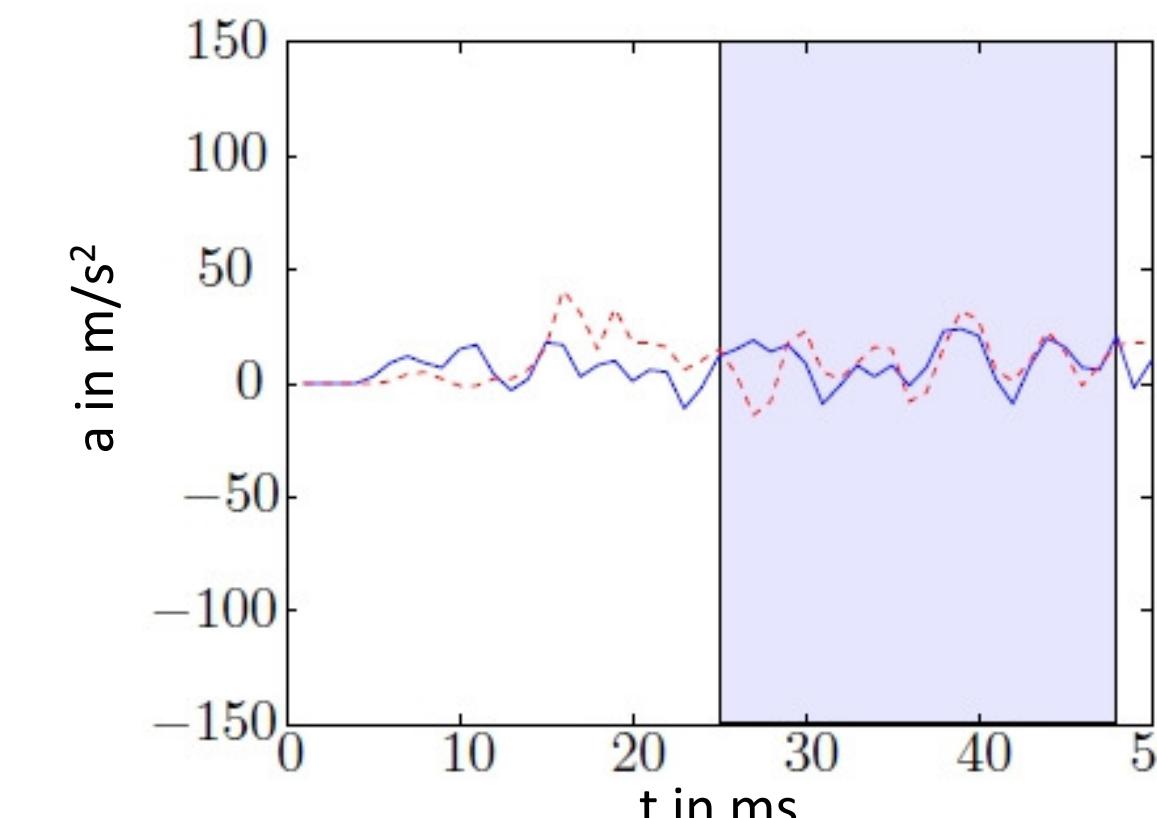
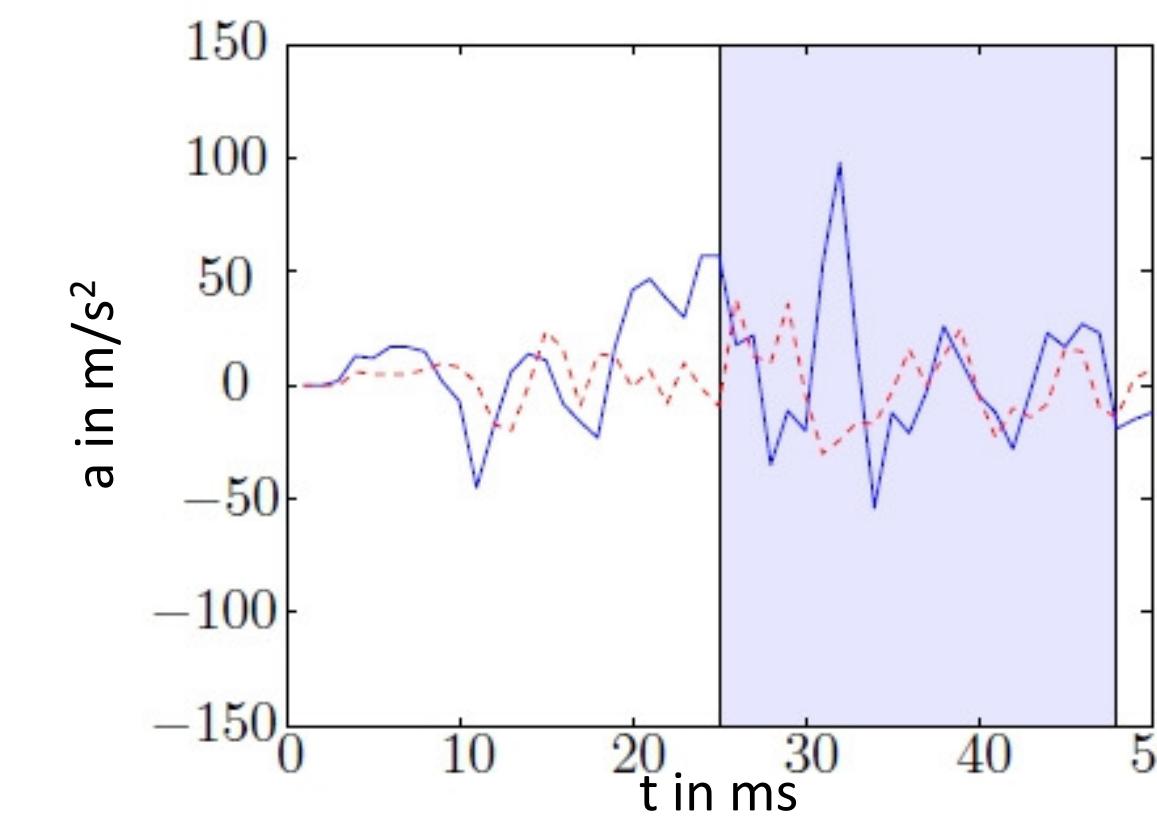
Quelle: M. Müller, P. Nadarajan, M. Botsch, W. Utschick, D. Böhmländer, S. Katzenbogen, "A Statistical Learning Approach for Estimating the Reliability of Crash Severity Predictions", IEEE Intelligent Transportation Systems Society Conference, 2016

Maschinelle Lernverfahren in Anwendungen der Fahrzeugsicherheit

Klassifikation der Crashschwere beruhend auf Beschleunigungssignalen nach der ersten Berührung im Crash



Kollision mit 27 und 56 km/h



Kollision mit 15 und 40 km/h (ODB)

Fazit

- **Maschinelle Lernverfahren** sind von großem Nutzen für das automatisierte Fahren
 - sowohl in der **Umfeldwahrnehmung**
 - als auch in der **Trajektorienplanung**
- **Kontextwissen sehr wichtig: hybride Methoden**

Vielen Dank